



UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL ROSARIO

Ciencia de Datos

Ingeniería en Sistemas de Información

2026

Trabajo Practico Integrador

Profesores: Silvia Scime y Juan Moine.

Turno: Noche.

Comisión N°: 503

Integrantes:

- 51418 – San Pedro, Lucas
- 51190 – Gimenez, Joaquin
- 50739 – Sofia Elisa Coppari
- 46755 – Jeronimo Alvarez

Entendimiento del negocio	4
Contexto y Definición del Problema	4
Objetivos del Proyecto	4
Técnicas de Clasificación Seleccionadas	5
Plan del Proyecto	5
Entendimiento de los datos	6
Descripción de Variables	6
Análisis Exploratorio	8
Evaluación de la Calidad de los Datos	18
Análisis Multivariante	19
Preparación de los Datos	26
Limpieza de datos	26
Modelado	30
Selección y aplicación de técnicas/algoritmos	30
Aspectos comunes a ambos modelos	30
Flujo de trabajo	31
Especificación de los parámetros utilizados para cada técnica	31
Análisis Discriminante (SPSS Statistics)	33
Regresión Logística (SPSS Statistics)	39
Evaluación	44
Especificación del criterio de evaluación	44
Evaluación de los modelos construidos.	46
Selección de los modelos construidos	54
Implementación	56
Aplicación del modelo sobre casosNuevos.xlsx	57
Flujo operativo del agente inteligente	57
Generación del reporte para el Gerente	58
Consideraciones para la operación en producción	58
Análisis multivariante (dataset Clientes)	59
Relaciones entre variables numéricas	59
Relaciones entre variables numéricas y categóricas	63
Análisis de Componentes Principales	64
Preparación de los Datos (Dataset Clientes)	68
Limpieza de datos	68
Decisiones estructurales sobre las variables	69
Transformaciones aplicadas	70
Vista minable resultante	71
Aplicación del Árbol de Decisión sobre casosNuevos.xlsx	71
Reentrenamiento del modelo final	72
Aplicación sobre los casos nuevos	72
Resultados de la predicción	73
Cruce con el dataset de clientes	73
Dataset resultante y salida del notebook	73
Selección y aplicación de técnicas	74

Modelado (Segmentación de Pasajeros)	74
Modelado de K-Medias	74
Modelado de Cluster Jerárquico y Bietápico	87
Modelado de ACP	99
Preparación de los datos	100
Adecuación del análisis	100
Extracción de componentes	101
Selección del número de componentes	102
Interpretación de los componentes	103
Visualización	104
Salida del notebook	105
Síntesis	105
Conclusiones finales del trabajo y aplicación de los modelos seleccionados al dataset casosNuevos.xls	106
Selección del modelo de segmentación	106
Asignación de beneficios según el segmento	107
Aplicación al dataset casosNuevos: reporte final de beneficios	108
Notebook integrador y reporte final	109
Conclusiones finales del trabajo	110

Entendimiento del negocio

Contexto y Definición del Problema

DS Airlines enfrenta un desafío habitual de la industria aeronáutica: la gestión reactiva de demoras. Cuando un vuelo se retrasa sin aviso, el impacto sobre la experiencia del pasajero es importante y genera insatisfacción, reclamos e incluso migración hacia aerolíneas competidoras.

El objetivo del proyecto es desarrollar un agente inteligente capaz de anticipar demoras y actuar proactivamente, ofreciendo beneficios compensatorios según el perfil del pasajero. La solución aborda dos necesidades del negocio:

- Predecir si un vuelo tendrá demora antes de que ocurra, para notificar anticipadamente al pasajero.
- Segmentar a los pasajeros según su perfil, para determinar el beneficio más adecuado (voucher de comida o acceso a sala VIP).

Objetivos del Proyecto

Clasificación de vuelos

Construir un modelo de clasificación que, en base a las características históricas de los vuelos (condiciones climáticas, congestión aérea, día de la semana, entre otras), prediga si un nuevo vuelo tendrá demora. La variable objetivo es Demorado (0 = No demorado, 1 = Demorado).

Segmentación de pasajeros

Construir un modelo de agrupamiento no supervisado que junte a los pasajeros en perfiles diferenciados según sus características y comportamientos de compra. El resultado de esta segmentación permitirá al agente determinar si el pasajero es candidato a recibir un voucher de comida o acceso a la sala VIP.

Criterios de Éxito

DS Airlines establece que la selección del modelo de clasificación se oriente a minimizar costos, considerando el impacto económico que conllevan los beneficios ofrecidos a los

pasajeros. Para traducir este requerimiento en un criterio técnico, analizamos los tipos de error posibles y su consecuencia operativa:

- **Falso Negativo (FN):** el modelo predice que un vuelo no se demora, pero sí lo hace. El pasajero no recibe notificación o beneficio compensatorio alguno, derivando en insatisfacción, reclamos y posible pérdida del cliente hacia la competencia. Esto impacta sobre la imagen de la aerolínea y la fidelización del pasajero, siendo difícilmente cuantificable pero estratégicamente crítico.
- **Falso Positivo (FP):** el modelo predice demora, pero el vuelo sale a tiempo. La aerolínea ofrece un beneficio (voucher o acceso a sala VIP) que no era necesario, generando un costo económico directo y acotado.

Técnicas de Clasificación Seleccionadas

Se evaluarán los siguientes algoritmos, especificados en las pautas de la cátedra:

- **Árbol de Decisión**
- **K-Nearest Neighbors (KNN)**
- **Regresión Logística**

Plan del Proyecto

El proyecto se desarrolla siguiendo la metodología CRISP-DM:

#	Fase	Actividades principales	Herramientas	Período
1	Comprensión del Negocio	Definición del problema, objetivos, criterios de éxito y selección de técnicas.	—	Semana 1
2	Entendimiento de los Datos	Análisis exploratorio univariante y multivariante, evaluación de calidad.	Python	Semana 1-2
3	Preparación de los Datos	Limpieza, tratamiento de outliers y NAs, transformaciones y generación de la vista minable.	Python	Semana 2-3
4	Modelado — Obj. 1	Árbol de Decisión (Modeler + Python), KNN (Python), Regresión Logística (Statistics).	SPSS Modeler, Python, SPSS Statistics	Semana 3-4

5	Evaluación	Comparación de modelos de clasificación. Selección según criterio de minimización de costos.	Python	Semana 4-5
6	Implementación	Aplicación de modelos sobre casosNuevos.xls. Generación del reporte final para el Gerente.	Python	Semana 5

Entendimiento de los datos

Descripción de Variables

Dataset de Vuelos (vuelos.xls)

Variable	Descripción	Tipo	Rol
<u>Id_vuelo</u>	Identificador único del vuelo	Numérica	Identificador
<u>Aeropuerto_origen</u>	Aeropuerto de salida	Categórica	Predictora
<u>Aeropuerto_destino</u>	Aeropuerto de llegada	Categórica	Predictora
<u>Hora_salida_programada</u>	Hora prevista de salida	Numérica	Predictora
<u>Dia_semana</u>	Día de la semana del vuelo	Categórica	Predictora
<u>Distancia_vuelo</u>	Distancia en kilómetros	Numérica	Predictora
<u>Condiciones_climaticas</u>	Estado del clima en el momento del vuelo	Categórica	Predictora
<u>Congestion_aerea</u>	Nivel de tráfico aéreo	Categórica	Predictora
<u>Tipo_avion</u>	Modelo de la aeronave utilizada	Categórica	Predictora
<u>Ocupacion_vuelo</u>	Porcentaje de asientos ocupados	Numérica	Predictora
<u>Temporada_alta</u>	Indica si el vuelo ocurrió en temporada alta	Booleana	Predictora
<u>Puerta_embarque</u>	Número de puerta de embarque asignada	Numérica	Predictora
<u>Visibilidad</u>	Visibilidad en kilómetros al momento del vuelo	Numérica	Predictora

<u>Tiempo_estimado_vuelo</u>	Tiempo estimado del vuelo en minutos	Numérica	Predictora
<u>Demorado</u>	Variable objetivo: 0 = No demorado / 1 = Demorado	Categórica (binaria)	Predicha

Dataset de Clientes (clientes.xlsx)

Variable	Descripción	Tipo	Rol
Id_cliente	Identificador único del cliente	Numérica	Identificador
Sexo	Sexo del cliente	Categórica	Entrada
Provincia	Provincia de residencia del cliente	Categórica	Entrada
Edad	Edad del cliente en años	Numérica	Entrada
Ocupación	Ocupación laboral del cliente	Categórica	Entrada
Cant_vuelos	Cantidad de vuelos acumulados históricos	Numérica	Entrada
Clase_preferida	Clase tarifaria más frecuente (económica / primera clase)	Categórica	Entrada
Gasto_acumulado	Consumo histórico en pasajes (USD)	Numérica	Entrada
Gasto_acumulado_extra	Consumo histórico en servicios extra (USD)	Numérica	Entrada
ProgramaMillas	Indica si está afiliado al programa de millas	Categórica	Entrada
Cantidad_millas	Millas acumuladas (si está afiliado)	Numérica	Entrada
Ingreso_mensual	Sueldo mensual del cliente (USD)	Numérica	Entrada
Anticipacion_compra_promedio	Promedio de días de anticipación en la compra de pasajes	Numérica	Entrada
Canal_compra	Medio preferido para la compra (app, web, agencia, aeropuerto)	Categórica	Entrada

Las variables “Id_cliente” e “Id_vuelo” son identificadores, no serán utilizadas como predictor.

La variable objetivo “Demorado” enmarca al problema como una clasificación binaria.


Análisis Exploratorio

Análisis Univariante (Dataset Vuelos)

Variable objetivo: demora

Clase	Cantidad	Proporción
0 — No demorado	10.222	68,15 %
1 — Demorado	4.778	31,85 %

La variable objetivo presenta una distribución desbalanceada: 10.222 vuelos no demorados (68,1%) frente a 4.778 vuelos demorados (31,9%), factor relevante a considerar en el modelado, ya que puede sesgar al clasificador hacia la clase mayoritaria.




Variables numéricas, dataset vuelos

	distancia_vuelo	ocupacion_vuelo	puerta_embarque	visibilidad	tiempo_estimado_vuelo	demora
count	15000.000000	15000.000000	15000.000000	15000.000000	15000.000000	15000.000000
mean	1811.709667	71.383327	25.052200	15.371927	169.874467	0.318533
std	2276.650883	15.964749	14.130638	8.633404	171.010583	0.465923
min	35.000000	9.200000	1.000000	0.200000	22.000000	0.000000
25%	300.000000	61.100000	13.000000	8.100000	58.000000	0.000000


50%	960.000000	73.400000	25.000000	15.600000	103.000000	0.000000
75%	2620.000000	83.800000	37.000000	22.900000	220.000000	1.000000
max	10050.000000	99.800000	49.000000	30.000000	802.000000	1.000000

Distancia de Vuelo


El histograma muestra una distribución de las distancias con fuerte asimetría positiva (sesgada hacia la derecha). La mayoría de las frecuencias se concentra en los valores bajos, lo que indica que el grueso de la operación corresponde a vuelos de corto o medio alcance (rutas de cabotaje, regionales o conexiones frecuentes). La frecuencia cae abruptamente al aumentar la distancia, aunque la cola se extiende lo suficiente como para evidenciar un volumen menor de vuelos de muy larga distancia (rutas transoceánicas o internacionales directas).



La "caja" del diagrama confirma visualmente lo visto en el histograma: al estar ubicada hacia los valores bajos del eje X, demuestra que la distancia mediana de los vuelos es relativamente corta. Nos permite ver con claridad los outliers y nos ayuda a explicar que, aunque matemáticamente estas distancias extremas son atípicas, desde la perspectiva del negocio son válidas. Representan las rutas de mayor alcance de la compañía y, por lo tanto, no deben ser eliminadas para el modelado posterior.





Ocupación del vuelo




La distribución de la ocupación de los vuelos (n = 15.000) muestra un comportamiento asimétrico con sesgo a la izquierda, con una media de 71,38% y una desviación estándar de

15,97. El grueso de los vuelos opera entre el 63% y el 84% de ocupación, con una mediana cercana al 74%. Tanto el histograma como el boxplot evidencian la presencia de valores atípicos por debajo del 30% de ocupación, que corresponden a un conjunto reducido de vuelos con demanda excepcionalmente baja que se alejan del comportamiento típico de la operación.





Puerta de embarque

La variable puerta de embarque tiene una distribución uniforme, con media de 25,05 y desviación estándar de 14,13: las puertas son asignadas equitativamente en el rango disponible (1 a 50), sin concentración en particular. El boxplot confirma la dispersión homogénea, con una mediana cercana a 25 y el 50% central de los datos entre aprox. las puertas 13 y 37, sin valores atípicos y bigotes que se extienden simétricamente hasta los extremos. Esto sugiere una asignación de puertas aleatoria, con operación equilibrada entre las disponibles.



Visibilidad








Distribución

bimodal

con sesgo positivo, con media de 15,37 y desviación estándar de 8,63. El histograma muestra comportamientos diferenciados: un pico pronunciado en valores muy bajos (~1-2 km), que podría asociarse a niebla o mal tiempo, seguido de una caída abrupta y luego una distribución relativamente uniforme en ~5 y 30 km. El boxplot muestra una mediana cercana a 16 km y el 50% central de los datos entre ~9 y 23 km, con bigotes que se extienden hasta los extremos sin

valores atípicos, aunque la cola inferior más larga confirma el sesgo hacia visibilidades reducidas.

Tiempo estimado de vuelo



La variable (n = 15.000) presenta una distribución fuertemente asimétrica positiva (sesgada a la derecha), con media de 169,87 minutos y desviación estándar de 171 minutos, lo que muestra gran dispersión. El histograma muestra que la mayoría de los vuelos se concentran debajo de los 150 minutos, con un pico principal entre los 30 y 50 minutos, sugiriendo predominio de vuelos de corta y media distancia. Se observa un segundo grupo de frecuencias en torno a los 600-800 minutos, que indica que hay vuelos de larga distancia como segmento diferenciado. En el boxplot la mediana se ubica en ~110 minutos, el 50% central entre 75 y 220 minutos, y muchos valores atípicos arriba de los 500, que corresponden a los vuelos de larga duración.


Variables categóricas

Condiciones Climáticas: Se muestra predominio del tiempo despejado, con 6.800 casos, un ~45% del total. Sigue nublado, con ~3.800 registros, y lluvia con 2.300.

Las más extremas y menos frecuentes son tormenta (~1.200) y niebla (~1.100) registros. La mayoría de los vuelos opera bajo condiciones favorables, pero más de la mitad del total se desarrolla bajo algún tipo de condición climática adversa.

Congestión aérea: La mayoría de las operaciones se dan en un entorno de congestión "Baja", seguidas por congestión "Media", y siendo la congestión "Alta". En términos generales, los vuelos operan bajo condiciones de tráfico aéreo favorables.


Aeropuerto de origen y destino: Distribución



heterogénea entre los 22 aeropuertos registrados, con concentración en ciertos nodos: CWB (≈ 2.150), BRC (≈ 1.950), FLN (≈ 1.450), MAD (≈ 1.575) y ROS (≈ 1.350), lo que los posiciona como los principales puntos de salida de la operación. Aeropuertos como IAH, GRU, NON, SJO y ASU concentran muy pocos vuelos, sugiriendo rutas de baja frecuencia. El gráfico de aeropuerto de destino presenta un patrón muy


similar al de origen, lo que refuerza la consistencia de la red operativa.

Hora de salida programada: muestra una distribución bimodal con dos picos de alta




frecuencia a lo largo del día. El más pronunciado se concentra entre las 8:00 y las 9:00 hs, con 400 vuelos por franja horaria, y el segundo entre las 15:00 y las 16:00 hs, con 300-350 vuelos. Se observa una caída en el mediodía y durante la madrugada, que representa el valle mínimo de operación.

Día de la semana: muestra una distribución casi




homogénea, con frecuencias entre 1.950 y 2.400 vuelos por día. Los días de mayor actividad son viernes (≈ 2.375) y domingos (≈ 2.250), seguidos por sábado y miércoles, mientras que martes y lunes registran los volúmenes más bajos.

Temporada alta: vacaciones de verano, receso



invernal, y fines de semana largos abarcan menos meses que el resto del año estándar: El dataset refleja la operación anual sostenida de la aerolínea y no un recorte sesgado de un período pico. Durante los picos donde la infraestructura aeroportuaria se estresa (más pasajeros, más equipaje, procesos más lentos), se suelen generar retrasos.

Tipo de avión: muestra 12 modelos distintos,



con una distribución moderadamente


heterogénea. En el extremo inferior se ubican el Airbus A330 y el A350 con ≈700 vuelos cada uno. La distribución refleja una flota equilibrada entre modelos de corto y mediano alcance, con una participación secundaria de aeronaves de gran porte destinadas a rutas específicas.

Análisis Univariante (Dataset Clientes)

Variables numéricas

	id_cliente	edad	cant_vuelos	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio
count	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000	50000.000000
mean	25000.500000	37.827400	17.071860	6759.361980	3062.882160	19.91066
std	14433.901067	11.479385	15.750424	23529.642402	3780.380841	21.40158
min	1.000000	18.000000	1.000000	0.000000	300.000000	0.00000
25%	12500.750000	29.000000	6.000000	0.000000	1250.000000	5.00000
50%	25000.500000	38.000000	14.000000	0.000000	2100.000000	13.00000
75%	37500.250000	46.000000	21.000000	0.000000	3823.000000	27.00000
max	50000.000000	80.000000	99.000000	541589.000000	350075.000000	180.00000



Edad



Presenta una distribución asimétrica positiva, con media de 37,83 años y desvío estándar de 11,48. El histograma muestra un pico pronunciado en los 18 años, seguido de una distribución que se extiende hacia la derecha, con mayor concentración entre los 30 y 45



años y un decaimiento gradual hasta los 80. El boxplot confirma esta forma: la caja se ubica entre los 29 y 46 años con mediana cercana a 38, y muestra una cantidad reducida de outliers superiores (entre 72 y 80 años), valores válidos dentro del dominio. La base de clientes es mayormente adulta joven, con pocos pasajeros mayores de 65 años.

Gasto Acumulado Extra





Distribución extremadamente asimétrica positiva (media \$953,73 USD; desvío \$1.987,62, que duplica a la media, alta dispersión). Mayoría de los clientes concentrada cerca de cero, con caída abrupta hacia valores mayores: se gasta poco o nada en servicios extra. El boxplot lo confirma, con una caja imperceptible en la base y muchos outliers dispersos que llegan hasta casi \$50.000 USD, correspondientes al segmento de alto consumo.

Anticipación compra promedio





La variable `anticipacion_compra_promedio` presenta distribución fuertemente asimétrica positiva (media 19,91 días; desvío 21,40, mayor que la media e indicando alta dispersión). El histograma muestra que la mayoría compra con poca anticipación, concentrándose en los primeros días con frecuencia que decae rápidamente. El boxplot confirma una caja compacta y baja (entre 5 y 27 días aproximadamente) y una gran cantidad de outliers que se extienden hasta los 180 días. El comportamiento dominante es la compra de último momento, aunque un segmento minoritario planifica con meses de anticipación.

Ingreso mensual





La variable ingreso_mensual presenta la asimetría más extrema de las analizadas (media \$3.062,88 USD; desvío \$3.780,38, que supera ampliamente a la media). El histograma muestra casi la totalidad de los clientes agrupada en valores muy bajos, con la distribución prácticamente colapsada en la primera barra. El boxplot hace visible la magnitud del problema: caja casi invisible en la base y outliers que se dispersan hasta valores cercanos a \$350.000 USD, con dos casos extremos que superan los \$200.000. La base de clientes es mayoritariamente de ingresos bajos/medios, con un grupo reducido de altísimo poder adquisitivo que distorsiona fuertemente la media y el desvío.

Gasto acumulado





La variable gasto_acumulado presenta un patrón muy similar al de ingreso_mensual, con asimetría pronunciada hacia la derecha (media \$6.587,56 USD; desvío \$12.439,88, que casi duplica a la media). El histograma muestra mayor concentración en valores bajos (hasta ~\$20.000), con frecuencia que decae rápido aunque más gradual que en ingreso_mensual. El boxplot confirma una caja comprimida en la base de la escala y una nube densa de outliers que se extiende hasta \$250.000 USD, con un caso extremo cercano a \$300.000.

Cantidad millas




La variable `cantidad_millas` presenta la asimetría más extrema del dataset, estructuralmente esperable: más de 38.000 clientes no están afiliados al programa y tienen valor 0, generando la barra dominante del histograma. Entre los afiliados (cerca de 12.000), las millas se distribuyen también de forma asimétrica (media 6.759,36; desvío 23.529,64, que la triplica ampliamente). El boxplot lo refleja con una caja prácticamente inexistente en la base y outliers que llegan hasta casi 600.000 millas en un caso extremo. La media resulta poco representativa para el conjunto total; sería más adecuado analizar la variable de forma separada entre afiliados y no afiliados.

Cantidad vuelos




La variable `cant_vuelos` presenta una distribución bimodal con asimetría positiva (media 17,07; desvío 15,75). El histograma revela dos zonas de alta frecuencia: una primera concentración entre 1 y 10 vuelos y una segunda meseta uniforme entre 10 y 25, tras la cual la frecuencia cae abruptamente. Esto sugiere al menos dos perfiles de clientes: viajeros ocasionales y moderadamente frecuentes. El boxplot confirma una caja entre 5 y 25 vuelos con mediana cercana a 15, y una abundante nube de outliers por encima de los 40, correspondientes a los viajeros muy frecuentes.

Variables categóricas




Sexo

Sexo: muestra una distribución equilibrada, con frecuencias similares para femenino y masculino. La categoría "No binario" representa una proporción muy pequeña del total. No se presenta sesgo de género relevante.




Provincia

Provincia: muestra una distribución relativamente uniforme, con frecuencias entre 1.000 y 2.500 clientes por provincia. CABA, Buenos Aires, Córdoba, Salta y Tucumán presentan valores ligeramente superiores. Las de menor representación rondan los 1.000 clientes.



Ocupación


Muestra una distribución no uniforme. La categoría Empleado domina con ~11.500 clientes, y jubilado es la menos representada con ~700 clientes. Los clientes son mayoritariamente trabajadores en relación de dependencia.



Clase preferida


La variable clase_preferida muestra una distribución desigual entre sus tres categorías. La económica es dominante con ~37.000 clientes (aprox. 74%), la ejecutiva ~11.000 y la primera clase es la menos frecuente, con apenas ~2.000. Esto es coherente con la distribución de ingresos: la mayoría se concentra en niveles medios-bajos y solo una minoría accede a las categorías tarifarias superiores.

Programa millas



ProgramaMillas muestra que aprox. el 76% de los clientes (~ 38.000) no está afiliado al programa de millas, y solo el 24% restante (alrededor de 12.000) lo está. Esto reafirma lo observado en cantidad_millas y en el perfil predominante de viajero ocasional identificado en cant_vuelos: la fidelización mediante millas es un comportamiento minoritario, del segmento de clientes frecuentes y mayor poder adquisitivo.

Canal compra



Canal_compra: muestra preferencia por canales digitales. Web domina con ~20.000 clientes, seguido por App con ~19.000, sumando el 78% del total. Agencia es el canal intermedio con ~7.500 clientes, y la compra en Aeropuerto es menos frecuente con ~4.500. Muestra clientes con alto grado de adopción tecnológica, donde la compra presencial/ tradicional es residual.

Evaluación de la Calidad de los Datos

Valores atípicos

En el dataset vuelos.xlsx se identificaron valores atípicos en distancia_vuelo (máximo de 10.050 km) y tiempo_estimado_vuelo (máximo de 802 minutos), ambas con distribuciones asimétricas hacia la derecha. Las variables ocupacion_vuelo, puerta_embarque y visibilidad no presentaron valores atípicos de consideración. En el dataset clientes.xlsx se detectaron valores atípicos en ingreso_mensual (máximo USD 350.075 frente a una media de USD 3.063), gasto_acumulado (máximo USD 253.140), gasto_acumulado_extra (máximo USD 47.395), cant_vuelos (hasta 99 vuelos) y anticipacion_compra_promedio (hasta 180 días). Las variables edad y cantidad_millas no presentaron valores atípicos relevantes.



Valores nulos

Ambos datasets presentan completitud total: ninguna variable de vuelos.xlsx ni de clientes.xlsx contiene valores nulos o faltantes sobre los 15.000 y 50.000 registros respectivamente, y tampoco se detectaron duplicados. Los valores 0 en cantidad_millas no son faltantes, sino que corresponden a clientes no afiliados al programa. Se decidió no aplicar ningún tratamiento sobre los valores atípicos: no responden a errores de carga ni a inconsistencias, sino a situaciones reales del dominio (rutas de larga distancia, clientes de alta frecuencia, ingresos elevados, planificación anticipada). Conservarlos es una decisión deliberada porque aportan información valiosa sobre casos excepcionales relevantes para los modelos de predicción y la segmentación. Al no haber valores nulos, tampoco fue necesario aplicar técnicas de imputación.

Análisis Multivariante

Matriz de dispersión

La matriz de dispersión deja en claro una fuerte relación lineal entre la distancia de vuelo y el tiempo estimado, indicando colinealidad entre ambas variables, esto indica que ambas variables “dicen” prácticamente lo mismo. El resto de las variables no presenta relaciones lineales significativas.



Correlaciones de Pearson

		Correlaciones						
		distancia_vuelo	ocupacion_vuelo	temporada_alta	puerta_embarque	visibilidad	tiempo_estimado_vuelo	demora
distancia_vuelo	Correlación de Pearson	1	,009	,016	-,012	,009	,999***	,008
	Sig. (bilateral)		,263	,054	,137	,294	<,001	,316
	N	15000	15000	15000	15000	15000	15000	15000
ocupacion_vuelo	Correlación de Pearson	,009	1	,006	,006	,014	,009	,015
	Sig. (bilateral)	,263		,431	,426	,094	,252	,068
	N	15000	15000	15000	15000	15000	15000	15000
temporada_alta	Correlación de Pearson	,016	,006	1	,016	,005	,016*	,099***
	Sig. (bilateral)	,054	,431		,057	,521	,045	<,001
	N	15000	15000	15000	15000	15000	15000	15000
puerta_embarque	Correlación de Pearson	-,012	,006	,016	1	,003	-,012	,000
	Sig. (bilateral)	,137	,426	,057		,682	,145	,993
	N	15000	15000	15000	15000	15000	15000	15000
visibilidad	Correlación de Pearson	,009	,014	,005	,003	1	,009	-,127***
	Sig. (bilateral)	,294	,094	,521	,682		,295	<,001
	N	15000	15000	15000	15000	15000	15000	15000
tiempo_estimado_vuelo	Correlación de Pearson	,999***	,009	,016*	-,012	,009	1	,008
	Sig. (bilateral)	<,001	,252	,045	,145	,295		,334
	N	15000	15000	15000	15000	15000	15000	15000
demora	Correlación de Pearson	,008	,015	,099***	,000	-,127***	,008	1
	Sig. (bilateral)	,316	,068	<,001	,993	<,001	,334	
	N	15000	15000	15000	15000	15000	15000	15000

Correlación muy fuerte: distancia_vuelo y tiempo_estimado_vuelo presentan una correlación de 0,999 ($p < 0,001$), esperable: a mayor distancia, mayor tiempo de vuelo. Esta relación indica que ambas variables aportan información prácticamente idéntica, por lo que podría eliminarse una en la fase de transformación para evitar redundancia.


Correlación negativa moderada: visibilidad y demora muestran -0,127 ($p < 0,001$): a menor visibilidad, más demoras. Aunque el valor es bajo, es la relación más relevante con la variable target y tiene sentido de negocio claro.

Correlación negativa baja: puerta_embarque y tiempo_estimado_vuelo presentan -0,012, y temporada_alta con demora muestra 0,099 (significativa), sugiriendo una leve asociación entre temporada alta y mayor probabilidad de demora.

Resto de variables: las demás correlaciones son cercanas a cero y no significativas, indicando que las variables numéricas son en su mayoría independientes entre sí, lo que es favorable para el modelado.

Relación entre variables categóricas y la variable objetivo (demora)


Condiciones Climáticas: Tormenta y lluvia muestran una proporción de demoras relativamente mayor en relación al tamaño de su barra, mientras que niebla también




presenta una proporción considerable.

Despejado y nublado tienen una porción bordó visualmente menor en relación a su total. El gráfico sugiere que las condiciones climáticas adversas están asociadas a mayor demora.


congestión aérea: Muestra que el sistema absorbe eficientemente el tráfico normal y moderado, manteniendo la puntualidad bajo control. Sin embargo, existe un "punto de quiebre" cuando la congestión llega al nivel "Alta". En este escenario crítico, los procesos estándar fallan y la impuntualidad se vuelve la norma. Esto demuestra que la variable congestión aérea es un excelente predictor para la variable objetivo.



temporada alta: La barra de temporada baja (0) es más grande: la mayoría de los vuelos operan fuera de temporada alta. En la proporción interna de demoras, temporada alta (1) muestra una tasa de demorados (bordó) de ~39% sobre su total, vs 30% en temporada baja, indicando mayor probabilidad de demora en temporada alta: En alta demanda incrementa la congestión aeroportuaria, la rotación de aeronaves se vuelve más ajustada y cualquier inconveniente se propaga con mayor facilidad. Temporada alta resulta tener poder discriminante respecto a la demora y debería considerarse como predictor relevante.




hora salida programada: Se muestra una distribución estable a lo largo de todo el eje X. La proporción de vuelos que salen a tiempo domina siempre sobre la proporción de retrasados. En ningún momento del día se observa una inversión de la tendencia o un pico donde las demoras superan a los




vuelos a tiempo, esta variable no nos aporta tanta información (Gain).



Dia_semana: Distribución porcentual homogénea a lo largo de todas las categorías del eje X. No se observan variaciones, picos ni caídas significativas en la tasa de demoras al comparar un día con otro. La variable no aporta ganancia de información significativa.



Tipo Avión: Todos los modelos oscilan sin diferencias importantes. No aporta información predictiva relevante.




aeropuerto de origen y destino:




No hay ni aeropuertos que concentren retrasos desproporcionados, ni que tengan puntualidad perfecta. El nivel base de impuntualidad (aprox. 20%) responde a un comportamiento general de la compañía y no a fallas de un origen particular. Las variables no aportan una ganancia de información relevante.

Relación entre variables numéricas y la variable objetivo (demora)



Distancia_vuelo: En rangos de distancia corta (hasta ~1.000 km) los no demorados dominan sobre los demorados, pero en distancias largas (>6.000 km)


la proporción de demorados aumenta relativamente. Los vuelos de larga distancia tienen mayor proporción de demoras que los cortos. La distancia podría tener poder discriminante moderado.



insuficiente para que sea un predictor fuerte por sí solo.


tiempo_estimado_vuelo

El histograma de tiempo_estimado_vuelo por demora replica el patrón de distancia_vuelo (correlación 0,999), con medias prácticamente idénticas entre clases (168,95 vs 171,85 min). En vuelos cortos (hasta 100 min) predomina el azul; entre 200 y 400 min crece la proporción de rojo. Los vuelos largos concentran más demoras, pero la diferencia es




ocupacion_vuelo

Las distribuciones de ocupacion_vuelo según demora son prácticamente idénticas (medias 71,22% vs 71,73%; desvíos 15,81 vs 16,28). La diferencia mínima entre clases indica que el porcentaje de ocupación no guarda relación con la demora y la variable no aportaría poder discriminante relevante.



puerta_embarque

Las distribuciones de puerta_embarque por demora son casi iguales en todo el rango (1 a 50), con medias iguales (25,05) y desvíos casi idénticos (14,19 vs 14,05). La variable no guarda relación con la demora y no aportaría poder discriminante al modelo.




Visibilidad

La distribución muestra una media de 16,12 km (desvío 8,27) en no demorados frente a 13,77 km (desvío 9,16) en demorados. A menor visibilidad, mayor proporción de demoras: dificultan las operaciones. Visibilidad es

una variable con poder discriminante, consistente con la correlación negativa ($r = -0,127$) detectada en el análisis multivariante.


Cruces entre predictores

Tiempo estimado de vuelo x distancia de vuelo




El diagrama que vemos acá muestra una relación lineal casi perfecta entre ambas variables: los puntos se alinean sobre una recta sin dispersión apreciable. El patrón se confirma con el coeficiente de Pearson ($r = 0,999$, $p < 0,001$) que está en la matriz de correlaciones. El tiempo estimado de un vuelo se calcula a partir de la distancia y la velocidad crucero de la aeronave, por lo que las dos variables son representaciones de lo mismo.

Visibilidad x condiciones climáticas




En este boxplot vemos que hay una relación lógica entre ambas variables, aunque con una redundancia parcial. Las categorías Despejado, Lluvia y Nublado presentan distribuciones de visibilidad muy similares, lo que nos indica que estas condiciones admiten un espectro variado de visibilidad. Niebla y Tormenta por otro lado nos muestran cajas con valores muy bajos.



Ocupacion vuelo x temporada alta


Los boxplots de ocupación segmentados por temporada son indistinguibles. Ambos muestran una media cercana al 73% y la misma distribución de outliers inferiores en torno al 20-30% de ocupación. Esto indica

que la ocupación no es afectada por la temporada del año. Además, esto sugiere que la aerolínea mantiene niveles de ocupación estables durante todo el año.



Temporada Alta x Congestión aérea


La distribución de los niveles de congestión aérea es similar entre temporada alta y no alta: en ambos casos la congestión baja y media representan cerca del 40% cada una y la alta ronda el 20%, sin variación significativa entre grupos. La temporada alta no influye en el nivel de congestión, y ambas variables son prácticamente independientes, por lo que aportarán información complementaria y no redundante al modelo.



Día semana x congestión aérea

La proporción de cada nivel de congestión (Alta, Media, Baja) se mantiene estable en los siete días de la semana, sin variaciones significativas. Confirma que ambas variables son independientes entre sí y refuerza el bajo poder discriminante del día de la semana ya observado en el análisis univariante.

Condiciones climáticas x congestión aérea



La distribución relativa de los niveles de congestión es similar entre las cinco categorías climáticas, aunque el volumen absoluto varíe (mayor en Despejado y Nublado, menor en Niebla y Tormenta). La congestión no depende del clima sino de otros factores (volumen tráfico, franja horaria, etc); ambos predictores aportan información útil.

El hallazgo más importante es la correlación casi perfecta entre `distancia_vuelo` y `tiempo_estimado_vuelo` (0,999), que implica que ambas variables aportan la misma información al modelo. El tratamiento específico aplicado a cada variable según los requerimientos de cada técnica se detalla en la fase 3 "Preparación de los datos".

Preparación de los Datos

Se realizarán transformaciones específicas sobre las variables predictoras para adecuarlas a las exigencias de los algoritmos de clasificación que se utilizarán. Las transformaciones contemplan el escalamiento de las variables numéricas y la codificación de las categóricas. El KNN, por operar mediante el cálculo de distancias entre observaciones, requiere que todas las variables se encuentren en una escala común; el Árbol de Decisión es invariante a la escala, pero acepta sin perjuicio los datos escalados. Construimos entonces una única vista minable común a ambos algoritmos.

Limpieza de datos

Tratamiento de valores nulos, registros duplicados, valores atípicos e identificadores

No existen valores nulos, duplicados ni outliers atribuibles a errores de carga: esta etapa no requiere intervención. Los 38.052 registros con `cantidad_millas = 0` en el dataset de clientes no constituyen valores faltantes, sino que reflejan correctamente la situación de los clientes no afiliados al programa de millas, el cero no se imputa si no que cumple un rol semántico válido. En cuanto a registros duplicados, no se detectaron en ningún dataset. No existen vuelos con `aeropuerto_origen = aeropuerto_destino` (lo que sería una inconsistencia operativa). Respecto a los outliers, se deciden conservar ya que corresponden a vuelos de larga distancia, clientes de alto poder adquisitivo y viajeros muy frecuentes, casos válidos y relevantes en el dominio del problema. Finalmente, las variables `id_vuelo` e `id_cliente` se excluyen del rol predictor, dado que son identificadores técnicos sin valor explicativo. Se conservan en una columna paralela para permitir la trazabilidad sobre el archivo `casosNuevos.xlsx` para generar el reporte final.

Tratamiento de la multicolinealidad: `distancia_vuelo` vs `tiempo_estimado_vuelo`

El análisis multivariante de la fase anterior muestra una correlación de Pearson de $r = 0,999$ entre `distancia_vuelo` y `tiempo_estimado_vuelo`. Aportan información redundante,

representando lo mismo en la práctica. Decidimos optar únicamente por `distancia_vuelo`, eliminando `tiempo_estimado_vuelo`.

Tratamiento de variables sin poder discriminante

Del análisis bivalente surge que `puerta_embarque`, `tipo_avion`, `aeropuerto_origen` y `aeropuerto_destino` no tienen relación con la variable objetivo (sus distribuciones estratificadas por demora son casi idénticas) por lo que se excluyen. Las variables `hora_salida_programada` y `dia_semana` se conservan: podrían ser predictores secundarios o capturar interacciones con otras variables que los modelos sí pueden detectar.

Transformaciones aplicadas

Conversión de `hora_salida_programada` a variable numérica: la variable está almacenada como cadena en formato "HH:MM" (p. ej. "09:30") y los algoritmos a utilizar (Árbol de Decisión y KNN, implementados con scikit-learn en Python) requieren predictores numéricos. Se convierte a una variable continua que expresa la hora del día como número decimal:
$$\text{hora_decimal} = HH + \frac{MM}{60}$$

Esta transformación preserva el orden temporal y la magnitud relativa entre franjas horarias.

Codificación de variables categóricas:

Las variables categóricas (almacenadas como texto en los datasets) deben transformarse a un formato numérico antes de ser ingresadas a los modelos. Se aplica una codificación conocida como one-hot encoding, que consiste en reemplazar cada variable categórica con tantas variables binarias (0/1) como categorías tenga, menos una que queda como categoría de referencia. La omisión de una categoría es necesaria para evitar la llamada trampa de las variables dummy: incluir todas las categorías generaría una dependencia lineal exacta entre columnas, ya que la suma de todas las dummies daría siempre 1.

Las categorías de referencia elegidas son:

- **condiciones_climaticas:** referencia Despejado (la más frecuente y operativamente neutra).
- **congestion_aerea:** referencia Baja.
- **dia_semana:** referencia Lunes.

La variable `temporada_alta`, al ser booleana, se convierte directamente a 0/1 sin necesidad de generar variables adicionales.

Esta codificación se incorpora a la vista minable común que utilizarán todos los algoritmos de clasificación, ya que tanto el Árbol de Decisión como KNN requieren predictores en formato numérico.

Escalamiento min-max de variables numéricas

Cuando los métodos están basados en distancias (como es el caso de KNN) las variables con mayor magnitud dominan el cálculo, por lo que es necesario llevarlas a una escala común. Se aplica el escalamiento min-max, que mapea cada variable al rango [0, 1]:

$$y_i^j = \frac{x_i^j - \min_j}{\max_j - \min_j}$$

En nuestro caso las variables numéricas con mayor magnitud como `distancia_vuelo`, que llega a valores de hasta 10.050 km dominarían el cálculo y harían que variables de magnitud menor pero igualmente relevantes como `visibilidad`, acotada entre 0 y 30 km pesaran de forma despreciable.

El Árbol de Decisión, en cambio, es invariante a transformaciones monótonas de los predictores numéricos: el algoritmo busca puntos de corte sobre cada variable, y dichos cortes producen las mismas particiones tanto si la variable está en su escala original como si está escalada al rango [0, 1] (sólo cambia el umbral numérico exacto, no la estructura del árbol resultante). Esto significa que aplicar el escalamiento al árbol no lo perjudica.

Esta propiedad permite trabajar con una única vista minable común a ambos algoritmos, simplificando el código y el flujo de trabajo en Google Colab sin sacrificar la corrección técnica de ninguno de los modelos.

Min-max es sensible a la presencia de valores extremos en el mínimo y el máximo. En este dataset las variables con outliers más marcados (`distancia_vuelo`, `ocupacion_vuelo`) tienen máximos válidos del dominio (vuelos transoceánicos, vuelos casi llenos), por lo que el riesgo de distorsión es acotado y la decisión se considera adecuada para el alcance del trabajo. Los parámetros de escalamiento (mínimos y máximos) se calculan únicamente sobre el dataset de entrenamiento y luego se aplican al dataset de prueba y al dataset `casosNuevos.xlsx`.

Vistas minables resultantes

Para el Objetivo 1 (clasificación de vuelos) se construye una única vista minable que servirá de insumo para los algoritmos de clasificación que se incorporen.

Vista minable para el Objetivo:

hora_salida_programada	Convertida a numérica decimal y escalada (min-max)
<u>dia_semana</u>	Codificación dummy, referencia Lunes
distancia_vuelo	Escalada (min-max)
condiciones_climaticas	Codificación dummy, referencia Despejado
<u>congestion_aerea</u>	Codificación dummy, referencia Baja
ocupacion_vuelo	Escalada (min-max)
temporada_alta	Convertida a 0/1
visibilidad	Escalada (min-max)
demora	Variable objetivo

Partición del conjunto de datos

Para evaluar el desempeño de los modelos de clasificación es necesario contar con un conjunto de datos que el modelo no haya visto durante el entrenamiento. Para ello se divide el dataset vuelos.xlsx en dos subconjuntos:

- 70 % de los registros (10.500 vuelos) como conjunto de entrenamiento.
- 30 % restante (4.500 vuelos) como conjunto de prueba.

La partición se realiza con un muestreo estratificado sobre la variable objetivo demora. Esta decisión se justifica por el desbalance detectado en el análisis univariante (68,15 % de vuelos no demorados frente a 31,85 % demorados): un muestreo aleatorio simple podría arrojar conjuntos con proporciones distintas a las del universo, sesgando la evaluación. El muestreo estratificado garantiza que tanto el conjunto de entrenamiento como el de prueba conserven la misma proporción 68/32 de la variable objetivo.

Para garantizar la reproducibilidad de los resultados se utiliza una semilla fija (random_state = 42) tanto en la partición como en los algoritmos que la requieran.

Aplicación de las transformaciones al dataset casosNuevos.xlsx

Las mismas transformaciones se replicarán sobre el dataset de aplicación al momento de implementar los modelos, con dos consideraciones críticas:

1. Los parámetros de escalamiento (mínimos y máximos) y las codificaciones (categorías de referencia y conjunto de dummies generadas) se toman del entrenamiento, no se recalculan sobre casosNuevos. Esto preserva la coherencia entre lo aprendido por el modelo y lo aplicado.

2. La verificación inicial garantiza que no aparecerán categorías desconocidas, por lo que la codificación one-hot se aplicará sin necesidad de tratamientos especiales para valores nuevos.

Modelado

Selección y aplicación de técnicas/algoritmos

En esta etapa del proyecto se aborda el primer objetivo planteado: construir un modelo de clasificación que permita predecir, a partir de las características operativas de un vuelo, si éste tendrá demora. Para ello se aplican distintas técnicas de clasificación supervisada vistas en la materia, que serán comparadas posteriormente bajo el criterio de minimización de costos definido anteriormente.

Las técnicas seleccionadas para esta entrega son el Árbol de Decisión y KNN. Ambas se implementan en Python sobre Google Colab utilizando la biblioteca scikit-learn, sobre la única vista minable construida en la Fase 3 y con la partición 70/30 estratificada por la variable objetivo demora.

Aspectos comunes a ambos modelos

Ambos modelos se entrenan sobre la misma vista minable definida en la fase anterior, con las mismas variables predictoras y la misma variable objetivo (demora). La partición utilizada es la 70/30 estratificada por demora ya descrita, con semilla `random_state = 42` para garantizar la reproducibilidad.

El análisis univariante reveló una proporción 68/32 en la variable objetivo. Si bien no se trata de un desbalance extremo, es lo suficientemente marcado como para sesgar a los modelos hacia la clase mayoritaria (vuelos no demorados). Esto se vuelve crítico dado que el criterio de éxito del negocio penaliza más los Falsos Negativos (vuelos efectivamente demorados que el modelo no detecta) que los Falsos Positivos. Para abordarlo, en cada algoritmo se evaluarán mecanismos específicos cuyo detalle se desarrollará en la sub-sección de parámetros.

Tal como se estableció en las fases anteriores y siguiendo el enfoque de la cátedra, los modelos se compararán mediante matriz de confusión, matriz de costos y gráfico de

ganancia. Estas tres herramientas permitirán cuantificar el impacto económico de los errores y seleccionar el modelo más adecuado en las siguientes fases.

Toda la implementación se realiza en Python sobre Google Colab, utilizando scikit-learn (DecisionTreeClassifier y KNeighborsClassifier), pandas para la manipulación de datos y matplotlib/seaborn para la visualización de resultados.

Flujo de trabajo

Para cada algoritmo se seguirá el siguiente flujo:

1. Entrenamiento de un modelo base con los parámetros por defecto de la implementación, que servirá como referencia inicial.
2. Exploración de hiperparámetros relevantes para cada técnica (profundidad máxima y criterio de impureza para el árbol; valor de k y métrica de distancia para KNN), buscando aquella configuración que mejor responda al criterio de minimización de costos definido en la primera fase.
3. Selección del mejor modelo candidato dentro de cada algoritmo, que será el que se utilice en la siguiente fase de evaluación para la comparación final.

Especificación de los parámetros utilizados para cada técnica

En esta sub-sección se detallan los parámetros explorados para cada algoritmo. Para ambos algoritmos se sigue una estrategia en dos pasos: primero se entrena un modelo base con los parámetros por defecto, que sirve como punto de comparación; luego se realiza una exploración sistemática de los hiperparámetros más relevantes para identificar la configuración que mejor responde al criterio de minimización de costos del negocio.

El procedimiento de exploración consiste en entrenar el modelo sobre el conjunto de entrenamiento variando un hiperparámetro a la vez, evaluar el desempeño sobre el conjunto de prueba para cada valor y graficar la evolución de la tasa de error. El valor óptimo de los hiperparámetros se obtiene experimentalmente, seleccionando aquel que genera la menor tasa de error en el conjunto de prueba.

Árbol de Decisión

Se utiliza la clase `DecisionTreeClassifier` de `scikit-learn`, que implementa el algoritmo CART (Classification and Regression Trees) con particiones binarias en cada nodo. Los parámetros relevantes son los siguientes:

Criterio de impureza (criterion). Determina la función que se utiliza para evaluar la calidad de cada partición candidata. Se evalúan los dos criterios disponibles en `scikit-learn`:

- Gini (por defecto): mide la impureza de un nodo como la probabilidad de clasificar incorrectamente un elemento elegido al azar si se asignara según la distribución de clases del nodo.
- Entropía: mide el desorden o la incertidumbre dentro del nodo, asociado a la ganancia de información que produce cada partición.

Ambos criterios tienden a producir árboles similares en la práctica, pero la entropía suele generar árboles ligeramente más balanceados, mientras que Gini es computacionalmente más eficiente. Se prueban los dos y se selecciona el que arroje mejor desempeño.

Profundidad máxima (`max_depth`): limita la cantidad de niveles del árbol. Se exploran los siguientes valores: [3, 5, 7, 10, 15, None], donde None significa "sin límite explícito" (el árbol crece hasta que cada hoja sea pura o cumpla otros criterios de detención).

Mínimo de muestras para partir un nodo (`min_samples_split`): define la cantidad mínima de observaciones que debe tener un nodo para considerarlo como candidato a partición. Valores explorados: [2, 10, 20, 50].

Mínimo de muestras por hoja (`min_samples_leaf`): define la cantidad mínima de observaciones que debe quedar en cada hoja resultante de una partición. Valores explorados: [1, 5, 10, 20]. Es un parámetro de regularización complementario a `min_samples_split`.

Semilla (`random_state`): se fija en 42 para garantizar la reproducibilidad de los resultados, dado que el algoritmo realiza desempates aleatorios cuando dos particiones tienen el mismo valor de impureza.

K-Vecinos Más Cercanos (KNN)

Se utiliza la clase `KNeighborsClassifier` de `scikit-learn`. Los parámetros relevantes son los siguientes:

Número de vecinos (n_neighbors, equivalente a K): determina cuántos vecinos cercanos se consideran al clasificar una nueva observación. La selección de k es muy importante y se obtiene experimentalmente. Siguiendo el procedimiento sugerido por el apunte, se explorarán valores de k entre 1 y 30, graficando la tasa de error en función de k para identificar visualmente el valor óptimo. Se priorizan valores impares para evitar empates en la votación cuando se trabaja con un problema de clasificación binaria.

Métrica de distancia (metric): se utiliza la distancia Euclídea, definida como la longitud de la recta que une dos puntos en el espacio:

$$d_{ij} = \sqrt{\sum_{s=1}^p (x_{is} - x_{js})^2}$$

Análisis Discriminante (SPSS Statistics)

Justificación de la técnica

El Análisis Discriminante es una técnica de clasificación supervisada que busca una combinación lineal de los predictores (la función discriminante) que maximice la separación entre los grupos de la variable objetivo. A diferencia del Árbol de Decisión y de KNN, parte de supuestos estadísticos sobre la distribución de los datos, lo que lo hace más exigente respecto a la naturaleza de las variables, pero a cambio ofrece una función explícita e interpretable y un marco probabilístico para la clasificación.

Preparación de los datos

El Análisis Discriminante se aplica sobre el mismo archivo .sav generado en Google Colab que se utiliza para la Regresión Logística (cuaderno Preparacion_Vista_Minable_SPSS.ipynb). Sin embargo, dado que el Análisis Discriminante Lineal trabaja con variables numéricas, no se incorporan al modelo las variables categóricas codificadas mediante one-hot (día de la semana, condiciones climáticas y congestión aérea). Como predictoras se utilizan las variables numéricas continuas: distancia_vuelo, hora_salida_programada (convertida previamente de "HH:MM" a número decimal), visibilidad y ocupacion_vuelo sumado de la variable temporada_alta.


Para reproducir en Statistics la misma partición 70/30 estratificada utilizada en Python (semilla 42), se emplea la columna sel_train ya incluida en el archivo, que marca con valor 1 los 10.500 registros de entrenamiento y con 0 los 4.500 de prueba.

Verificación de los supuestos

Dado que todos los predictores del modelo son variables numéricas continuas, se evalúa la normalidad univariada de cada uno mediante gráficos Q-Q en SPSS Statistics. El supuesto de normalidad multivariante no se cumple estrictamente, en línea con lo observado en el análisis exploratorio de fases anteriores.

Normalidad

Los predictores incorporados al modelo son cuatro variables continuas (distancia_vuelo, hora_salida_programada, visibilidad y ocupacion_vuelo) y una dicotómica (temporada_alta), que por construcción solo toma los valores 0 y 1 y no puede ajustarse a una distribución normal. Para las variables continuas se evaluó la normalidad mediante gráficos Q-Q; a modo ilustrativo se presenta el de distancia_vuelo, la variable más asimétrica del dataset.



El gráfico Q-Q sin tendencia muestra los puntos alejándose claramente de la línea horizontal de referencia (que representaría el ajuste perfecto a la normal), con un patrón curvo marcado en los valores bajos y una fuerte dispersión en la cola derecha (vuelos de larga distancia). Esto confirma la asimetría positiva ya descrita en el análisis univariante de la fase anterior. El supuesto de normalidad multivariante no se satisface.

El gráfico Q-Q sin tendencia muestra los puntos alejándose de la línea horizontal de referencia (que representaría el ajuste perfecto a la normal), con un patrón curvo marcado en los valores bajos y una fuerte dispersión en la cola derecha (vuelos de larga distancia). Esto confirma visualmente la asimetría positiva ya descrita en el análisis univariante de la fase anterior. En conjunto (dummies binarias por un lado y continuas asimétricas por el otro) el supuesto de normalidad multivariante no se satisface.

Diferencia de medias entre grupos

La tabla de pruebas de igualdad de las medias de los grupos (Lambda de Wilks univariada, equivalente a un ANOVA por variable) evalúa, para cada predictor, la hipótesis nula de que su media es igual en los grupos demorado y no demorado. El rechazo de esa hipótesis (Sig. < 0,05) indica que la variable aporta capacidad de discriminación.

Prueba de igualdad de medias de grupos

	Lambda de Wilks	F	gl1	gl2	Sig.
→ hora_salida_programada	,999	5,285	1	10498	,022
distancia_vuelo	1,000	,282	1	10498	,595
ocupacion_vuelo	,999	5,540	1	10498	,019
temporada_alta	,990	108,115	1	10498	,000
visibilidad	,984	170,407	1	10498	,000

Los resultados muestran que las variables con mayor poder discriminante (Lambda más baja, F más alta y Sig. = 0,000) son visibilidad (F = 170,407) y temporada_alta (F = 108,115). En menor medida, ocupacion_vuelo (F = 5,540; Sig. = 0,019) y hora_salida_programada (F = 5,285; Sig. = 0,022) también presentan diferencias significativas de medias entre grupos, aunque con un peso considerablemente menor. La única variable que no muestra diferencias significativas es distancia_vuelo (Sig. = 0,595), resultado coherente con el análisis exploratorio de fases anteriores, donde esta variable ya había mostrado bajo poder discriminante. Dado que cuatro de las cinco variables presentan medias significativamente distintas entre grupos, el supuesto que da sentido a la técnica se cumple.

No multicolinealidad

Este supuesto fue analizado y resuelto en fases anteriores del trabajo, por lo que no requiere un nuevo procesamiento en esta etapa:

- En la fase de análisis multivariante, tanto en la matriz de dispersión como en las correlaciones de Pearson, se detectó una correlación de 0,999 entre distancia_vuelo y tiempo_estimado_vuelo, señalando que ambas variables aportaban información prácticamente idéntica.
- En la fase de preparación de los datos, en el apartado "Tratamiento de la multicolinealidad: distancia_vuelo vs tiempo_estimado_vuelo", se decidió eliminar tiempo_estimado_vuelo y conservar únicamente distancia_vuelo.

En consecuencia, la vista minable utilizada ya no contiene la redundancia detectada, y la matriz de correlación intra-grupos solicitada en el análisis permite verificar que no persisten correlaciones extremas entre los predictores restantes. El supuesto de no multicolinealidad se considera atendido.

Igualdad de matrices de covarianza

La prueba M de Box evalúa la hipótesis nula de que las matrices de covarianza de ambos grupos son iguales.

Funciones en centroides de grupo

demora	Función 1
,00	-,114
1,00	,245

Las funciones discriminantes canónicas sin estandarizar se han evaluado en medias de grupos

Logaritmo de los determinantes

demora	Rango	Logaritmo del determinante
,00	5	26,902
1,00	5	27,184
Dentro de grupos combinados	5	27,000

Los logaritmos naturales y los rangos de determinantes impresos son los de las matrices de covarianzas de grupo.

Resultados de prueba

M de Box	83,446
F	Aprox. 5,560
gl1	15
gl2	182600262,6
Sig.	,000

Prueba la hipótesis nula de las matrices de covarianzas de población iguales.

El resultado obtenido (M de Box =

83,446; F = 5,560; Sig. = 0,000) lleva a rechazar la hipótesis nula: las matrices de covarianza de los grupos demorado y no demorado no son iguales. La tabla de logaritmos de los determinantes muestra, sin embargo, valores cercanos entre grupos (26,902 para no demorados y 27,184 para demorados, con 27,000 en el conjunto combinado), lo que indica que la diferencia entre matrices, aunque significativa, no es de gran magnitud. Cabe señalar que, con tamaños muestrales grandes como el de este dataset (10.500 casos de entrenamiento), la prueba M de Box es muy sensible y tiende a rechazar el supuesto incluso ante diferencias pequeñas, por lo que el resultado debe leerse con cautela; no obstante, formalmente el supuesto no se cumple.

Decisión

Antes de pasar a los resultados de clasificación, conviene mirar las medidas globales de ajuste de la función discriminante. La Lambda de Wilks dio 0,973 con un Chi-cuadrado de 290,290 (5 gl) y Sig. = 0,000, lo que permite rechazar la hipótesis nula de que las medias de los grupos son iguales en el espacio de los predictores: la función separa de manera estadísticamente significativa a los vuelos demorados de los no demorados.

Autovalores

Función	Autovalor	% de varianza	% acumulado	Correlación canónica
1	,028 ^a	100,0	100,0	,165

a. Se utilizaron las primeras 1 funciones discriminantes canónicas en el análisis.

Coefficientes de función discriminante canónica estandarizados

	Función 1
hora_salida_programada	,153
distancia_vuelo	,027
ocupacion_vuelo	,142
temporada_alta	,615
visibilidad	-,771

Lambda de Wilks

Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,973	290,290	5	,000

Sin embargo, el valor de Lambda muy cercano a 1 anticipa que la separación, aunque significativa, es escasa. Esto se ratifica con el autovalor de 0,028 y la correlación canónica de 0,165. La correlación canónica al cuadrado ($\approx 0,027$) indica que apenas el 2,7 % de la variabilidad total queda explicada por la pertenencia al grupo, un poder de separación sensiblemente menor al de la versión anterior del modelo. Esta caída era previsible: al restringir el conjunto de predictores a las variables numéricas, se excluyen del modelo las categorías climáticas adversas y la congestión alta, que en el análisis exploratorio se habían identificado como los factores más asociados con la demora.

Los coeficientes estandarizados muestran qué variables pesan más en la función. Las dominantes son visibilidad (-0,771) y temporada_alta (0,615), seguidas a distancia por hora_salida_programada (0,153) y ocupacion_vuelo (0,142). La variable distancia_vuelo (0,027) tiene peso prácticamente nulo, coherente con la falta de significancia detectada en la Lambda de Wilks univariada. El signo negativo de visibilidad indica que sus valores altos empujan la función hacia el centroide del grupo no demorado, mientras que temporada_alta (positivo) la empuja hacia el grupo demorado. Llama la atención el peso mayor de visibilidad respecto de la versión anterior del modelo: antes su coeficiente quedaba absorbido por las dummies climáticas (Niebla y Tormenta) y, al excluirlas, visibilidad recupera todo el peso predictivo del fenómeno climático.

Función discriminante

A partir de los coeficientes no estandarizados, la función discriminante SPSS es:

$$D = -0,090 + 0,031 \cdot \text{hora_salida_programada} + 0,000 \cdot \text{distancia_vuelo} + 0,009 \cdot \text{ocupacion_vuelo} + 1,293 \cdot \text{temporada_alta} - 0,090 \cdot \text{visibilidad}$$

Coeficientes de la función discriminante canónica

	Función 1
hora_salida_programada	,031
distancia_vuelo	,000
ocupacion_vuelo	,009
temporada_alta	1,293
visibilidad	-,090
(Constante)	-,090

Coeficientes no estandarizados

El coeficiente de distancia_vuelo es prácticamente cero, consistente con su falta de poder discriminante; el de temporada_alta es por lejos el mayor en magnitud, lo que refleja que pasar de temporada baja (0) a temporada alta (1) suma 1,293 unidades a la puntuación discriminante. Los coeficientes no estandarizados no son directamente comparables entre sí debido a las distintas escalas de las variables (por eso la interpretación del peso relativo se hace sobre los coeficientes estandarizados), pero son los que se aplican sobre las observaciones para obtener la puntuación D que cada vuelo recibe.

Punto de corte

Las funciones en los centroides de los grupos arrojaron los siguientes valores: $\bar{D}_0 = -0,114$ para el grupo no demorado y $\bar{D}_1 = 0,245$ para el grupo demorado. Dado que los tamaños muestrales de los grupos en el conjunto de entrenamiento son desiguales ($n_0 = 7.155$ no demorados y $n_1 = 3.345$ demorados), el punto de corte óptimo se calcula como la media ponderada de los centroides utilizando como ponderadores los tamaños del grupo opuesto:

$$PC = (n_0 \cdot \bar{D}_1 + n_1 \cdot \bar{D}_0) / (n_0 + n_1) = (7.155 \times 0,245 + 3.345 \times (-0,114)) / 10.500 = 1.371,645 / 10.500 \approx 0,131$$

Como $\bar{D}_1 > \bar{D}_0$, la regla de clasificación queda definida del siguiente modo: si $D(x) > 0,131$ el vuelo se clasifica como demorado, y si $D(x) \leq 0,131$ se clasifica como no demorado.

Resultados de clasificación^{a,b,c,d}

			Pertenencia a grupos pronosticada			
			demora	,00	1,00	Total
Casos seleccionados	Original	Recuento	,00	7105	50	7155
			1,00	3267	78	3345
		%	,00	99,3	,7	100,0
			1,00	97,7	2,3	100,0
	Validación cruzada ^c	Recuento	,00	7102	53	7155
			1,00	3268	77	3345
		%	,00	99,3	,7	100,0
			1,00	97,7	2,3	100,0
Casos no seleccionados	Original	Recuento	,00	3044	23	3067
			1,00	1401	32	1433
		%	,00	99,3	,7	100,0
			1,00	97,8	2,2	100,0

a. 68,4% de casos agrupados originales seleccionados clasificados correctamente.

b. 68,4% de casos agrupados originales sin seleccionar clasificados correctamente.

c. La validación cruzada se ha realizado sólo para aquellos casos del análisis. En la validación cruzada, cada caso se clasifica mediante las funciones derivadas de todos los casos distintos a dicho caso.

d. 68,4% de casos agrupados validados de forma cruzada seleccionados clasificados correctamente.

Matriz de clasificación y costo total

Sobre el conjunto de prueba (los 4.500 vuelos no utilizados durante el entrenamiento, identificados como "casos no seleccionados" en la tabla de SPSS), el modelo arrojó: 3.044 Verdaderos Negativos, 23 Falsos Positivos, 1.401 Falsos Negativos y 32 Verdaderos Positivos. De esto se desprenden las siguientes métricas:

- Accuracy: $(3.044 + 32) / 4.500 = 68,4 \%$
- Sensibilidad / recall sobre clase demorado: $32 / 1.433 = 2,2 \%$
- Especificidad: $3.044 / 3.067 = 99,3 \%$
- Precisión sobre clase demorado: $32 / 55 = 58,2 \%$

El modelo presenta un desbalance extremo entre métricas: clasifica casi perfectamente a los vuelos que no se demoran (99,3 % de especificidad) pero apenas detecta uno de cada cincuenta vuelos que efectivamente se demoran. Esta caída marcada en la sensibilidad respecto a la versión anterior del modelo es consecuencia directa de haber restringido el conjunto de predictores a las variables numéricas: al excluirse las categorías climáticas adversas y la congestión alta, que en el análisis exploratorio aparecían como los factores más asociados con la demora, el modelo pierde precisamente los atributos con mayor

capacidad para identificar la clase minoritaria.

Aplicando la matriz de costos definida (FN = 5, FP = 1):

$$\text{Costo total} = (23 \times 1) + (1.401 \times 5) = 23 + 7.005 = 7.028$$

Los Falsos Negativos representan el 99,7 % del costo total. El valor es considerablemente mayor al obtenido por el modelo anterior (5.668), lo que confirma que la restricción metodológica del conjunto de predictores tiene un impacto importante sobre el desempeño bajo el criterio de evaluación definido.

Regresión Logística (SPSS Statistics)

Justificación de la técnica

La Regresión Logística es un modelo lineal generalizado que estima la probabilidad de que una observación pertenezca a la clase positiva (vuelo demorado) mediante una función sigmoide aplicada sobre una combinación lineal de los predictores. A pesar de su nombre, es una técnica de clasificación, no de regresión. Su principal ventaja frente a los demás modelos es la interpretabilidad: cada coeficiente se traduce en un odds ratio ($\text{Exp}(B)$) que cuantifica cómo cambia la probabilidad de demora ante una variación del predictor, manteniendo el resto constante. Esto la convierte en una herramienta valiosa no solo para predecir, sino también para explicar qué factores influyen en la demora y en qué medida. Además, a diferencia del Análisis Discriminante, no exige normalidad de los predictores ni igualdad de matrices de covarianza, por lo que es especialmente adecuada cuando esos supuestos no se cumplen.

Preparación de los datos

La Regresión Logística se aplicó sobre la misma vista minable que el resto de los modelos, cargada en SPSS Statistics a partir del archivo .sav generado en Google Colab (el mismo descrito en la sección de Análisis Discriminante: con la conversión de hora a decimal, la codificación one-hot de las categóricas, temporada_alta en 0/1 y la columna de selección sel_train).

A diferencia del procedimiento Discriminante, la Regresión Logística de Statistics sí permite indicar variables categóricas mediante el botón "Categórica", en cuyo caso el programa genera internamente sus propias variables dummy. Sin embargo, se optó por no utilizar esa opción y entrar todas las variables ya codificadas desde la vista minable como covariables numéricas. La razón es la coherencia entre modelos: las dummies de la vista minable

utilizan categorías de referencia explícitas (Lunes, Despejado y Baja), de modo que conservarlas garantiza que los coeficientes de la Regresión Logística sean directamente comparables con los del Análisis Discriminante y consistentes con las transformaciones de la fase de preparación. Si se dejara que SPSS recodificara las categóricas, podría adoptar categorías de referencia distintas y los resultados dejarían de ser comparables.

Tampoco se aplicó escalamiento min-max: la Regresión Logística no requiere que los predictores estén en una escala común, ya que estima un coeficiente independiente por variable.

Para reproducir la misma partición 70/30 estratificada utilizada en los demás modelos (semilla 42), se empleó la variable `sel_train` como variable de selección dentro del procedimiento. Indicando la regla `sel_train = 1`, el modelo se entrena exclusivamente con el conjunto de entrenamiento (10.500 vuelos) y reporta los resultados de clasificación de forma separada para los casos seleccionados (entrenamiento) y los no seleccionados (los 4.500 vuelos de prueba), que son la base de la comparación final.

Verificación de los supuestos

Una vez estimado el modelo de regresión logística, se procede a verificar el cumplimiento de las hipótesis básicas sobre los errores. El modelo trabaja con las variables visibilidad, distancia_vuelo, hora_salida_programada, ocupacion_vuelo, temporada, día de la semana, condiciones climáticas y congestión aérea. Los supuestos se evalúan sobre la diferencia de las probabilidades pronosticadas y observadas, que cumple el rol de los errores del modelo.

Media cero

Se contrasta que el promedio de los errores sea igual a cero mediante una prueba t para una muestra:

Prueba para una muestra						
Valor de prueba = 0						
	t	gl	Sig. (bilateral)	Diferencia de medias	95% de intervalo de confianza de la diferencia	
					Inferior	Superior
Diferencia entre las probabilidades pronosticadas y observadas	-,063	14999	,950	-,00022832	-,0073188	,0068622

El estadístico t es de -0,063 con 14999 grados de libertad y una significancia de 0,950. Como el p-valor (0,950) es mayor a 0,05, no se rechaza la hipótesis nula. Además, el

intervalo de confianza del 95% para la diferencia de medias va de -0,0073188 a 0,0068622, conteniendo al cero. El supuesto se cumple, los errores tienen media cero.

Varianza constante

Se evalúa la homocedasticidad de los errores con la prueba de homogeneidad de varianzas:

H_0 : Errores homocedásticos

H_a : Hay Heterocedasticidad

El estadístico de Levene basado en la media es de 526,100 con una significancia de 0,000. Como el p-valor

(0,000) es menor a 0,05, se rechaza la hipótesis nula. El supuesto no se cumple, hay evidencia de heterocedasticidad en los errores.

Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	Se basa en la media	526,100	1	14998	,000
	Se basa en la mediana	432,003	1	14998	,000
	Se basa en la mediana y con gl ajustado	432,003	1	14836,618	,000
	Se basa en la media recortada	512,974	1	14998	,000

Normalidad de los errores

Se contrasta la normalidad de los errores mediante la prueba de Kolmogorov-Smirnov:

H_0 : $\epsilon \sim \text{Normal}$

H_a : $\epsilon \neq \text{Normal}$

Pruebas de normalidad

	Kolmogorov-Smirnov ^a		
	Estadístico	gl	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	,293	15000	,000

a. Corrección de significación de Lilliefors

El estadístico de Kolmogorov-Smirnov es de 0,293 con 15000 grados de libertad y una significancia de 0,000. Como el p-valor (0,000) es menor a 0,05, se rechaza la hipótesis nula. El supuesto no se cumple, los errores no siguen una distribución normal.

No multicolinealidad

Se analiza la multicolinealidad entre las variables explicativas a través del índice de condición. El criterio del apunte indica que un IC mayor a 30 evidencia multicolinealidad:

Diagnósticos de colinealidad ^a																			
Proporciones de varianza																			
Autovalor	Índice de condición	(Constante)	hora_salida_programada	distancia_vuelo	ocupacion_vuelo	temporada_alta	visibilidad	dia_semana_Domingo	dia_semana_Jueves	dia_semana_Martes	dia_semana_Miercoles	dia_semana_Sabado	dia_semana_Viernes	condiciones_climaticas_Lluvia	condiciones_climaticas_Niebla	condiciones_climaticas_Nublado	condiciones_climaticas_Tormenta	congestion_area_Alta	congestion_area_Media
6,535	1,000	,00	,00	,01	,00	,01	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,01
1,089	2,450	,00	,00	,00	,00	,00	,01	,00	,00	,00	,00	,00	,00	,00	,04	,22	,07	,20	,00
1,024	2,527	,00	,00	,00	,00	,00	,00	,08	,00	,02	,02	,10	,00	,01	,09	,01	,11	,07	,03
1,013	2,540	,00	,00	,00	,00	,00	,00	,00	,10	,02	,01	,01	,07	,05	,06	,03	,05	,12	,04
1,009	2,545	,00	,00	,00	,00	,00	,00	,03	,00	,12	,01	,08	,04	,18	,00	,09	,00	,02	,01
1,000	2,556	,00	,00	,00	,00	,00	,00	,14	,01	,00	,30	,01	,02	,00	,00	,00	,00	,00	,00
1,000	2,557	,00	,00	,00	,00	,00	,00	,04	,19	,12	,03	,00	,09	,00	,00	,00	,00	,00	,00
,991	2,568	,00	,00	,00	,00	,00	,00	,01	,07	,00	,00	,04	,15	,19	,00	,09	,01	,02	,01
,987	2,574	,00	,00	,00	,00	,00	,00	,00	,04	,10	,01	,06	,01	,05	,04	,04	,05	,14	,05
,977	2,586	,00	,00	,00	,00	,00	,00	,09	,00	,04	,02	,09	,00	,00	,12	,00	,10	,07	,03
,622	3,241	,00	,00	,19	,00	,81	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00
,578	3,359	,00	,00	,74	,00	,14	,00	,00	,00	,00	,00	,00	,00	,03	,01	,03	,01	,02	,03
,451	3,805	,00	,00	,02	,00	,01	,02	,00	,00	,00	,00	,00	,00	,40	,07	,57	,09	,07	,11
,351	4,315	,00	,03	,03	,00	,02	,03	,02	,01	,01	,01	,01	,01	,04	,00	,06	,00	,43	,66
,150	6,603	,00	,77	,00	,00	,00	,05	,10	,11	,10	,11	,11	,11	,00	,02	,00	,02	,00	,00
,129	7,119	,00	,02	,00	,00	,00	,50	,29	,26	,27	,28	,29	,29	,00	,18	,00	,18	,00	,00
,074	9,397	,03	,09	,01	,37	,01	,28	,13	,13	,13	,13	,13	,14	,01	,11	,01	,12	,01	,01
,017	19,375	,97	,08	,01	,62	,01	,11	,07	,07	,06	,06	,07	,07	,01	,06	,01	,05	,01	,02

Diagnósticos de colinealidad ^a																			
Proporciones de varianza																			
Modelo	Dimensión	Autovalor	Índice de condición	(Constante)	hora_salida_programada	distancia_vuelo	ocupacion_vuelo	temporada_alta	visibilidad	dia_semana_Domingo	dia_semana_Jueves	dia_semana_Martes	dia_semana_Miercoles	dia_semana_Sabado	dia_semana_Viernes	condiciones_climaticas_Lluvia	condiciones_climaticas_Niebla	condiciones_climaticas_Nublado	condiciones_climaticas_Tormenta
1	1	6,535	1,000	,00	,00	,01	,00	,01	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,01
	2	1,089	2,450	,00	,00	,00	,00	,00	,01	,00	,00	,00	,00	,00	,00	,04	,22	,07	,20
	3	1,024	2,527	,00	,00	,00	,00	,00	,00	,08	,00	,02	,02	,10	,00	,01	,09	,01	,11
	4	1,013	2,540	,00	,00	,00	,00	,00	,00	,00	,10	,02	,01	,01	,07	,05	,06	,03	,05
	5	1,009	2,545	,00	,00	,00	,00	,00	,00	,03	,00	,12	,01	,08	,04	,18	,00	,09	,00
	6	1,000	2,556	,00	,00	,00	,00	,00	,00	,14	,01	,00	,30	,01	,02	,00	,00	,00	,00
	7	1,000	2,557	,00	,00	,00	,00	,00	,00	,04	,19	,12	,03	,00	,09	,00	,00	,00	,00
	8	,991	2,568	,00	,00	,00	,00	,00	,00	,01	,07	,00	,00	,04	,15	,19	,00	,09	,01
	9	,987	2,574	,00	,00	,00	,00	,00	,00	,00	,04	,10	,01	,06	,01	,05	,04	,04	,05
	10	,977	2,586	,00	,00	,00	,00	,00	,00	,09	,00	,04	,02	,09	,00	,00	,12	,00	,10
	11	,622	3,241	,00	,00	,19	,00	,81	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00	,00
	12	,578	3,359	,00	,00	,74	,00	,14	,00	,00	,00	,00	,00	,00	,00	,03	,01	,03	,01
	13	,451	3,805	,00	,00	,02	,00	,01	,02	,00	,00	,00	,00	,00	,00	,40	,07	,57	,09
	14	,351	4,315	,00	,03	,03	,00	,02	,03	,02	,01	,01	,01	,01	,01	,04	,00	,06	,00
	15	,150	6,603	,00	,77	,00	,00	,00	,05	,10	,11	,10	,11	,11	,11	,00	,02	,00	,00
	16	,129	7,119	,00	,02	,00	,00	,00	,50	,29	,26	,27	,28	,29	,29	,00	,18	,00	,00
	17	,074	9,397	,03	,09	,01	,37	,01	,28	,13	,13	,13	,13	,13	,14	,01	,11	,01	,01
	18	,017	19,375	,97	,08	,01	,62	,01	,11	,07	,07	,06	,06	,07	,07	,01	,06	,01	,02

a. Variable dependiente: demora

El mayor índice de condición de la tabla es de 19,375. Como este valor es menor a 30, no se rechaza la hipótesis nula. El supuesto se cumple, no hay multicolinealidad entre las variables explicativas.

No autocorrelación de errores

Se verifica la ausencia de autocorrelación en los errores mediante las autocorrelaciones:

H₀: ∈ no autocorrelados

H_a: ∈ autocorrelados

Las significancias del estadístico de Box-Ljung para todos los retardos analizados (del 1 al 16) son mayores a 0,05 (el menor valor es 0,061 en el retardo 14). Como en ningún retardo se rechaza la hipótesis nula, el supuesto se cumple, los errores no están autocorrelados.

Autocorrelaciones				
Serie: Diferencia entre las probabilidades pronosticadas y observadas				
Retardo	Autocorrelación	Desv. Error ^a	Estadístico de Box-Ljung	
			Valor	gl
				Sig. ^b
1	-,010	,008	1,398	1
2	,000	,008	1,398	2
3	-,010	,008	3,012	3
4	,000	,008	3,012	4
5	,018	,008	7,839	5
6	,011	,008	9,649	6
7	,007	,008	10,346	7
8	,001	,008	10,365	8
9	-,009	,008	11,617	9
10	-,011	,008	13,303	10
11	-,007	,008	14,135	11
12	-,007	,008	14,818	12
13	-,013	,008	17,458	13
14	-,019	,008	22,953	14
15	-,002	,008	23,033	15
16	,004	,008	23,278	16

a. El proceso subyacente asumido es independencia (ruido blanco).

b. Se basa en la aproximación de chi-cuadrado asintótica.

Independencia entre variables explicativas y error

Se evalúa la independencia entre los errores y las variables explicativas mediante la correlación de Pearson:

H_0 : $\in$ ind de VE

H_a : $\in$ no ind de VE


Las correlaciones de Pearson entre la diferencia de probabilidades y cada variable

Correlaciones						
	Diferencia entre las probabilidades pronosticadas y observadas	visibilidad	distancia_vuelo	hora_salida_programada	ocupacion_vuelo	
Diferencia entre las probabilidades pronosticadas y observadas	Correlación de Pearson	1	-,003	,004	-,010	-,008
	Sig. (bilateral)		,735	,652	,216	,335
	N	15000	15000	15000	15000	15000
visibilidad	Correlación de Pearson	-,003	1	,009	,010	,014
	Sig. (bilateral)	,735		,294	,230	,094
	N	15000	15000	15000	15000	15000
distancia_vuelo	Correlación de Pearson	,004	,009	1	,008	,009
	Sig. (bilateral)	,652	,294		,331	,263
	N	15000	15000	15000	15000	15000
hora_salida_programada	Correlación de Pearson	-,010	,010	,008	1	-,003
	Sig. (bilateral)	,216	,230	,331		,718
	N	15000	15000	15000	15000	15000
ocupacion_vuelo	Correlación de Pearson	-,008	,014	,009	-,003	1
	Sig. (bilateral)	,335	,094	,263	,718	
	N	15000	15000	15000	15000	15000

explicativa (visibilidad, distancia_vuelo, hora_salida_programada, ocupacion_vuelo) son muy cercanas a cero, con significancias (bilaterales) de 0,735, 0,652, 0,216 y 0,335 respectivamente, todas mayores a 0,05. El supuesto se cumple, los errores son independientes de las variables explicativas.

Puntos influyentes / Distancia de Cook

Se identifican posibles observaciones influyentes mediante la distancia de Cook. Según el criterio del apunte, se consideran puntos influyentes aquellos con $D_i > 1$: La media de los valores equivalentes a la distancia de Cook es de 0,00172 y el valor máximo observado en el histograma no supera aproximadamente 0,012, muy por debajo del umbral de 1. No hay puntos influyentes: ninguna observación supera el criterio $D_i > 1$.



Tamaño de muestra

La Regresión Logística requiere un tamaño de muestra suficiente para estimar de forma estable los coeficientes, especialmente en relación con la cantidad de predictores. Con 10.500 registros de entrenamiento y 17 predictores, la relación de casos por variable es ampliamente holgada, por lo que el supuesto se cumple sin inconvenientes.

Evaluación

Especificación del criterio de evaluación

El objetivo de esta fase es comparar los modelos de clasificación construidos (Árbol de Decisión, KNN, Análisis Discriminante y Regresión Logística) y seleccionar el más adecuado para el problema de DS Airlines. La comparación no se basa únicamente en la exactitud global (porcentaje de aciertos), ya que esta métrica resulta engañosa frente a una variable objetivo desbalanceada como la nuestra (68 % de vuelos no demorados frente a 32 % demorados): un modelo que predijera "no demorado" para todos los vuelos alcanzaría un 68 % de aciertos sin tener ningún valor práctico. Por ese motivo, el criterio de evaluación se orienta al objetivo de negocio definido en la fase de entendimiento del negocio.

Tipos de error y su impacto en el negocio

Tal como se estableció en los criterios de éxito de la fase anterior, los dos tipos de error que puede cometer el modelo tienen consecuencias muy distintas:

- Falso Negativo (FN): el modelo predice que un vuelo no se demorará, pero efectivamente se demora. El pasajero no recibe ninguna notificación ni beneficio compensatorio, lo que deriva en insatisfacción, reclamos y posible pérdida del cliente hacia la competencia. Es un error difícil de cuantificar con exactitud, pero estratégicamente crítico, porque afecta la imagen de la aerolínea y la fidelización del pasajero.
- Falso Positivo (FP): el modelo predice demora, pero el vuelo sale a tiempo. La aerolínea ofrece un beneficio (voucher de comida o acceso a sala VIP) que no era necesario, generando un costo económico directo pero acotado y conocido.

La conclusión del negocio es clara: el costo de un Falso Negativo es mayor que el de un Falso Positivo. Por lo tanto, entre dos modelos con exactitud similar, se preferirá aquel que cometa menos Falsos Negativos, es decir, el que mejor detecte los vuelos que efectivamente se demoran.

Herramientas de evaluación

Para traducir este criterio de negocio en una comparación técnica, se utilizan tres herramientas complementarias, siguiendo el enfoque de la cátedra:

Matriz de confusión: para cada modelo se construye la matriz de confusión sobre el mismo conjunto de prueba (los 4.500 vuelos no vistos durante el entrenamiento), que clasifica las predicciones en Verdaderos Negativos (VN), Falsos Positivos (FP), Falsos Negativos (FN) y Verdaderos Positivos (VP). A partir de la matriz se obtienen, además de la exactitud, métricas más informativas para este problema, en particular la sensibilidad o recall sobre la clase demorado ($VP / (VP + FN)$), que mide qué proporción de los vuelos realmente demorados logra detectar el modelo. Dado el criterio de negocio, esta es la métrica más relevante de la comparación.

Matriz de costos: sobre la matriz de confusión se aplica una matriz de costos que asigna un peso económico a cada tipo de error, de modo de obtener un costo total por modelo que refleje el impacto real de sus errores y no solo su cantidad. Los aciertos (VN y VP) no tienen costo. Los valores asignados son:

	Predicho: No demorado	Predicho: Demorado
Real: No demorado	0	Costo FP = 1
Real: Demorado	Costo FN = 5	0

El Falso Positivo se toma como unidad de costo (1): representa una pérdida directa, acotada y conocida: el beneficio entregado innecesariamente por un vuelo que salió a tiempo. El Falso Negativo fija un valor cinco veces mayor (5), reflejando que dejar a un pasajero

demorado sin aviso ni compensación tiene un impacto mucho más grave (insatisfacción, reclamos y posible pérdida del cliente hacia la competencia), cuyo costo de readquisición en la industria aérea supera ampliamente al de un beneficio puntual. La relación 1:5 expresa esta asimetría sin llevarla a un extremo que volvería trivial al modelo (marcar casi todos los vuelos como demorados). El costo total de cada modelo se calcula como:

$$\text{Costo total} = (FP \times 1) + (FN \times 5)$$

El modelo seleccionado será el de menor costo total.

Criterio de selección final

Integrando las tres herramientas, el modelo elegido será aquel que minimice el costo total según la matriz de costos, dando prioridad a la reducción de Falsos Negativos. La exactitud global se considera como criterio complementario para desempatar o para validar la decisión, pero el factor determinante es el costo asociado a los errores, en línea con el objetivo central planteado por DS Airlines.

Evaluación de los modelos construidos.

K-Vecinos Más Cercanos (KNN)

El modelo final se seleccionó con $k = 41$ y distancia euclídea, lo que minimizó la tasa de error sobre el conjunto de prueba dentro del rango explorado.

	k	err_train	err_test	FN	FP
0	1	0.000000	0.385333	884	850
1	3	0.196095	0.350889	953	626
2	5	0.239714	0.329333	997	485
3	7	0.257619	0.319778	1015	424
4	9	0.268381	0.318222	1025	407
5	11	0.274667	0.316000	1047	375
6	13	0.277333	0.310444	1059	338
7	15	0.279238	0.312222	1069	336
8	17	0.278476	0.307111	1064	318
9	19	0.280476	0.303333	1069	296
10	21	0.280095	0.302889	1074	289

11	23	0.282190	0.298889	1072	273
12	25	0.283619	0.301333	1090	266
13	27	0.284000	0.300444	1092	260
14	29	0.287048	0.298667	1095	249
15	31	0.286000	0.297556	1102	237
16	33	0.287333	0.298222	1106	236
17	35	0.288190	0.298000	1107	234
18	37	0.287714	0.297556	1109	230
19	39	0.289333	0.296222	1108	225
20	41	0.288190	0.296000	1110	222
21	43	0.287905	0.297111	1119	218
22	45	0.289238	0.300000	1127	223
23	47	0.289429	0.299556	1131	217
24	49	0.289619	0.299333	1134	213
25	51	0.289143	0.298444	1136	207

La curva de error muestra el comportamiento clásico del algoritmo. Para $k = 1$ el error de entrenamiento es 0 (el modelo memoriza cada punto, ya que cada observación es su propio vecino más cercano) mientras el error de prueba es el más alto de toda la serie (0,385), por sobreajuste. A medida que k aumenta, el error de entrenamiento crece y el de prueba descende, hasta que sus curvas convergen y se estabilizan en torno a 0,29. El error de prueba alcanza su valor mínimo en $k = 41$ (0,296), por lo que se adoptó ese valor. La convergencia de las dos curvas en valores cercanos demuestra que con k alto el modelo deja de sobreajustar pero se acerca al comportamiento de la clase mayoritaria.


Con $k = 41$ sobre el conjunto de prueba, el modelo arrojó: 2.845 Verdaderos Negativos, 222

Falsos Positivos, 1.110 Falsos

Negativos y 323 Verdaderos

Positivos. De esto se desprenden

las siguientes métricas:



Accuracy: $(2.845 + 323) / 4.500 = 70,4 \%$.

Sensibilidad / recall sobre la clase demorado: $323 / (323 + 1.110) = 22,5 \%$.

Especificidad (clase no demorado): $2.845 / 3.067 = 92,8 \%$.

Precisión sobre la clase demorado: $323 / (323 + 222) = 59,3 \%$.

La métrica más importante según el criterio de negocio, la sensibilidad sobre los vuelos demorados, es muy baja: el modelo detecta solo 1 de cada 4 vuelos que efectivamente se demoran (deja pasar 1.110 de 1.433). En cambio, clasifica casi perfectamente los vuelos que salen a tiempo (92,8 % de especificidad). Este patrón confirma el riesgo anticipado en el análisis univariante: comparado al desbalance 68/32, el KNN con k alto se sesga fuertemente hacia la clase mayoritaria, que es el error que el negocio penaliza más.

Aplicando la matriz de costos definida (FP = 1, FN = 5), el costo total del modelo es:

$$\text{Costo total} = (\text{FP} \times 1) + (\text{FN} \times 5) = (222 \times 1) + (1.110 \times 5) = 5.772$$

Los Falsos Negativos aportan 5.550 sobre 5.772, o sea que el 96 % del costo total proviene del tipo de error que el negocio busca minimizar. El bajo recall del modelo significa costos elevados. Por otro lado, el valor de k se eligió minimizando la tasa de error global, pero esa tasa y el costo total no van en la misma dirección. La tabla de exploración muestra que cuando k crece, los Falsos Positivos bajan (de 850 en k = 1 a 222 en k = 41) pero los Falsos Negativos suben (de 884 a 1.110). Como cada FN pesa cinco veces más que un FP, el costo total en realidad aumenta con k:

$$- k = 1 \rightarrow (850 \times 1) + (884 \times 5) = 5.270$$

$$- k = 5 \rightarrow (485 \times 1) + (997 \times 5) = 5.470$$


$$- k = 41 \rightarrow (222 \times 1) + (1.110 \times 5) = 5.772$$

Por lo tanto, el k que minimiza el error no es el k que minimiza el costo, y tiene sentido con el desbalance: subir k suaviza las fronteras de decisión hacia la clase mayoritaria, reduciendo FP a costa de inflar FN.

El KNN ofrece una exactitud aceptable (70,4 %) pero poca sensibilidad sobre la clase demorado (22,5 %) y un costo total alto (5.772), concentrado casi por completo en Falsos Negativos. Estos valores son provisorios y tienen sentido al compararlos con los del Árbol de Decisión, el Análisis Discriminante y la Regresión Logística en la comparación final.


Árbol de decisión

El modelo final se seleccionó con `*max_depth = 5*` y criterio de impureza `*Gini*`, configuración que minimizó la tasa de error sobre el conjunto de prueba dentro de los valores explorados.



La curva muestra claramente el sobreajuste asociado a la profundidad del árbol. En profundidades bajas (`max_depth = 3` y `5`) las curvas de entrenamiento y prueba están casi superpuestas en torno a 0,29, por lo que el modelo generaliza bien. El error de prueba alcanza su valor mínimo en `max_depth = 5`; a partir de ahí, al

aumentar la profundidad, el error de entrenamiento cae (llega a 0,12 en profundidad 15, 0,04 en 20 y prácticamente 0 sin límite) mientras el error de prueba crece sostenidamente (0,31 en profundidad 10, 0,35 en 15, hasta 0,38 sin límite). Esa divergencia creciente entre las dos curvas es típica del sobreajuste: el árbol profundo recuerda el ruido del entrenamiento y pierde capacidad de generalización. Por eso se adoptó el árbol poco profundo (`max_depth = 5`), que es el punto de mejor compromiso entre sesgo y varianza.



Con `max_depth = 5` sobre el conjunto de prueba, el modelo da: 2.838 Verdaderos Negativos, 229 Falsos Positivos, 1.082 Falsos Negativos y 351 Verdaderos Positivos. De eso surgen las siguientes métricas:

Accuracy: $(2.838 + 351) / 4.500 = 70,9 \%$.

Sensibilidad / recall sobre la clase demorado: $351 / (351 + 1.082) = 24,5 \%$.

Especificidad (clase no demorado): $2.838 / 3.067 = 92,5 \%$.


Precisión sobre la clase demorado: $351 / (351 + 229) = 60,5 \%$.

Al igual que el KNN, el Árbol muestra sensibilidad baja sobre los vuelos demorados: detecta aproximadamente 1 de cada 4 demoras reales (351 de 1.433, dejando pasar 1.082), frente a una especificidad muy alta del 92,5 % sobre los vuelos puntuales. Vuelve a mostrarse el sesgo hacia la clase mayoritaria provocado por el desbalance 68/32, que es el comportamiento que el criterio de negocio penaliza.

Aplicando la matriz de costos definida (FP = 1, FN = 5), el costo total del modelo es:


$$\text{Costo total} = (\text{FP} \times 1) + (\text{FN} \times 5) = (229 \times 1) + (1.082 \times 5) = 5.639$$

De nuevo la composición es lo determinante: los Falsos Negativos aportan 5.410 sobre 5.639, o es lo mismo decir que el 96 % del costo total proviene del error crítico para el negocio. El costo del Árbol es algo menor que el del KNN (5.639 frente a 5.772), porque comete menos Falsos Negativos (1.082 vs. 1.110) con un número de Falsos Positivos comparable.



La variable más relevante por mucho es visibilidad ($\approx 0,40$), seguida de congestion_aerea_Alta ($\approx 0,23$) y temporada_alta ($\approx 0,10$). Estas tres concentran la mayoría del poder predictivo y coinciden exactamente con las variables que el análisis bivalente había señalado como más asociadas a la demora (la correlación negativa de visibilidad con demora, el "punto de quiebre" operativo de la congestión alta y la mayor tasa de demora en temporada alta). Por otro lado, variables como

hora_salida_programada, dia_semana_Jueves/Viernes y distancia_vuelo son de mínima



importancia, también en línea con la baja ganancia de información detectada para esas variables en la fase de entendimiento de los datos.

El Árbol de Decisión alcanza una exactitud de 70,9 %, una sensibilidad sobre la clase demorado de 24,5 % y un costo total de 5.639.

Comparación entre knn y árbol.

	Modelo	Accuracy test	VN	FP	FN	VP
0	Árbol (max_depth=5, gini)	0.708667	2838	229	1082	351
1	KNN (k=41, euclídea)	0.704000	2845	222	1110	323

Análisis discriminante

El Análisis Discriminante Lineal se desarrolló íntegramente en la sección anterior, ahora se sintetizan los resultados que entran en la comparación final con los otros tres modelos.

Sobre el conjunto de prueba (4.500 vuelos no utilizados durante el entrenamiento, identificados como "casos no seleccionados" en SPSS), la función discriminante construida sobre las cinco variables numéricas (distancia_vuelo, hora_salida_programada, visibilidad, ocupacion_vuelo y temporada_alta) nos dió: 3.044 Verdaderos Negativos, 23 Falsos Positivos, 1.401 Falsos Negativos y 32 Verdaderos Positivos. Las métricas resultantes son una accuracy de 68,4%, una sensibilidad sobre la clase demorado de apenas 2,2%, una especificidad de 99,3% y una precisión sobre demorados de 58,2%.

Aplicando la matriz de costos definida (FN = 5, FP = 1), el costo total del modelo es:

$$\text{Costo total} = (23 \times 1) + (1.401 \times 5) = 23 + 7.005 = 7.028$$

El modelo presenta un desbalance extremo entre métricas, ya que clasifica casi perfectamente a los vuelos puntuales (99,3% de especificidad) pero apenas detecta a uno de cada cincuenta vuelos demorados. Los Falsos Negativos representan el 99,7% del costo total. Esta sensibilidad muy baja es la consecuencia directa de haber restringido el conjunto de predictores a variables numéricas para cumplir con los supuestos del LDA, dejando fuera del modelo a las categorías climáticas adversas y la congestión alta, que son los factores más fuertemente asociados con la demora en el dataset.

Regresión logística

Antes de mirar la matriz de clasificación, conviene revisar las medidas globales de ajuste del modelo, que indican si el conjunto de predictores aporta información relevante respecto a la variable objetivo.

Pruebas ómnibus de coeficientes de modelo

		Chi-cuadrado	gl	Sig.
Paso 1	Paso	994,852	17	,000
	Bloque	994,852	17	,000
	Modelo	994,852	17	,000

Tabla de contingencia para la prueba de Hosmer y Lemeshow

		demora = ,00		demora = 1,00		Total
		Observado	Esperado	Observado	Esperado	
Paso 1	1	926	895,649	124	154,351	1050
	2	869	864,238	181	185,762	1050
	3	814	826,046	236	223,954	1050
	4	813	805,024	237	244,976	1050
	5	758	778,877	292	271,123	1050
	6	714	724,254	336	325,746	1050
	7	679	687,864	371	362,136	1050
	8	623	634,616	427	415,384	1050
	9	550	550,087	500	499,913	1050
	10	409	388,347	641	661,653	1050

La prueba ómnibus arroja un Chi-cuadrado de 994,852 con 17 grados de libertad y Sig. = 0,000, lo que permite rechazar la hipótesis nula de que todos los coeficientes son simultáneamente iguales a cero. En otras palabras, el conjunto de predictores aporta información estadísticamente significativa para explicar la probabilidad de demora respecto al modelo nulo.

La prueba de Hosmer y Lemeshow compara las frecuencias observadas con las esperadas dentro de diez grupos formados según la probabilidad pronosticada. Mirando la tabla de contingencia, los valores observados y esperados son razonablemente cercanos en casi todos los

grupos (por ejemplo, en el grupo 9 observado = 500 vs esperado = 499,9; en el grupo 6 observado = 336 vs esperado = 325,7). La mayor discrepancia aparece en el grupo 10, donde el modelo subestima ligeramente las demoras (observado = 641 vs esperado = 661,7). En conjunto, el ajuste es aceptable y no muestra desviaciones sistemáticas graves.

Variables en la ecuación									
		B	Error estándar	Wald	gl	Sig.	Exp(B)	95% C.I. para EXP(B)	
								Inferior	Superior
Paso 1 ^a	hora_salida_programada	,009	,004	3,744	1	,053	1,009	1,000	1,018
	distancia_vuelo	,000	,000	,403	1	,525	1,000	1,000	1,000
	ocupacion_vuelo	,003	,001	5,087	1	,024	1,003	1,000	1,006
	temporada_alta	,482	,045	113,208	1	,000	1,620	1,482	1,770
	visibilidad	,002	,003	,198	1	,657	1,002	,995	1,008
	dia_semana_Domingo	,186	,082	5,078	1	,024	1,204	1,024	1,415
	dia_semana_Jueves	-,064	,085	,557	1	,455	,938	,794	1,109
	dia_semana_Martes	,052	,086	,367	1	,545	1,053	,891	1,245
	dia_semana_Miercoles	-,027	,084	,102	1	,750	,974	,826	1,148
	dia_semana_Sabado	,061	,084	,538	1	,463	1,063	,902	1,253
	dia_semana_Viernes	,187	,082	5,281	1	,022	1,206	1,028	1,415
	condiciones_climaticas_Lluvia	,466	,064	53,180	1	,000	1,593	1,406	1,806
	condiciones_climaticas_Niebla	,940	,098	91,568	1	,000	2,559	2,111	3,103
	condiciones_climaticas_Nublado	-,089	,057	2,434	1	,119	,915	,818	1,023
	condiciones_climaticas_Tormenta	1,579	,095	273,999	1	,000	4,851	4,024	5,849
	congestion_aerea_Alta	1,094	,059	344,609	1	,000	2,985	2,659	3,350
	congestion_aerea_Media	,466	,051	84,202	1	,000	1,594	1,443	1,760
	Constante	-2,058	,149	190,048	1	,000	,128		

a. Variables especificadas en el paso 1: hora_salida_programada, distancia_vuelo, ocupacion_vuelo, temporada_alta, visibilidad, dia_semana_Domingo, dia_semana_Jueves, dia_semana_Martes, dia_semana_Miercoles, dia_semana_Sabado, dia_semana_Viernes, condiciones_climaticas_Lluvia, condiciones_climaticas_Niebla, condiciones_climaticas_Nublado, condiciones_climaticas_Tormenta, congestion_aerea_Alta, congestion_aerea_Media.

La tabla de coeficientes es la pieza más interpretable del modelo. Cada B representa el cambio en el log-odds de demora ante una variación unitaria del predictor, mientras que Exp(B) traduce ese efecto en términos de odds ratio, indica cuántas veces se multiplica la chance de demora cuando la variable aumenta en una unidad (o cuando la categoría está presente, en el caso de las dummies), manteniendo el resto constante.

Las variables con mayor peso y significancia (Sig. = 0,000) son las que ya habíamos identificado como las más asociadas a la demora a lo largo de todo el trabajo:

- condiciones_climaticas_Tormenta (B = 1,579; Exp(B) = 4,851): es por lejos el predictor más fuerte. Que el vuelo se opere bajo tormenta multiplica por casi cinco las chances de que se demore respecto a un vuelo en condiciones despejadas (categoría de referencia), con un intervalo de confianza al 95% entre 4,02 y 5,85.
- congestion_aerea_Alta (B = 1,094; Exp(B) = 2,985): la congestión alta casi triplica las chances de demora respecto a la congestión baja.
- condiciones_climaticas_Niebla (B = 0,940; Exp(B) = 2,559): la niebla multiplica por 2,56 las chances de demora.
- temporada_alta (B = 0,482; Exp(B) = 1,620): operar en temporada alta incrementa las chances de demora en un 62%.

- condiciones_climaticas_Lluvia ($B = 0,466$; $\text{Exp}(B) = 1,593$) y congestion_aerea_Media ($B = 0,466$; $\text{Exp}(B) = 1,594$): ambas elevan las chances de demora en aproximadamente un 59%.

Las variables dia_semana_Domingo ($\text{Exp}(B) = 1,204$; $\text{Sig.} = 0,024$) y dia_semana_Viernes ($\text{Exp}(B) = 1,206$; $\text{Sig.} = 0,022$) resultan significativas y muestran que volar esos días incrementa modestamente las chances de demora respecto al lunes (categoría de referencia). El resto de los días de la semana (Jueves, Martes, Miércoles, Sábado) no presentan diferencias significativas, lo que coincide con el bajo poder discriminante de esta variable detectado en el análisis exploratorio.

La variable ocupacion_vuelo alcanza significancia ($\text{Sig.} = 0,024$) pero con un $\text{Exp}(B)$ de 1,003, es decir, un efecto prácticamente despreciable, cada punto porcentual adicional de ocupación incrementa las chances de demora apenas un 0,3%.

Llaman la atención dos resultados:

- visibilidad no resulta significativa ($\text{Sig.} = 0,657$), pese a que en el análisis univariante y en la matriz de correlaciones era una de las variables con mayor asociación con la demora ($r = -0,127$). Esto se explica por el solapamiento con las dummies climáticas, una vez que Niebla y Tormenta entran en el modelo, capturan gran parte de la información que aporta la visibilidad, y esta queda sin efecto propio.
- distancia_vuelo tampoco resulta significativa ($\text{Sig.} = 0,525$), consistente con lo visto en la Lambda de Wilks univariada del análisis anterior.
- condiciones_climaticas_Nublado ($\text{Sig.} = 0,119$) y hora_salida_programada ($\text{Sig.} = 0,053$, en el límite) tampoco aportan información significativa.

La constante del modelo es -2,058, lo que implica que en el escenario de referencia (lunes, despejado, congestión baja, fuera de temporada alta y con el resto de las variables continuas en cero) la probabilidad base de demora es muy baja (aproximadamente 11%, calculada como $1/(1+e^{2,058})$).

Tabla de clasificación^a

Observado		Pronosticado					
		Casos seleccionados ^b			Casos no seleccionados ^c		
		demora ,00	demora 1,00	Porcentaje correcto	demora ,00	demora 1,00	Porcentaje correcto
Paso 1	demora ,00	6668	487	93,2	2863	204	93,3
	demora 1,00	2620	725	21,7	1118	315	22,0
	Porcentaje global			70,4			70,6

a. El valor de corte es ,500

b. Casos seleccionados sel_train EQ 1

c. Casos no seleccionados sel_train NE 1

El modelo se aplicó sobre los 4.500 vuelos del conjunto de prueba (casos no seleccionados, sel_train = 0). La matriz de confusión arroja: 2.863 Verdaderos Negativos, 204 Falsos Positivos, 1.118 Falsos Negativos y 315 Verdaderos Positivos.

De allí se desprenden las siguientes métricas:

- Accuracy: $(2.863 + 315) / 4.500 = 70,6\%$.
- Sensibilidad / recall sobre la clase demorado: $315 / (315 + 1.118) = 22,0\%$.
- Especificidad (clase no demorado): $2.863 / (2.863 + 204) = 93,3\%$.
- Precisión sobre la clase demorado: $315 / (315 + 204) = 60,7\%$.

El modelo reproduce el mismo patrón que ya habíamos observado en el Análisis Discriminante, presenta una alta especificidad pero una sensibilidad muy baja. Es decir, clasifica correctamente a la enorme mayoría de los vuelos que efectivamente no se demoran, pero apenas detecta uno de cada cinco vuelos que sí se demoran. Sobre los 1.433 vuelos demorados del conjunto de prueba, el modelo identifica solamente 315.

Esta asimetría es consistente entre los conjuntos de entrenamiento y prueba (93,2% / 21,7% en entrenamiento frente a 93,3% / 22,0% en prueba), lo que indica que no hay sobreajuste y que el comportamiento del modelo es estable. El accuracy global de 70,6% sobre prueba es prácticamente idéntico al de entrenamiento (70,4%), lo que confirma la capacidad de generalización.

Selección de los modelos construidos

Sobre el mismo conjunto de prueba (4.500 vuelos, 30 % estratificado por la variable objetivo), las cuatro técnicas evaluadas arrojaron los siguientes resultados:

Modelo	Accuracy	VN	FP	FN	VP	Sensibilidad (recall)	Costo total
Árbol de Decisión (max_depth = 5, Gini)	70,9 %	2.838	229	1.082	351	24,5 %	5.639
Análisis Discriminante	68,4 %	3.044	23	1.401	32	2,2 %	7.028
KNN (k = 41, euclídea)	70,4 %	2.845	222	1.110	323	22,5 %	5.772
Regresión Logística	70,6 %	2.863	204	1.118	315	22,0 %	5.794

Lo primero que se puede ver del cuadro es que los cuatro modelos muestran un desempeño similar en exactitud global, con una diferencia entre el mejor y el peor de solo medio punto porcentual. Esta convergencia tiene sentido según el análisis exploratorio, en los cuatro casos las variables que terminan dominando la predicción son las mismas (visibilidad, condiciones climáticas adversas, congestión aérea alta y temporada alta), por lo que ningún algoritmo extrae información distinta a partir de la vista minable disponible. La señal predictiva ya está capturada por modelos más “simples”, y los márgenes diferenciales se juegan en cómo cada uno gestiona el desbalance 68/32 de la variable objetivo.

Como se anticipó en la fase de entendimiento del negocio y se formalizó en el criterio de evaluación, la exactitud global no es la métrica decisiva. El desbalance de la variable objetivo la vuelve engañosa (un clasificador trivial que prediga siempre "no demorado" rondaría el 68 % de aciertos sin tener ningún valor práctico). Por otro lado, los dos tipos de error tienen consecuencias económicas asimétricas, un Falso Negativo, o sea dejar a un pasajero demorado sin aviso ni compensación, se ponderó cinco veces más que un Falso Positivo (entregar un beneficio innecesario a un vuelo puntual). El criterio determinante es, entonces, el costo total ponderado.

Aplicando la matriz de costos definida (FN = 5, FP = 1), el ranking se ordena así:

- Árbol de Decisión: $5.639 = (229 \times 1) + (1.082 \times 5)$
- KNN: $5.772 = (222 \times 1) + (1.110 \times 5)$
- Regresión Logística: $5.794 = (204 \times 1) + (1.118 \times 5)$
- Análisis Discriminante: $7.028 = (23 \times 1) + (1.401 \times 5)$

El Árbol de Decisión presenta el costo total más bajo, con una diferencia de 1.389 unidades respecto al Análisis Discriminante, 133 frente al KNN y 155 frente a la Regresión Logística. Aunque las brechas son muy acotadas en términos absolutos, en los cuatro casos los Falsos Negativos representan aproximadamente el 96 % del costo total, lo que confirma que la sensibilidad sobre la clase demorado es el factor dominante de la decisión. El Árbol es

justamente el modelo que mejor logra detectar los vuelos efectivamente demorados (351 sobre 1.433), seguido por el KNN (323), la Regresión Logística (315) y luego el Análisis Discriminante (32). Cada demora adicional detectada es un pasajero al que la aerolínea puede notificar y compensar a tiempo, evitando el desgaste reputacional asociado.

En base a este análisis, se selecciona el Árbol de Decisión ($\text{max_depth} = 5$, criterio Gini) como modelo final para el objetivo de la clasificación de vuelos, debido a lo siguiente:

- Minimización de costos: es el modelo de menor costo total bajo la matriz definida, alineándose directamente con el criterio de éxito declarado en la fase de entendimiento del negocio.
- Mayor sensibilidad sobre la clase demorado (24,5 %): es el que mejor identifica el caso de uso central del agente inteligente, que son los vuelos que efectivamente se demorarán.
- Interpretabilidad: a diferencia del KNN que no construye un modelo explícito y de los modelos lineales, el Árbol permite visualizar de forma directa las reglas de decisión que llevan a clasificar un vuelo como demorado. La importancia de variables resultante ($\text{visibilidad} \approx 0,40$; $\text{congestion_aerea_Alta} \approx 0,23$; $\text{temporada_alta} \approx 0,10$) es trazable y coherente con lo observado en el análisis bivalente.
- Robustez operativa: no requiere escalamiento previo y es invariante a transformaciones monótonas, lo que simplifica el flujo de datos y reduce el riesgo de inconsistencias entre entrenamiento y producción.
- Buena generalización: a profundidad 5 las curvas de error en entrenamiento y prueba están prácticamente superpuestas en torno a 0,29, indicando ausencia de sobreajuste.

Es importante señalar que las cuatro técnicas comparten una limitación, la sensibilidad sobre la clase demorado se ubica en torno al 22-25%, lo que significa que tres de cada cuatro vuelos demorados todavía no son anticipados por el modelo. Esta limitación es propia de la información disponible y del desbalance de la variable objetivo, no de los algoritmos en sí.

Implementación

Esta sección describe cómo el modelo seleccionado debe utilizarse para colaborar concretamente con el problema de negocio planteado por DS Airlines, pasando así de una

gestión reactiva a una gestión proactiva de las demoras, anticipándolas al pasajero y orientando los beneficios compensatorios según su perfil.

Aplicación del modelo sobre casosNuevos.xlsx

El Árbol de Decisión entrenado se aplica sobre la hoja VuelosNuevos del archivo casosNuevos.xlsx, replicando exactamente la cadena de transformaciones definida en la fase de Preparación de los Datos. El proceso es el siguiente: se eliminan las columnas no predictoras (id_vuelo, tiempo_estimado_vuelo, puerta_embarque, tipo_avion, aeropuerto_origen y aeropuerto_destino), conservando id_vuelo en una columna paralela para asegurar la trazabilidad sobre el archivo original; se convierte hora_salida_programada de texto "HH:MM" a número decimal y temporada_alta a formato 0/1; se aplica la codificación one-hot con las mismas categorías de referencia utilizadas en entrenamiento (Despejado, Baja, Lunes); y se aplica el escalamiento min-max usando los parámetros (mínimos y máximos) calculados sobre el conjunto de entrenamiento, no recalculándolos sobre los casos nuevos. Esto preserva la coherencia entre lo aprendido por el modelo y lo aplicado en producción. El resultado es un dataset enriquecido en el que cada vuelo de casosNuevos.xlsx queda etiquetado con su predicción binaria (0 = no demorado, 1 = demorado) y la probabilidad asociada.

Flujo operativo del agente inteligente

La predicción del Árbol es la primera pieza del agente inteligente. Su salida dispara el resto de la cadena de acciones:

- Vuelos clasificados como no demorados (predicción = 0): no se ejecuta ninguna acción adicional. El pasajero opera bajo el flujo habitual y la aerolínea no incurre en costos compensatorios.
- Vuelos clasificados como demorados (predicción = 1): el agente dispara dos procesos simultáneos. Por un lado, una notificación anticipada al pasajero, que informa la posible demora antes de que se materialice en el aeropuerto y reduce el impacto reputacional. Por otro lado, una asignación de beneficio compensatorio, que utilizará el modelo de segmentación de pasajeros para determinar si el cliente afectado debe recibir un voucher de comida o un acceso a sala VIP, según su perfil sociodemográfico, su comportamiento de compra y su nivel de fidelización.

Esta arquitectura separa la predicción de la demora del criterio de compensación. La integración entre ambos modelos se realiza a través de la hoja VuelosNuevos_Clientes de

casosNuevos.xlsx, que vincula cada vuelo predicho con los pasajeros que viajan en él mediante el campo id_cliente. De este modo, un mismo vuelo demorado puede derivar en beneficios diferenciados por pasajero, alineando el costo compensatorio con el valor estratégico de cada cliente.

Generación del reporte para el Gerente

Una vez aplicado el modelo sobre la totalidad de los casos nuevos y cruzado el resultado con la información de pasajeros, se genera un reporte ejecutivo para el Gerente de DS Airlines que sintetiza los hallazgos operativos. El reporte contempla la cantidad y proporción de vuelos clasificados como demorados sobre el total de casos nuevos; la distribución de las demoras predichas según las variables más relevantes identificadas por el árbol (visibilidad, condiciones climáticas, congestión aérea, temporada alta), aprovechando la interpretabilidad nativa del modelo, la cantidad de pasajeros afectados y su distribución por segmento, la asignación tentativa de beneficios (voucher de comida vs. acceso a sala VIP) por segmento, y una estimación preliminar del costo económico de los beneficios a entregar, contrastada con el costo estimado de no actuar (reclamos, pérdida de fidelidad y posible fuga hacia la competencia).

Consideraciones para la operación en producción

Para que el sistema mantenga su validez en el tiempo, deben tenerse presentes algunas pautas operativas. Conviene realizar un reentrenamiento periódico del modelo (al menos una vez por trimestre, o ante cualquier cambio operativo relevante de la aerolínea (nuevas rutas, modificaciones de flota, cambios de política comercial)), ya que el modelo aprendió sobre los patrones del año anterior y estos pueden modificarse. Es necesario monitorear el desempeño en producción registrando la coincidencia entre las predicciones y los resultados reales, de manera de detectar a tiempo caídas en la sensibilidad o desplazamientos en la distribución de las variables predictoras. Ante la llegada de nuevos lotes de datos también debe verificarse la coherencia de las categorías (aeropuertos, tipo de avión, condiciones climáticas, etc.) respecto a las que estaban presentes durante el entrenamiento, la aparición de categorías nuevas requeriría un reentrenamiento del modelo. Finalmente, el umbral de decisión utilizado por defecto (0,5) puede ajustarse para gestionar la compensación entre cobertura y costo, un umbral menor incrementaría la cantidad de vuelos marcados como demorados, mejorando la sensibilidad a costa de más Falsos Positivos, en caso de que la dirección comercial decida priorizar aún más la fidelización por

sobre el costo compensatorio. Esta calibración es ajena al modelo y depende de una decisión estratégica del negocio.

En síntesis, el Árbol de Decisión seleccionado constituye una herramienta operativa concreta para que DS Airlines anticipe demoras, notifique al pasajero antes del incidente y oriente los recursos compensatorios de manera diferenciada según el perfil de cada cliente, materializando el agente inteligente planteado como objetivo central del proyecto.

Analisis multivariante (dataset Clientes)


A diferencia del análisis multivariante realizado sobre el dataset Vuelos, donde el foco estuvo puesto en la relación entre los predictores y la variable objetivo demora, en el dataset Clientes no existe una variable objetivo, porque el segundo objetivo del proyecto consiste en una tarea no supervisada, que es la caracterización de pasajeros mediante técnicas de agrupamiento. Por este motivo, el análisis multivariante apunta a comprender la estructura interna de las relaciones entre variables, detectar redundancias que deban tratarse durante la preparación de los datos e identificar qué dimensiones aportan poder discriminante para diferenciar perfiles de clientes.

Relaciones entre variables numéricas

Matriz de dispersión

Se construyó la matriz de dispersión entre las siete variables numéricas, considerando una muestra aleatoria de 15.000 registros para evitar la saturación visual propia de un dataset de 50.000 casos.

El gráfico revela un patrón claro, la mayor parte de las nubes de puntos se concentra en el extremo inferior izquierdo de cada panel, lo que es consistente con las distribuciones asimétricas hacia la derecha identificadas en el análisis univariante. Se aprecia una relación lineal positiva muy marcada entre `gasto_acumulado` y `gasto_acumulado_extra`, y relaciones positivas más difusas entre `cant_vuelos`,




gasto_acumulado, gasto_acumulado_extra y cantidad_millas. La variable edad y la variable anticipacion_compra_promedio no muestran asociaciones visualmente apreciables con el resto.

Correlaciones de Pearson

Para cuantificar las relaciones detectadas visualmente se calculó la matriz de correlaciones de Pearson sobre la totalidad de los 50.000 registros.

Los hallazgos principales son:

Correlación muy fuerte entre gasto_acumulado y gasto_acumulado_extra con 0,906 (significativa con $p < 0,001$). Esta relación, comparable en magnitud a la observada entre distancia_vuelo y tiempo_estimado_vuelo en el primer apartado ($r = 0,999$), constituye un caso de redundancia informativa que deberá tratarse en la fase de preparación, dado que ambas variables aportan prácticamente la misma información al modelo.




- Se identifican varias relaciones entre las variables de "valor económico del cliente". cant_vuelos correlaciona con gasto_acumulado ($r = 0,614$), con gasto_acumulado_extra ($r = 0,555$) y con cantidad_millas ($r = 0,497$). A su vez, cantidad_millas correlaciona con gasto_acumulado ($r = 0,555$) y gasto_acumulado_extra ($r = 0,502$). ingreso_mensual se vincula con todas estas variables en niveles más bajos (entre $r = 0,263$ y $r = 0,395$). Este conjunto de correlaciones describe un núcleo de cinco variables que se mueven coordinadamente y conforman el eje del valor económico del pasajero.
- Las variables edad y anticipacion_compra_promedio son prácticamente independientes, presentan correlaciones cercanas a cero con todas las demás variables (valores absolutos inferiores a 0,15). Esto las convierte en ejes informativos independientes del eje económico, lo que es valioso para la

segmentación porque pueden generar distinciones entre perfiles que el bloque económico no capturaría por sí solo.

Dado que más del 76% de los clientes no participa del programa de millas y registra cantidad_millas = 0, las correlaciones de esta variable pueden estar sesgadas por la masa de ceros. Para confirmar su comportamiento real se replicó el análisis restringido al subconjunto de afiliados al programa (11.948 registros).

Cuando se filtra el dataset a este subgrupo, las correlaciones de cantidad_millas se intensifican notablemente: con gasto_acumulado pasa de 0,555 a 0,837, con gasto_acumulado_extra de 0,502 a 0,766 y con cant_vuelos de 0,497 a 0,682. El resto de las correlaciones se mantienen en niveles similares. Esto confirma que, para quienes efectivamente acumulan millas, esta variable es prácticamente una función del comportamiento de compra, los clientes que más vuelan y más gastan son los que más millas juntan. Para el clustering general se trabajará con cantidad_millas tal como se encuentra en el dataset, ya que el valor 0 para los no afiliados tiene un significado semántico propio que aporta información sobre el perfil del cliente.



Relaciones entre variables categóricas

Para estudiar las asociaciones entre variables categóricas se construyeron tablas cruzadas en SPSS Statistics, complementadas con la prueba Chi-cuadrado de Pearson para evaluar la significatividad estadística de la asociación. Se priorizaron los pares más relevantes para la segmentación, clase_preferida con programaMillas, clase_preferida con ocupacion, y programaMillas con ocupacion.

Clase preferida y Programa de millas

Resumen de procesamiento de casos						
	Válido		Casos Perdido		Total	
	N	Porcentaje	N	Porcentaje	N	Porcentaje
clase_preferida * programaMillas	50000	100,0%	0	0,0%	50000	100,0%

Tabla cruzada clase_preferida*programaMillas

			programaMillas		Total
			No	Sí	
clase_preferida	Económica	Recuento	28820	8273	37093
		% dentro de clase_preferida	77,7%	22,3%	100,0%
	Ejecutiva	Recuento	7902	3035	10937
		% dentro de clase_preferida	72,3%	27,7%	100,0%
	Primera clase	Recuento	1330	640	1970
		% dentro de clase_preferida	67,5%	32,5%	100,0%
Total	Recuento		38052	11948	50000
	% dentro de clase_preferida		76,1%	23,9%	100,0%

La prueba Chi-cuadrado arroja un valor de 221,011 con 2 grados de libertad y significación asintótica de 0,000, lo que indica una asociación estadísticamente significativa entre ambas variables. El patrón observado es coherente, dentro de la clase Económica, el 22,3% de los clientes está afiliado al programa de millas, en la clase Ejecutiva la

Pruebas de chi-cuadrado

	Valor	df	Significación asintótica (bilateral)
Chi-cuadrado de Pearson	221,011 ^a	2	,000
Razón de verosimilitud	213,367	2	,000
N de casos válidos	50000		

a. 0 casillas (0,0%) han esperado un recuento menor que 5. El recuento mínimo esperado es 470,75.

proporción asciende al 27,7%; y en Primera clase alcanza el 32,5%. Existe una asociación monótona entre el escalón de clase tarifaria y la afiliación al programa, aunque la diferencia entre los extremos no es extrema (apenas 10 puntos porcentuales).

Clase preferida y ocupación

Pruebas de chi-cuadrado

	Valor	df	Significación asintótica (bilateral)
Chi-cuadrado de Pearson	7731,836 ^a	28	,000
Razón de verosimilitud	7530,779	28	,000
N de casos válidos	50000		

a. 0 casillas (0,0%) han esperado un recuento menor que 5. El recuento mínimo esperado es 20,17.

Resumen de procesamiento de casos

	Válido		Casos Perdido		Total	
	N	Porcentaje	N	Porcentaje	N	Porcentaje
clase_preferida * ocupacion	50000	100,0%	0	0,0%	50000	100,0%

Tabla cruzada clase_preferida*ocupacion

			ocupacion															Total
			Abogado	Arquitecto	Comerciante	Contador	Deportista	Docente	Ejecutivo	Empleado	Empresario	Estudiante	Ingeniero	Jubilado	Médico	Otro	Profesional independiente	
clase_preferida	Económica	Recuento	1176	1198	2870	1617	783	3824	1729	9997	1280	3152	2076	443	1135	2492	3321	37093
		% dentro de clase_preferida	3,2%	3,2%	7,7%	4,4%	2,1%	10,3%	4,7%	27,0%	3,5%	8,5%	5,6%	1,2%	3,1%	6,7%	9,0%	100,0%
	Ejecutiva	Recuento	740	412	541	400	370	554	1424	1423	1208	463	840	69	1118	456	919	10937
		% dentro de clase_preferida	6,8%	3,8%	4,9%	3,7%	3,4%	5,1%	13,0%	13,0%	11,0%	4,2%	7,7%	0,6%	10,2%	4,2%	8,4%	100,0%
	Primera clase	Recuento	199	63	35	46	115	0	382	10	491	0	137	0	329	25	138	1970
		% dentro de clase_preferida	10,1%	3,2%	1,8%	2,3%	5,8%	0,0%	19,4%	0,5%	24,9%	0,0%	7,0%	0,0%	16,7%	1,3%	7,0%	100,0%
Total	Recuento		2115	1673	3446	2063	1268	4378	3535	11430	2979	3615	3053	512	2582	2973	4378	50000
	% dentro de clase_preferida		4,2%	3,3%	6,9%	4,1%	2,5%	8,8%	7,1%	22,9%	6,0%	7,2%	6,1%	1,0%	5,2%	5,9%	8,8%	100,0%

La asociación entre clase preferida y ocupación es marcadamente más fuerte (Chi-cuadrado = 7.731,836, gl = 28, p < 0,001). La tabla revela una estratificación ocupacional muy clara entre las tres clases tarifarias. La clase Económica concentra a Empleados (27,0% de

quienes la eligen), Docentes (10,3%), Profesionales independientes (9,0%) y Estudiantes (8,5%). La clase Ejecutiva muestra una composición más diversificada, con Empleados (13,0%) y Ejecutivos (13,0%) en cabeza, seguidos por Empresarios (11,0%) y Médicos (10,2%). En la clase Primera, la composición se configura completamente: el 24,9% corresponde a Empresarios, el 19,4% a Ejecutivos, el 16,7% a Médicos y el 10,1% a Abogados, mientras que las categorías Docente, Jubilado y Estudiante prácticamente desaparecen (0%, 0% y 0% respectivamente). Esta estratificación es un insumo importante para el clustering, dado que ocupación y clase preferida actúan como variables complementarias para describir el nivel socioeconómico de cada perfil.

Programa de millas y Ocupación

Resumen de procesamiento de casos

	Válido		Casos Perdido		Total	
	N	Porcentaje	N	Porcentaje	N	Porcentaje
programaMillas * ocupacion	50000	100,0%	0	0,0%	50000	100,0%

Pruebas de chi-cuadrado

	Valor	df	Significación asintótica (bilateral)
Chi-cuadrado de Pearson	2884,007 ^a	14	,000
Razón de verosimilitud	2558,320	14	,000
N de casos válidos	50000		

a. 0 casillas (0,0%) han esperado un recuento menor que 5. El recuento mínimo esperado es 122,35.

Tabla cruzada programaMillas*ocupacion

			ocupacion														Profesional independiente	Total
			Abogado	Arquitecto	Comerciante	Contador	Deportista	Docente	Ejecutivo	Empleado	Empresario	Estudiante	Ingeniero	Jubilado	Médico	Otro		
programaMillas	No	Recuento	1712	1346	2773	1665	599	3504	1792	9164	1705	2997	2431	430	2003	2388	3543	38052
		% dentro de programaMillas	4,5%	3,5%	7,3%	4,4%	1,6%	9,2%	4,7%	24,1%	4,5%	7,9%	6,4%	1,1%	5,3%	6,3%	9,3%	100,0%
	Sí	Recuento	403	327	673	398	669	874	1743	2266	1274	618	622	82	579	585	835	11948
		% dentro de programaMillas	3,4%	2,7%	5,6%	3,3%	5,6%	7,3%	14,6%	19,0%	10,7%	5,2%	5,2%	0,7%	4,8%	4,9%	7,0%	100,0%
Total	Recuento		2115	1673	3446	2063	1268	4378	3535	11430	2979	3615	3053	512	2582	2973	4378	50000
	% dentro de programaMillas		4,2%	3,3%	6,9%	4,1%	2,5%	8,8%	7,1%	22,9%	6,0%	7,2%	6,1%	1,0%	5,2%	5,9%	8,8%	100,0%

La prueba Chi-cuadrado confirma una asociación significativa (valor = 2.884,007, gl = 14, $p < 0,001$). Entre los afiliados al programa, los Ejecutivos representan el 14,6% (frente al 4,7% entre los no afiliados) y los Empresarios el 10,7% (frente al 4,5%), mientras que entre los no afiliados los Docentes y Profesionales independientes están sobre-representados. El patrón refuerza lo observado, la afiliación al programa de millas se concentra en ocupaciones de mayor poder adquisitivo, lo que es consistente con su correlación con la clase tarifaria preferida y con las variables de gasto.

Relaciones entre variables numéricas y categóricas

Para detectar qué variables categóricas discriminan mejor entre los pasajeros se ejecutó un análisis de varianza (ANOVA) de un factor para cada combinación de variable categórica con cada variable numérica. Los resultados son los siguientes:

- Sexo: prácticamente no discrimina ninguna variable numérica. Sólo cantidad_millas resulta significativa ($F = 7,60$, $p = 0,0005$) y con un estadístico F sumamente bajo. Las restantes seis variables presentan valores de p mayores a 0,10. Esto sugiere que sexo no aporta poder discriminante para la segmentación.
- Ocupación: discrimina significativamente todas las variables numéricas, con estadísticos F muy elevados. Los más destacados son cant_vuelos ($F = 6.443,96$), gasto_acumulado ($F = 1.542,92$), ingreso_mensual ($F = 1.418,03$) y edad ($F = 1.292,37$). Es una variable de alto poder discriminante.
- Clase preferida: también discrimina con fuerza todas las variables numéricas. Los F más altos se observan en gasto_acumulado ($F = 19.091,93$), gasto_acumulado_extra ($F = 14.087,04$), ingreso_mensual ($F = 4.851,40$) y cantidad_millas ($F = 3.162,99$). Es la variable con mayor poder discriminante sobre las dimensiones de valor económico.
- Programa de millas: discrimina muy fuertemente cantidad_millas ($F = 17.826,07$, lógico por construcción) y cant_vuelos ($F = 3.001,90$), y de forma moderada el resto de las variables.
- Canal de compra: presenta poder discriminante limitado. Sólo discrimina con relevancia la edad ($F = 672,62$), mientras que para el resto los estadísticos son bajos ($F < 11$). Esto indica que el canal de compra captura principalmente un patrón generacional.




Gráfico de medias del poder discriminante de la clase preferida sobre el ingreso:

La jerarquía es nítida: los pasajeros de clase Económica registran un ingreso mensual medio cercano a los 2.200 USD, los de Ejecutiva, aproximadamente 4.800 USD, y los de Primera clase, alrededor de 8.500 USD. Los intervalos de confianza al 95% son muy estrechos debido al

tamaño de la muestra, lo que confirma que las diferencias entre los tres grupos son no sólo estadísticamente significativas sino también de magnitud sustantiva.

Análisis de Componentes Principales

Las correlaciones moderadas a fuertes detectadas entre cinco de las variables numéricas (cant_vuelos, gasto_acumulado, gasto_acumulado_extra, cantidad_millas e

ingreso_mensual) sugieren que existe una estructura latente subyacente que puede capturarse mediante un número reducido de dimensiones. Para confirmar esta hipótesis y, simultáneamente, generar variables transformadas que permitan visualizar posteriormente los perfiles de pasajeros en un espacio de menor dimensión, se aplicó un Análisis de Componentes Principales sobre las siete variables numéricas del dataset, conforme a lo solicitado en el enunciado del trabajo.

Adecuación del análisis

Antes de proceder a la extracción de componentes se evaluaron dos indicadores que permiten determinar si el dataset es apto para esta técnica.

Comunalidades		
	Inicial	Extracción
edad	1,000	,563
cant_vuelos	1,000	,606
gasto_acumulado	1,000	,855
gasto_acumulado_extra	1,000	,794
cantidad_millas	1,000	,527
ingreso_mensual	1,000	,304
anticipacion_compra_promedio	1,000	,500

Método de extracción: análisis de componentes principales.

Prueba de KMO y Bartlett		
Medida Kaiser-Meyer-Olkin de adecuación de muestreo		,761
Prueba de esfericidad de Bartlett	Aprox. Chi-cuadrado	141662,251
	gl	21
	Sig.	,000

Varianza total explicada									
Componente	Autovalores iniciales			Sumas de cargas al cuadrado de la extracción			Sumas de cargas al cuadrado de la rotación		
	Total	% de varianza	% acumulado	Total	% de varianza	% acumulado	Total	% de varianza	% acumulado
1	3,081	44,017	44,017	3,081	44,017	44,017	3,052	43,603	43,603
2	1,068	15,253	59,270	1,068	15,253	59,270	1,097	15,668	59,270
3	,925	13,216	72,486						
4	,776	11,084	83,570						
5	,582	8,320	91,890						
6	,478	6,833	98,723						
7	,089	1,277	100,000						

Método de extracción: análisis de componentes principales.

La medida de Kaiser-Meyer-Olkin de adecuación de muestreo arrojó un valor de 0,761 (aceptable). Indica que las correlaciones parciales entre las variables son suficientemente pequeñas como para que el análisis tenga sentido. La prueba de esfericidad de Bartlett produjo un Chi-cuadrado aproximado de 141.662,251 con 21 grados de libertad y significación de 0,000, lo que permite rechazar la hipótesis nula de que la matriz de correlaciones sea la identidad. Ambos indicadores confirman la pertinencia de aplicar la técnica sobre este dataset.

Extracción de componentes

A partir de la matriz de correlaciones se calcularon los autovalores y los vectores propios asociados a cada uno de los siete posibles componentes. La tabla de varianza total explicada se presenta a continuación:

Varianza total explicada						
Componente	Total	Autovalores iniciales		Sumas de cargas al cuadrado de la extracción		
		% de varianza	% acumulado	Total	% de varianza	% acumulado
1	3,081	44,017	44,017	3,081	44,017	44,017
2	1,068	15,253	59,270	1,068	15,253	59,270
3	,925	13,216	72,486			
4	,776	11,084	83,570			
5	,582	8,320	91,890			
6	,478	6,833	98,723			
7	,089	1,277	100,000			

Método de extracción: análisis de componentes principales.

El primer componente presenta un autovalor de 3,081 y captura el 44,017% de la varianza total del dataset. El segundo aporta un autovalor de 1,068 y un 15,253% adicional. En conjunto, los dos primeros componentes acumulan el 59,270% de la varianza, mientras que los siguientes componentes presentan autovalores decrecientes y aportes individuales cada vez menores.

Dado que el objetivo principal del análisis es la visualización de los perfiles de pasajeros en un espacio de baja dimensión, tal como solicita el enunciado del trabajo cuando pide utilizar técnicas de reducción de dimensionalidad para representar la caracterización de los pasajeros, se conservan los tres primeros componentes. Esta proyección tridimensional constituye la mejor representación visual posible del dataset y permitirá graficar posteriormente los clusters obtenidos, con la salvedad de que no agota la totalidad de la variabilidad presente en el conjunto original.

Interpretación de los componentes

La matriz de componente recoge los coeficientes que ponderan a cada variable original en cada uno de los dos componentes retenidos. Estos coeficientes representan las direcciones de proyección sobre las cuales se calculan los nuevos ejes y permiten identificar a qué se refiere conceptualmente cada componente.

Matriz de componente ^a		
	Componente	
	1	2
edad	,133	-,738
cant_vuelos	,777	-,047
gasto_acumulado	,918	,105
gasto_acumulado_extra	,883	,118
cantidad_millas	,719	,100
ingreso_mensual	,547	-,073
anticipacion_compra_promedio	-,142	,693

Método de extracción: análisis de componentes principales.

a. 2 componentes extraídos.

El primer componente presenta cargas elevadas y de signo positivo en gasto_acumulado (0,918), gasto_acumulado_extra (0,883), cant_vuelos (0,777), cantidad_millas (0,719) e ingreso_mensual (0,547), mientras que edad y anticipacion_compra_promedio aportan en magnitudes despreciables (0,133 y −0,142 respectivamente). Esta configuración confirma cuantitativamente lo que la matriz de correlaciones había anticipado, existe un eje latente que agrupa el conjunto de variables vinculadas al gasto, la frecuencia de vuelo y

el poder adquisitivo del pasajero. Este eje, que por sí solo explica casi la mitad de la variabilidad del dataset, puede interpretarse como un eje del valor económico del cliente, donde las puntuaciones altas identifican a los pasajeros más activos comercialmente y las puntuaciones bajas a los menos relevantes desde el punto de vista del negocio.

El segundo componente presenta cargas significativas únicamente en edad ($-0,738$) y `anticipacion_compra_promedio` ($0,693$), mientras que el resto de las variables aporta en magnitudes prácticamente nulas. Estas dos cargas tienen signos opuestos, lo cual define un eje que contrasta perfiles distintos, en su polo positivo se ubican los pasajeros más jóvenes que tienden a comprar con mayor anticipación, y en su polo negativo los pasajeros de mayor edad que compran con menor anticipación. Este componente, independiente del eje económico, puede interpretarse como un eje generacional asociado al patrón temporal de compra, y aporta una segunda fuente de variación útil para distinguir perfiles que el primer componente no captura.

Las puntuaciones de cada cliente sobre estos dos componentes serán conservadas como nuevas variables y utilizadas durante la fase de implementación para visualizar gráficamente, en dos dimensiones, los clusters obtenidos en la fase de modelado.

Síntesis del análisis multivariante

El análisis multivariante del dataset Clientes permite extraer las siguientes conclusiones, que serán utilizadas como insumos para la fase de Preparación de los Datos y para el modelado de segmentación:

Existe un caso de alta redundancia entre `gasto_acumulado` y `gasto_acumulado_extra` ($r = 0,906$), que deberá tratarse durante la preparación.

La variable `sexo` muestra muy bajo poder discriminante en todos los contrastes realizados, lo que la convierte en candidata a ser excluida del conjunto de variables a utilizar en el clustering.

Las variables `clase_preferida`, `ocupacion` y `programaMillas` son las que mejor discriminan los perfiles de clientes y conforman, junto con las numéricas del eje económico, los descriptores naturales de la segmentación.

El `canal_compra` discrimina principalmente por edad y aporta información secundaria sobre un patrón generacional.

La aplicación del Análisis de Componentes Principales confirma que las siete variables numéricas se organizan en torno a dos dimensiones latentes, un componente económico que concentra cinco variables y un componente generacional/temporal que recoge a las dos variables independientes. Las puntuaciones factoriales obtenidas se conservarán para utilizarlas como espacio de visualización bidimensional de los perfiles resultantes del clustering, tal como solicita el enunciado.

Preparación de los Datos (Dataset Clientes)

A diferencia del dataset de vuelos, cuyo tratamiento se orientó a alimentar algoritmos de clasificación supervisada, sobre el dataset de clientes se aplicarán técnicas de aprendizaje no supervisado: K-Medias, Cluster Jerárquico, Bietápico y Análisis de Componentes Principales. La totalidad de las técnicas se implementa en Python sobre Google Colab utilizando scikit-learn, SciPy.

Esta decisión metodológica tiene una consecuencia importante sobre la preparación, como todos los algoritmos operarán en el mismo espacio numérico, todas las variables que entren al modelado deben ser numéricas y estar en escala comparable. Las variables categóricas con poder discriminante identificadas en el análisis multivariante (ocupacion, clase_preferida, programaMillas, canal_compra) no se incluyen como insumo de los modelos sino que se conservan para una caracterización posterior de los clusters resultantes mediante tablas cruzadas. Esto implica resignar el manejo nativo de variables mixtas que ofrece el Two-Step de SPSS, pero garantiza que las cuatro técnicas descriptivas compartan el mismo input y sean directamente comparables sobre la misma representación de los datos.

Limpieza de datos

Se mantienen las decisiones tomadas en el análisis exploratorio, no se aplican tratamientos de imputación (no hay valores nulos), no se eliminan duplicados (no hay) y se conservan los outliers detectados en ingreso_mensual, gasto_acumulado, gasto_acumulado_extra, cant_vuelos y anticipacion_compra_promedio. Todos estos valores extremos responden a perfiles reales del dominio (clientes de alto poder adquisitivo, viajeros muy frecuentes, planificadores anticipados) y, en el contexto de una segmentación de clientes, suprimirlos eliminaría precisamente los perfiles que el modelo necesita identificar.

Decisiones estructurales sobre las variables

Eliminación de identificadores

La variable `id_cliente` se excluye del conjunto de variables predictoras, es un identificador técnico sin valor explicativo. Se conserva en una columna paralela para permitir la trazabilidad sobre el archivo `casosNuevos.xlsx` al momento de generar el reporte final con la asignación de beneficios.

Eliminación de la variable sexo

El análisis de varianza realizado en la fase anterior mostró que sexo no discrimina ninguna de las variables numéricas analizadas, con la única excepción de `cantidad_millas` ($F = 7,60$), valor sumamente bajo en comparación con los obtenidos para otras categóricas (`ocupacion` y `clase_preferida` superaron en muchos casos valores de F de varios miles). Las restantes seis variables numéricas presentaron $p > 0,10$ frente a sexo. Se decide por lo tanto excluirla del conjunto a utilizar en la segmentación, dado que su inclusión no aportaría poder discriminante y ampliaría innecesariamente la dimensionalidad.

Tratamiento de la multicolinealidad: `gasto_acumulado` vs `gasto_acumulado_extra`

El análisis multivariante reveló una correlación de Pearson de $r = 0,906$ entre `gasto_acumulado` y `gasto_acumulado_extra`, valor que indica una redundancia informativa fuerte aunque no perfecta, comparable a la registrada entre `distancia_vuelo` y `tiempo_estimado_vuelo` en el primer dataset.

En métodos basados en distancias como K-Medias y Jerárquico, mantener dos variables fuertemente correlacionadas equivale a duplicar el peso de la dimensión económica en el cálculo de las distancias entre observaciones, generando una sobre-ponderación artificial de ese eje sobre el resto. Se decide eliminar `gasto_acumulado_extra` y conservar `gasto_acumulado`. La variable `gasto_acumulado` captura el comportamiento económico primario del cliente (consumo en pasajes), mientras que el extra es un complemento que correlaciona estrechamente con él. La señal específica del cliente "premium" (que era la información diferencial que aportaba el extra) queda recogida por otras variables del dataset que se conservan para la caracterización posterior de los clusters, `clase_preferida`, `programaMillas` y `cantidad_millas`.

Tratamiento de las variables categóricas

Las variables ocupacion, clase_preferida, programaMillas y canal_compra mostraron poder discriminante relevante en el análisis multivariante (Chi-cuadrado significativo entre ellas y F altos en los ANOVA contra las numéricas). Sin embargo, no se incluyen como input de los modelos de clustering. Los cuatro algoritmos a aplicar (K-Medias, Jerárquico, Bietápico y ACP) operan sobre distancias euclídeas o sobre matrices de correlaciones, ambas definidas únicamente sobre variables continuas. Incluir las mediante codificación one-hot generaría variables binarias 0/1 cuya distancia euclídea es semánticamente cuestionable (un par de observaciones que difieren en una sola categoría tendría distancia 1 sin gradación posible) y desbalancearía el peso relativo entre dimensiones continuas y dimensiones binarias.

Estas cuatro variables categóricas se conservan en el dataset original y se utilizan posteriormente para caracterizar los clusters obtenidos, calculando para cada cluster la distribución porcentual de las categorías de cada variable. Este enfoque permite enriquecer la interpretación de los grupos sin contaminar el cálculo de las distancias en el modelado.

La variable provincia se excluye tanto del modelado como de la caracterización, ya que tiene un elevado número de categorías sin un patrón discriminante claro identificado en el análisis exploratorio, y su inclusión generaría una sobrecarga interpretativa que dificultaría la lectura de los clusters resultantes.

Variables conservadas para el modelado

Tras las decisiones anteriores, las variables que entran efectivamente al modelado son seis variables numéricas: edad, cant_vuelos, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio y gasto_acumulado.

Transformaciones aplicadas

Estandarización z-score de variables numéricas

Las seis variables numéricas conservadas operan en magnitudes muy distintas (la edad se mide en años, el ingreso mensual en miles de USD, las millas en decenas de miles). En métodos basados en distancia euclídea como K-Medias, Jerárquico y bietapico esta diferencia de escala provoca que las variables de mayor magnitud dominen el cálculo y oscurezcan la contribución de las demás. La misma consideración se aplica al ACP, si bien la técnica admite operar sobre la matriz de covarianzas o sobre la matriz de correlaciones,

esta última es la elección estándar cuando las variables están en unidades distintas, y resulta equivalente a operar sobre datos previamente estandarizados.

Se aplica por lo tanto la estandarización z-score sobre las seis variables numéricas:

$$Z_i = \frac{x_i - \bar{x}}{s}$$

Tras la transformación, todas las variables tienen media cero y desvío estándar unitario, lo que garantiza que cada una contribuya proporcionalmente a su variabilidad y no a su escala original.

Se opta por estandarización z-score en lugar del escalamiento min-max utilizado en el dataset de vuelos por una razón específica de este dataset, las distribuciones de ingreso_mensual, gasto_acumulado y cantidad_millas presentan outliers extremos válidos del dominio (máximos que superan en órdenes de magnitud a la media). En estas condiciones, min-max comprime la masa principal de los datos en un rango ínfimo del intervalo [0, 1], desperdiciando la mayor parte del espacio de representación. El z-score, al escalar por desvío estándar y no por máximo, distribuye mejor los datos del bloque central, aunque los outliers sigan ubicándose lejos del grueso de las observaciones.

Vista minable resultante

Se construye una única vista minable común a los cuatro algoritmos descriptivos (K-Medias, Jerárquico, Bietápico y ACP), garantizando que partan del mismo input y sean directamente comparables.

A diferencia del primer objetivo, no se realiza partición train/test ya que las técnicas de clustering son no supervisadas y no existe variable objetivo. El ajuste se realiza sobre el subconjunto de 30.518 pasajeros afectados por al menos un vuelo demorado, por las razones operativas justificadas en cada subsección del Modelado.

Variable	Tratamiento
edad	Estandarizada (z-score)
cant_vuelos	Estandarizada (z-score)
cantidad_millas	Estandarizada (z-score)
ingreso_mensual	Estandarizada (z-score)
anticipacion_comp ra_promedio	Estandarizada (z-score)
gasto_acumulado	Estandarizada (z-score)

Aplicación del Árbol de Decisión sobre casosNuevos.xlsx

La implementación operativa del primer objetivo se materializa mediante un notebook de Google Colab que aplica el Árbol de Decisión seleccionado en la fase de Modelado sobre el dataset casosNuevos.xlsx y, a partir de los vuelos clasificados como demorados, identifica al subconjunto de pasajeros que deberán recibir un beneficio compensatorio. Este

subconjunto constituye además el insumo del segundo objetivo del proyecto, la segmentación de pasajeros.

Reentrenamiento del modelo final

El notebook comienza cargando el dataset vuelos.xlsx y aplicando exactamente la misma cadena de transformaciones definida en la fase de Preparación de los Datos. Las decisiones replicadas son: eliminación de las variables aeropuerto_origen, aeropuerto_destino, tipo_avion, puerta_embarque y tiempo_estimado_vuelo, conversión de hora_salida_programada de texto a número decimal, conversión de temporada_alta a 0/1, codificación one-hot de dia_semana, condiciones_climaticas y congestion_aerea con las categorías de referencia Lunes, Despejado y Baja, y aplicación de min-max sobre las cuatro variables numéricas conservadas (hora_salida_programada, distancia_vuelo, ocupacion_vuelo y visibilidad).

Sobre la vista minable resultante se reentrena el árbol con los parámetros del modelo final (criterion='gini', max_depth=5, random_state=42). A diferencia del procedimiento de la fase de Modelado, donde se trabajó con la partición 70/30 para poder evaluar el desempeño, en esta etapa de implementación se utiliza la totalidad de los 15.000 vuelos del dataset original como conjunto de entrenamiento. Esta decisión maximiza la información disponible al momento de predecir sobre datos nuevos sin comprometer la validez metodológica, dado que la evaluación del modelo ya fue realizada en la fase anterior.

Aplicación sobre los casos nuevos

El archivo casosNuevos.xlsx contiene dos hojas que cumplen funciones distintas dentro del flujo. La hoja VuelosNuevos contiene 5.000 vuelos a clasificar, con las mismas variables operativas que el dataset de entrenamiento pero sin la variable objetivo demora, que es precisamente la que el modelo debe predecir. La hoja VuelosNuevos_Clientes, con 356.416 filas, es una tabla relacional que vincula cada vuelo con los identificadores de los pasajeros que viajan en él.

Sobre la hoja VuelosNuevos se aplica el mismo preprocesamiento utilizado en entrenamiento, encapsulado en una función reutilizable para garantizar exactitud en la replicación. Una vez generada la vista minable, las columnas se alinean con las del entrenamiento mediante la operación reindex de pandas, que asegura que los nombres y el orden de las dummies coincidan con los esperados por el modelo. El escalamiento min-max

se aplica con los parámetros calculados en entrenamiento, sin recalcularse sobre los casos nuevos, conforme a la práctica de evitar fugas de información entre conjuntos.

Resultados de la predicción

Sobre los 5.000 vuelos, el árbol clasificó 659 vuelos como demorados (13,18% del total) y los 4.341 restantes como no demorados (86,82%).

```
Distribución de la predicción sobre casos nuevos:  
0      86.82  
1      13.18  
  
Total vuelos clasificados como demorados: 659  
Total vuelos clasificados como no demorados: 4341
```

Esta proporción es menor a la registrada en el dataset de entrenamiento (31,85% de demorados), comportamiento que resulta coherente con la baja sensibilidad observada para este modelo en la fase de Evaluación (alrededor del 24,5%), al privilegiar la especificidad por sobre la sensibilidad bajo el criterio de minimización de costos, el árbol tiende a marcar como demorados únicamente aquellos vuelos cuyas condiciones operativas se acercan fuertemente a los patrones de demora identificados durante el aprendizaje.

Cruce con el dataset de clientes

A partir de los 659 vuelos predichos como demorados, el notebook ejecuta dos cruces sucesivos para obtener el conjunto final de pasajeros afectados. El primer cruce, contra la hoja VuelosNuevos_Clientes, devuelve 47.247 registros vuelo-cliente, siendo todas las relaciones entre vuelos demorados y sus pasajeros. Este número es esperablemente mayor a la cantidad de vuelos demorados, ya que cada vuelo transporta a múltiples pasajeros.

Sobre esos 47.247 registros se obtiene el conjunto de identificadores únicos de cliente, que resulta en 30.518 pasajeros distintos afectados por al menos un vuelo demorado. Este vector de id_cliente se cruza finalmente con el dataset Clientes.xlsx, recuperando para cada uno de los 30.518 clientes la totalidad de sus atributos sociodemográficos, comportamentales y de fidelización.

Dataset resultante y salida del notebook

El notebook genera como salida un archivo Excel con cuatro hojas que documentan cada paso del proceso. La hoja vuelos_clasificados contiene los 5.000 vuelos originales con la predicción agregada. La hoja vuelos_demorados aísla los 659 vuelos marcados como demorados. La hoja clientes_a_analizar contiene los 30.518 pasajeros únicos afectados con todos sus atributos, dataset que será el insumo directo del segundo objetivo del proyecto. La hoja relacion_demorados conserva la tabla relacional filtrada sobre los vuelos

demorados, necesaria para reconstruir posteriormente la asignación pasajero-vuelo-beneficio que constituye el entregable final solicitado en el enunciado.

Con este resultado queda cerrado el primer objetivo y disponible el insumo del segundo, que se desarrolla en la sección siguiente con la aplicación de las técnicas de clustering sobre los 30.518 pasajeros que requieren ser segmentados para determinar el tipo de beneficio a recibir.

Selección y aplicación de técnicas

En esta etapa se aborda el segundo objetivo del proyecto, la caracterización de pasajeros mediante técnicas de agrupamiento no supervisado. A diferencia de la clasificación de vuelos, donde el modelo predice una variable conocida, en este caso el algoritmo debe descubrir agrupamientos latentes en los datos sin información previa sobre la pertenencia de los individuos a grupos.

Se aplican cuatro técnicas: K-Medias, Cluster Jerárquico, Bietápico y Análisis de Componentes Principales. Las tres primeras corresponden estrictamente a tareas de agrupamiento; el ACP se utiliza como técnica de reducción de dimensionalidad, tanto para validar la estructura latente del dataset como para proporcionar un espacio bidimensional sobre el cual visualizar los clusters obtenidos por los algoritmos restantes (visualización requerida explícitamente por el enunciado del trabajo).

La mayoría de las técnicas se implementan en Python sobre Google Colab. K-Medias utiliza la implementación de scikit-learn (KMeans), Jerárquico se construye con `scipy.cluster.hierarchy` (linkage + `fcluster` + dendograma), Bietápico se aplica utilizando Two-Step de SPSS, y ACP se calcula con `sklearn.decomposition.PCA`. Las cuatro técnicas operan sobre la única vista minable definida en la fase anterior, garantizando comparabilidad directa entre sus resultados.

Modelado (Segmentación de Pasajeros)

Modelado de K-Medias

La implementación de K-Medias se realiza sobre el subconjunto de los 30.518 clientes que viajan en vuelos clasificados como demorados, dataset obtenido en la sección anterior. Esta decisión, alternativa a la planteada inicialmente sobre los 50.000 clientes completos del

dataset Clientes.xlsx, concentra la segmentación sobre la población realmente objetivo del problema de negocio, son los únicos pasajeros a los que el agente inteligente debe asignar un beneficio compensatorio, y por lo tanto son aquellos cuya correcta caracterización tiene impacto operativo directo. El ajuste sobre los 50.000 generaría perfiles latentes que incluirían comportamientos de clientes que el agente no atenderá, diluyendo la especificidad de los segmentos sobre la población realmente accionable.

La preparación del dataset sigue las decisiones documentadas en la sección de preparación de los datos, se conservan únicamente las seis variables numéricas de la vista minable (edad, cant_vuelos, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio y gasto_acumulado), excluyendo del modelado a id_cliente (que se mantiene aparte como columna de trazabilidad), a sexo, a gasto_acumulado_extra y a provincia. Las cuatro variables categóricas conservadas (ocupacion, clase_preferida, programaMillas y canal_compra) se reservan para la caracterización posterior de los clusters obtenidos. Sobre las seis variables numéricas se aplica la estandarización z-score, obteniéndose un dataset transformado con media cero y desvío estándar unitario en todas sus columnas, condición indispensable para que el cálculo de distancias euclídeas del algoritmo no se vea dominado por las variables de mayor magnitud.

Preparación de los datos

Se utiliza la vista minable numérica estandarizada construida en la sección anterior, que contiene las seis variables numéricas con media cero y desvío estándar unitario. La identificación de los clientes (id_cliente) se mantiene en una columna paralela para permitir la posterior asignación de beneficios sobre el dataset casosNuevos.xlsx.

Determinación del número de clusters

K-Medias requiere especificar de antemano el número k de grupos. Para seleccionarlo se utilizan dos criterios complementarios:

1. Método del codo (elbow method): se ejecuta K-Medias para valores de k entre 2 y 10, registrando para cada uno la inercia (suma de las distancias cuadradas de cada observación a su centroide). Al graficar la inercia en función de k, se identifica el punto donde la curva presenta un cambio de pendiente significativo (el "codo"): incrementar k más allá de ese punto produce mejoras marginales decrecientes y se considera que el modelo se complejiza sin ganar capacidad explicativa relevante.

2. Coeficiente de Silhouette: para cada valor de k se calcula el coeficiente de silhouette promedio, que mide qué tan similar es cada observación a las de su propio cluster comparado con las del cluster vecino más cercano. Valores cercanos a 1 indican clusters bien definidos y separados; valores cercanos a 0 indican que las observaciones se ubican en zonas de frontera entre clusters.

Ambos criterios se evalúan conjuntamente para seleccionar el valor de k que mejor balancee parsimonia y calidad del agrupamiento. El resultado específico, junto con el análisis de los perfiles obtenidos para cada cluster, se presenta en la sub-sección de Evaluación.

Parámetros utilizados

Parámetro	Valor
n_clusters	A determinar mediante elbow method y silhouette
init	k-means++ (inicialización inteligente que acelera la convergencia)
n_init	10 (el algoritmo se ejecuta 10 veces con diferentes inicializaciones y conserva la mejor solución, para mitigar la sensibilidad a la elección inicial de centroides)
max_iter	300 (máximo de iteraciones por ejecución; rara vez se alcanza)
random_state	42 (semilla fija para reproducibilidad, coherente con la utilizada en la fase de clasificación)

Visualización mediante ACP


Dado que el espacio sobre el que opera K-Medias es de seis dimensiones (no representable visualmente de forma directa), se utiliza la proyección bidimensional obtenida por Análisis de Componentes Principales sobre las mismas variables estandarizadas. Cada cliente se grafica en el plano (PC1, PC2), coloreando por cluster asignado. Esta visualización no constituye una validación cuantitativa del modelo, pero permite inspeccionar visualmente la separación de los grupos en las dos direcciones de mayor variabilidad del dataset.

Caracterización con variables categóricas

Aunque ocupacion, clase_preferida, programaMillas y canal_compra no participan en el cómputo del modelo, su distribución dentro de cada cluster es un insumo central para la interpretación. Una vez asignados los clusters, se construyen tablas cruzadas de cada categórica contra la etiqueta de cluster para identificar qué tipo de pasajero predomina en cada grupo (por ejemplo, si un determinado cluster concentra a empresarios afiliados al programa de millas o a estudiantes que compran por web).

Determinación del número de clusters

Para seleccionar el valor de k se evaluaron los dos criterios definidos en la sección de Selección y aplicación de técnicas, el método del codo y el coeficiente de silhouette, sobre el rango $k \in [2, 10]$. Por cada valor de k se ajustó el algoritmo con los parámetros establecidos (`init='k-means++'`, `n_init=10`, `max_iter=300`, `random_state=42`) y se registró tanto la inercia (suma de las distancias cuadradas de cada observación a su centroide) como el coeficiente de silhouette promedio. Para este último cálculo, dado el tamaño del dataset (~30.500 registros), se utilizó una muestra aleatoria de 5.000 puntos, lo que mantiene los tiempos de cómputo razonables sin perder representatividad.



La lectura de ambos criterios muestra patrones que conviene analizar conjuntamente. El coeficiente de silhouette alcanza su máximo en $k = 2$ con un valor cercano a 0,57, separación que se

mantiene marcadamente por encima de la observada para cualquier otro valor de k . Este resultado refleja principalmente la facilidad con que el algoritmo aísla al segmento de pasajeros premium del resto del dataset, dada la magnitud de las diferencias entre ese grupo y la masa general. A partir de $k = 3$, el silhouette se estabiliza en valores entre 0,20 y 0,26, propios de datasets de clientes con presencia de outliers válidos del dominio.

El método del codo no presenta un punto de quiebre tajante. La inercia disminuye de manera relativamente sostenida entre $k = 2$ y $k = 6$, con reducciones porcentuales que oscilan entre el 10% y el 14% al incorporar cada cluster adicional. A partir de $k = 7$, las reducciones se ubican en torno al 7%, sugiriendo que las particiones adicionales aportan ganancia decreciente.

Selección del valor de k

A los criterios estadísticos se suma una restricción operativa del problema de negocio que termina determinando la elección. El agente inteligente debe asignar a cada pasajero demorado uno de los beneficios compensatorios definidos por DS Airlines (voucher de

comida o acceso a sala VIP). Esta restricción impone dos límites prácticos sobre el número de segmentos posibles:

Un valor de $k = 2$ resultaría insuficiente. Si bien estadísticamente el silhouette favorece esta opción, la brecha entre dos únicos grupos sería excesivamente amplia y obligaría a tratar de manera idéntica a perfiles muy distintos, como por ejemplo a un estudiante ocasional y a un adulto profesional. Una segmentación tan gruesa anularía buena parte del valor del análisis y no permitiría refinar la asignación de beneficios.

Un valor de k mayor o igual a 4, en sentido opuesto, resultaría excesivo. La aerolínea no dispone de tantos beneficios diferenciados como para justificar más de tres segmentos accionables, y los grupos adicionales generarían separaciones sin correlación en una decisión operativa concreta. La complejidad interpretativa del modelo aumentaría sin un retorno equivalente en términos de utilidad de negocio.

Se selecciona por lo tanto $k = 3$ como el valor que mejor compatibiliza los criterios estadísticos con la operativa del negocio, permitiendo definir tres perfiles claramente diferenciados y mapeables a las opciones de beneficio disponibles.

Resultados del modelo final

Con $k = 3$ y los parámetros establecidos, el algoritmo converge en 9 iteraciones con una inercia final de 117.829,35. La distribución de los clientes entre los tres clusters resultantes es la siguiente:

segmento	n_clientes	porcentaje
Cliente Adulto Frecuente	14216	46.58
Cliente Joven Ocasional	13648	44.72
Cliente Premium	2654	8.70

Distribución de clientes por segmento:

Un cluster contiene 2.654 clientes (8,70% del total), un segundo cluster contiene 14.216 clientes (46,58%) y un tercero contiene 13.648 clientes (44,72%). Los dos clusters mayoritarios se distribuyen casi simétricamente y agrupan a la mayor parte de la población, mientras que el cluster minoritario concentra a un grupo claramente diferenciado.

Interpretación de los centroides

Los centroides obtenidos por el algoritmo en el espacio estandarizado se traducen a las unidades originales de cada variable para permitir una lectura directa en términos del negocio.

Centroides en escala original:

segmento	edad	cant_vuelos	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio	gasto_acumulado
Cliente Joven Ocasional	28.33	11.73	2168.48	2250.31	25.83	3394.49
Cliente Premium	39.50	55.52	49878.56	8146.15	14.04	33186.95
Cliente Adulto Frecuente	46.65	14.97	2967.61	2950.81	15.64	4628.41

Centroides en espacio z-score (lectura: cuán alejado del promedio general está cada segmento en cada variable):

segmento	edad	cant_vuelos	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio	gasto_acumulado
Cliente Joven Ocasional	-0.827	-0.337	-0.195	-0.202	0.267	-0.256
Cliente Premium	0.145	2.439	1.865	1.220	-0.278	2.156
Cliente Adulto Frecuente	0.768	-0.131	-0.160	-0.033	-0.204	-0.156

El primer centroide muestra valores marcadamente superiores al promedio en cant_vuelos (~56 vuelos frente a una media general de 17), cantidad_millas (~50.600 millas frente a 6.700 de promedio), ingreso_mensual (~8.200 USD frente a 3.100 USD) y gasto_acumulado (~33.200 USD frente a 6.500 USD). Su edad promedio es cercana a 40 años y la anticipación de compra se sitúa en torno a los 14 días. En el espacio estandarizado, las cargas positivas elevadas (entre 1,2 y 2,5 desvíos por encima de la media) en las cuatro variables económicas confirman que este cluster recoge a los pasajeros de mayor valor para la aerolínea.

El segundo centroide tiene una edad promedio cercana a 47 años, valores de cant_vuelos (~15) y gasto_acumulado (~4.600 USD) ligeramente por encima de la media general, y una anticipación de compra de 16 días. En z-score, su única variable con carga positiva relevante es la edad (+0,77 desvíos), siendo el resto cercanas a la media o ligeramente negativas.

El tercer centroide presenta la edad promedio más baja (~28 años), un volumen de vuelos y un gasto comparables al cluster anterior pero ligeramente inferiores, y una anticipación de compra promedio de 26 días, valor que es el mayor de los tres centroides. En z-score

destaca por su edad fuertemente negativa (-0,83 desvíos), lo que lo separa nítidamente de los otros dos.

Asignación de nombres descriptivos


Para que la segmentación resulte directamente utilizable por el negocio, a cada cluster se le asigna un nombre descriptivo en función de sus características observadas. La lógica de asignación se construye sobre los centroides en escala original, evitando depender del número arbitrario que el algoritmo asigna en cada corrida.

El cluster con mayor gasto acumulado promedio corresponde al perfil de mayor valor económico y se denomina Cliente Premium. De los dos clusters restantes, el de menor edad promedio corresponde al perfil joven y se denomina Cliente Joven Ocasional. El cluster restante, de mayor edad promedio, se denomina Cliente Adulto Frecuente.

Con esta asignación, los segmentos finales quedan definidos así: el Cliente Premium agrupa a 2.654 clientes (8,70% del total), el Cliente Adulto Frecuente agrupa a 14.216 (46,58%) y el Cliente Joven Ocasional agrupa a 13.648 (44,72%).

Visualización mediante Análisis de Componentes Principales

Dado que el espacio sobre el que opera el modelo tiene seis dimensiones y por lo tanto no es representable visualmente de forma directa, se utiliza la proyección sobre los tres primeros componentes principales obtenidos mediante un Análisis de Componentes Principales aplicado sobre las mismas seis variables estandarizadas. Esta solución coincide con la adoptada en la sección de Modelado de ACP, donde se justifica la retención de tres componentes como compromiso entre el criterio de Kaiser y el criterio del 80% de varianza acumulada. Se muestra en primer lugar la proyección sobre el plano (PC1, PC2), que constituye el espacio bidimensional habitual para representar segmentaciones, y posteriormente una proyección tridimensional que incorpora PC3 y permite observar la separación de los segmentos en el espacio completo de la solución del ACP.



El primer componente principal explica el 39,31% de la varianza total y el segundo el 17,56%, acumulando entre ambos el 56,87% de la información del dataset. La incorporación del tercer componente eleva la varianza acumulada al 72,25%. Las

cargas de cada variable sobre los tres componentes son las siguientes:

	PC1	PC2	PC3
edad	0.114	0.706	0.674
cant_vuelos	0.535	-0.023	-0.026
cantidad_millas	0.491	-0.165	-0.062
ingreso_mensual	0.375	-0.007	0.160
anticipacion_compra_promedio	-0.116	-0.679	0.718
gasto_acumulado	0.553	-0.114	-0.017

Cargas de cada variable sobre los componentes principales:


El primer componente está dominado por las variables de valor económico, con cargas elevadas y positivas en gasto_acumulado (0,553), cant_vuelos (0,535), cantidad_millas (0,491) e ingreso_mensual (0,375), mientras que edad y anticipacion_compra_promedio aportan magnitudes despreciables. Se interpreta como el eje del valor económico del cliente.

El segundo componente está definido casi exclusivamente por edad (0,706) y anticipacion_compra_promedio (-0,679) con signos opuestos. Se interpreta como un eje generacional contrapuesto asociado al patrón temporal de compra: el polo positivo recoge a los pasajeros mayores que compran con poca anticipación y el negativo a los más jóvenes que planifican con antelación.

El tercer componente está definido por anticipacion_compra_promedio (0,718) y edad (0,674), ambas positivas, con las cuatro variables económicas en magnitudes nulas. A diferencia de PC2, ambas se mueven en el mismo sentido, separando a los pasajeros que combinan mayor edad y planificación (adulto previsor) de los más jóvenes que compran sobre la fecha. Se interpreta como un eje generacional concordante, ortogonal a PC2.

La proyección bidimensional confirma que el Cliente Premium se proyecta desplazado hacia la derecha del plano, distinguido por su posición sobre PC1. Los Clientes Joven Ocasional y Adulto Frecuente se separan principalmente sobre PC2, reflejando su diferencia de edad y anticipación. Los centroides lo ratifican: el del Premium aparece desplazado sobre PC1

respecto del origen, mientras que los otros dos se ubican próximos a PC1 = 0 y se diferencian sobre PC2.



La proyección tridimensional incorpora PC3 como tercer eje y permite observar que la separación de los tres segmentos sigue siendo nítida también sobre esa dirección, aunque no aporta una distinción adicional sustantiva respecto de lo que ya muestra el plano (PC1, PC2). El segmento Premium se mantiene aislado sobre PC1, mientras que los dos

segmentos restantes ocupan zonas diferenciadas del subespacio (PC2, PC3) consistentes con sus respectivos perfiles de edad y anticipación de compra. La estructura confirma que las tres dimensiones latentes capturadas por el ACP son las que efectivamente organizan la segmentación obtenida por K-Medias.

Caracterización con variables categóricas

Aunque las cuatro variables categóricas no participaron del cómputo del modelo, su distribución dentro de cada segmento es central para la interpretación. Para cada categórica se construyó una tabla cruzada con la etiqueta de segmento, expresada en porcentajes por fila.

Distribución de ocupacion por segmento (%):

ocupacion	Abogado	Arquitecto	Comerciante	Contador	Deportista	Docente	Ejecutivo	Empleado	Empresario	Estudiante	Ingeniero	Jubilado	Médico	Otro	Profesional independiente
segmento															
Cliente Adulto Frecuente	5.32	4.12	8.29	4.97	1.16	10.25	4.42	23.19	5.23	0.00	7.57	2.24	6.62	6.04	10.57
Cliente Joven Ocasional	3.85	2.98	6.86	3.89	0.56	8.59	1.71	27.23	2.70	16.25	5.50	0.00	4.07	7.05	8.78
Cliente Premium	0.72	0.19	0.00	0.19	20.50	0.00	46.04	0.04	28.11	0.00	0.45	0.00	3.05	0.00	0.72

La distribución de la ocupación es la más reveladora del perfil de cada cluster. El Cliente Premium concentra ocupaciones de alto poder adquisitivo, con un 46,04% de Ejecutivos, un 28,11% de Empresarios y un 20,50% de Deportistas (estos últimos asociados al perfil de viajeros frecuentes y patrocinados), totalizando casi el 95% del segmento entre estas tres categorías. El segmento prácticamente no incluye Empleados (0,04%) ni Estudiantes (0%). El Cliente Adulto Frecuente, en contraste, está dominado por Empleados (23,19%) y categorías de clase media-profesional como Profesionales independientes (10,57%) y Docentes (10,25%). El Cliente Joven Ocasional muestra una composición claramente distinta, con Empleados (27,2%) y Estudiantes (16,3%) como categorías predominantes.

clase_preferida	Económica	Ejecutiva	Primera clase
segmento			
Cliente Adulto Frecuente	75.81	21.55	2.64
Cliente Joven Ocasional	80.43	18.06	1.51
Cliente Premium	32.40	44.91	22.68

Distribución de clase_preferida por segmento (%):

Se confirma la diferenciación. El Cliente Premium muestra una composición invertida respecto a la población general, con un 44,91% de Ejecutiva, un 22,68% de Primera clase y solo un 32,40% de Económica. Los otros dos están dominados por la clase Económica (75,81% en el Adulto Frecuente y 80,43% en el Joven Ocasional).

programaMillas	No	Sí
segmento		
Cliente Adulto Frecuente	79.02	20.98
Cliente Joven Ocasional	80.17	19.83
Cliente Premium	39.22	60.78

Distribución de programaMillas por segmento (%):

La afiliación al programa de millas refuerza esta jerarquía. El 60,78% de los Clientes Premium está afiliado, frente a apenas el 20% en los otros dos segmentos. Este patrón es coherente con la asociación entre programa de millas, clase tarifaria y nivel de gasto identificada en el análisis multivariante.

canal_compra	Aero puerto	Agencia	App	Web
segmento				
Cliente Adulto Frecuente	10.35	17.94	32.58	39.12
Cliente Joven Ocasional	7.45	11.02	42.36	39.17
Cliente Premium	9.01	14.66	35.04	41.30

Distribución de canal_compra por segmento (%):

Se muestran menores diferencias. El Cliente Premium tiene una leve preferencia por la Web (41,30%) por sobre la App (35,04%), mientras que en los otros dos segmentos la App es el canal mayoritario. La presencia de la Agencia es algo mayor en el Cliente Adulto Frecuente (17,94%) que en los demás, reflejando un patrón generacional de adopción tecnológica más lenta.

Las diferencias en este último cruce son moderadas, lo cual es coherente con el bajo poder discriminante identificado para esta variable en el análisis multivariante.

Perfil resumen de los segmentos

Integrando las medias numéricas, las modas categóricas y los tamaños de cada segmento se obtiene la tabla resumen que sintetiza los tres perfiles obtenidos.

Perfil resumen de cada segmento:

segmento	n_clientes	edad	cant_vuelos	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio	gasto_acumulado	ocupacion	clase_preferida	programa_Millas	canal_compra
Cliente Premium	2654	39.50	55.51	49803.39	8140.63	14.03	33170.04	Ejecutivo	Ejecutiva	Sí	Web
Cliente Adulto Frecuente	14216	46.65	14.96	2968.85	2950.27	15.66	4620.83	Empleado	Económica	No	Web
Cliente Joven Ocasional	13648	28.32	11.73	2167.65	2250.05	25.82	3396.68	Empleado	Económica	No	App

El **Cliente Premium** es un pasajero de aproximadamente 40 años, con cerca de 56 vuelos acumulados, más de 50.000 millas, ingreso mensual cercano a 8.200 USD y gasto acumulado de aproximadamente 33.200 USD. Su ocupación más frecuente es Ejecutivo, vuela mayoritariamente en clase Ejecutiva, está afiliado al programa de millas y compra por la Web.

El **Cliente Adulto Frecuente** es un pasajero de aproximadamente 47 años, con cerca de 15 vuelos acumulados, gasto cercano a 4.600 USD y anticipación de compra de aproximadamente 14 días. Su ocupación más frecuente es Empleado, vuela en clase Económica, no está afiliado al programa de millas y compra principalmente por la Web.

El **Cliente Joven Ocasional** es un pasajero de aproximadamente 29 años, con alrededor de 12 vuelos acumulados, gasto cercano a 3.600 USD y anticipación de compra de 14 días en promedio. Su ocupación más frecuente también es Empleado, vuela en clase Económica, no está afiliado al programa de millas y compra principalmente por la App.

Salida del notebook

El notebook genera como cierre un archivo Excel con tres hojas que documentan los resultados de la aplicación de K-Medias. La hoja clientes_con_segmento contiene los 30.518 clientes con todos sus atributos originales más el número de cluster y el nombre del segmento asignado. La hoja centroides_originales contiene los tres centroides expresados en las unidades originales de cada variable. La hoja perfil_segmentos contiene la tabla resumen con medias numéricas, moda de cada categórica y tamaño por segmento.

Estos resultados constituyen el primer modelo de segmentación obtenido sobre el dataset de clientes demorados y se utilizarán como referencia para la posterior comparación con los modelos de Cluster Jerárquico y Bietápico, a partir de la cual se seleccionará el modelo final que alimentará la asignación de beneficios del agente inteligente.

Modelado de Cluster Jerárquico y Bietápico

Cluster Jerárquico

Justificación de la técnica

El Cluster Jerárquico Aglomerativo es un método no supervisado que construye una jerarquía completa de agrupamientos a partir de la fusión sucesiva de observaciones o

grupos, hasta consolidar todo el dataset en un único cluster. En cada paso del proceso se fusionan los dos grupos más próximos según un criterio de enlace previamente definido, generando un árbol binario (dendrograma) que representa la estructura completa de las relaciones de similitud entre los registros. A diferencia de K-Medias, no requiere fijar de antemano el número de clusters, sino que éste se selecciona ex post observando dónde el dendrograma presenta saltos significativos en las distancias de fusión.

Se utiliza el método de enlace Ward, que en cada fusión minimiza el incremento de la suma de cuadrados intra-cluster. Es la elección estándar cuando las variables están estandarizadas y se busca una segmentación interpretable, dado que tiende a producir clusters compactos y de tamaños comparables. La métrica de distancia es la euclídea, consistente con el espacio z-score sobre el que se trabaja.

Preparación de los datos

Se utiliza la vista minable construida en la fase de Preparación de los Datos, conformada por las seis variables numéricas estandarizadas z-score: edad, cant_vuelos, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio y gasto_acumulado. La identificación del cliente (id_cliente) se mantiene en una columna paralela para la trazabilidad posterior sobre el reporte final de asignación de beneficios.

Las variables categóricas (ocupacion, clase_preferida, programaMillas, canal_compra) se conservan en el dataset original pero no participan del cómputo, y se utilizan a posteriori para enriquecer la caracterización interpretativa de los clusters resultantes.

Estrategia de muestreo y asignación al dataset completo

El Cluster Jerárquico Aglomerativo en su implementación clásica (SciPy) requiere construir y mantener en memoria la matriz de distancias completa entre todos los pares de observaciones. Para los 30.518 clientes a analizar esto implica 9 GB de RAM, que excede los recursos disponibles en entornos como Google Colab. Esta limitación es propia de la complejidad $O(n^2)$ en memoria del algoritmo y no resulta de una decisión metodológica del equipo.

El abordaje seguido es la estrategia estándar de **muestreo + asignación al centroide**, equivalente a la lógica que aplica SPSS Modeler internamente cuando se le suministra un dataset grande al nodo de Cluster Jerárquico. El procedimiento consiste en seleccionar una muestra aleatoria de 5.000 registros con semilla fija (random_state = 42, coherente con la

utilizada en la fase de clasificación), construir el linkage Ward y el dendrograma sobre esa muestra, elegir el número de clusters K en base al dendrograma y a métricas de calidad, aglomerar la muestra con K, calcular los centroides en el espacio z-score de cada cluster resultante y, finalmente, asignar cada uno de los 30.518 clientes al cluster cuyo centroide se encuentra a menor distancia euclídea. Este abordaje preserva la estructura jerárquica capturada en la muestra y la extiende al dataset completo sin perder validez metodológica.

Determinación del número de clusters

Selección de K: El dendrograma sobre la muestra de 5.000 registros muestra un salto de fusión muy marcado entre K=2 y K=1 (de 72,15 a 118,21 en distancia Ward), y un segundo salto relevante de K=3 a K=2 (de 60,89 a 72,15). El silhouette es de 0,484 en K=2 pero cae a 0,160 desde K=3 en adelante, lo cual es engañoso: K=2 separa trivialmente a los outliers Premium del resto sin discriminar perfiles intermedios. El criterio sustantivo prevalece sobre el numérico y se elige **K=3**, que es la primera segmentación con valor de negocio.

Parámetros utilizados

Parámetro	Valor
Método de enlace	Ward
Métrica de distancia	Euclídea
Tamaño de muestra para el dendrograma	5.000 registros
Número de clusters K	3
Criterio de corte	maxclust (corte por número de clusters, no por umbral de distancia)
random_state	42 (para la selección de la muestra aleatoria)
Asignación al dataset completo	distancia euclídea al centroide más cercano

Asignación a los 30.518 registros: Aplicado fcluster con K=3 sobre la muestra, se obtuvieron los tres clusters y se calcularon sus centroides en el espacio z-score como el promedio de las observaciones asignadas a cada uno. Posteriormente se calculó la distancia euclídea de los 30.518 clientes a cada uno de los tres centroides, asignando cada cliente al cluster del centroide más cercano. La distribución resultante sobre el dataset completo es de 3.781 clientes en el Cluster 1 (11,1%), 14.936 en el Cluster 2 (43,8%) y

15.374 en el Cluster 3 (45,1%). El silhouette sobre el dataset completo asciende a 0,21 (calculado con muestreo interno de 5.000 registros), un valor algo superior al obtenido sobre la muestra inicial, lo que confirma que la estructura capturada en la muestra se extiende coherentemente al universo completo.

Perfiles obtenidos:

Cluster	%	Edad	Vuelos	Millas	Ingreso (USD)	Anticipación	Gasto (USD)
1 - Premium	11,1%	39	51	41.481	7.710	14	29.225
2 - Adultos ocasionales	43,8%	46	14	2.559	2.842	12	4.214
3 - Jóvenes planificadores	45,1%	29	11	2.063	2.159	29	3.208


Caracterización categórica: El Cluster Premium concentra Ejecutivos (43%), Empresarios (30%) y Deportistas (18%); el 65% viaja en Ejecutiva o Primera clase y el 55% está afiliado al programa de millas. El Cluster Adultos ocasionales reúne Empleados (24%), Profesionales independientes y Docentes, mayoritariamente en clase Económica (77%), no afiliados al programa (80%) y con leve preferencia por canal Agencia/Aeropuerto. El Cluster Jóvenes planificadores es el único que concentra Estudiantes (16%) y usa la App como canal preferente (43%), también en clase Económica. El cluster 1 es candidato para el acceso a la sala VIP, mientras que los clusters 2 y 3, por perfil económico moderado y comportamiento de compra no Premium, son los candidatos al voucher de comida como beneficio compensatorio:

- Cluster 1 (Premium) → Sala VIP
- Clusters 2 y 3 (no Premium) → Voucher de comida

Visualización mediante Análisis de Componentes Principales

Dado que el espacio sobre el que opera el modelo tiene seis dimensiones y por lo tanto no es representable visualmente de forma directa, se utiliza la proyección sobre los tres primeros componentes principales obtenidos mediante un Análisis de Componentes Principales aplicado sobre las mismas seis variables estandarizadas. Esta solución coincide con la adoptada en la sección de Modelado de ACP, donde se justifica la retención de tres componentes como compromiso entre el criterio de Kaiser y el criterio del 80% de varianza acumulada. Se muestra en primer lugar la proyección sobre el plano (PC1, PC2), que constituye el espacio bidimensional habitual para representar segmentaciones, y

posteriormente una proyección tridimensional que incorpora PC3 y permite observar la separación de los segmentos en el espacio completo de la solución del ACP.



El primer componente principal explica el 39,31% de la varianza total y el segundo el 17,56%, acumulando entre ambos el 56,87% de la información del dataset. La incorporación del tercer componente eleva la varianza acumulada al 72,25%. Las cargas de cada variable sobre los tres componentes son las siguientes:

	PC1	PC2	PC3
edad	0.114	0.706	0.674
cant_vuelos	0.535	-0.023	-0.026
cantidad_millas	0.491	-0.165	-0.062
ingreso_mensual	0.375	-0.007	0.160
anticipacion_compra_promedio	-0.116	-0.679	0.718
gasto_acumulado	0.553	-0.114	-0.017

El primer componente está dominado por las variables del valor económico del cliente, con cargas elevadas y positivas en gasto_acumulado (0,553), cant_vuelos (0,535), cantidad_millas (0,491) e ingreso_mensual (0,375), mientras que edad y anticipacion_compra_promedio aportan en magnitudes despreciables. Este componente se interpreta como el eje del valor económico del cliente.


El segundo componente está definido casi exclusivamente por edad (0,706) y anticipacion_compra_promedio (-0,679), con signos opuestos. Se interpreta como un eje generacional contrapuesto asociado al patrón temporal de compra, donde el polo positivo recoge a los pasajeros de mayor edad que compran con poca anticipación y el polo negativo a los más jóvenes que planifican con mayor antelación.

El tercer componente está definido por anticipacion_compra_promedio (0,718) y edad (0,674), ambas con signos positivos, mientras que las cuatro variables económicas aportan en magnitudes prácticamente nulas. A diferencia de PC2, en PC3 ambas variables se mueven en el mismo sentido, separando a los pasajeros que combinan mayor edad con mayor planificación (perfil del adulto previsor) de los más jóvenes que compran sobre la fecha de vuelo. Se interpreta como un eje generacional concordante, ortogonal a PC2.

La proyección bidimensional permite confirmar que el Cliente Premium se proyecta claramente desplazado hacia la derecha del plano, distinguiéndose del resto por su posición

sobre el eje económico (PC1). Los Clientes Joven Ocasional y Adulto Frecuente, en cambio, se separan principalmente sobre el eje vertical (PC2), reflejando su diferencia de edad y anticipación de compra. Esta estructura confirma que las dos dimensiones latentes principales del dataset son las que efectivamente estructuran la segmentación obtenida por el Cluster Jerárquico

La proyección tridimensional incorpora PC3 como tercer eje. Sobre esa dirección los tres segmentos no muestran una separación adicional sustantiva respecto de lo que ya queda visible en el plano (PC1, PC2): el segmento Premium se mantiene aislado sobre PC1, mientras que los dos segmentos restantes ocupan regiones diferenciadas del subespacio (PC2, PC3) coherentes con sus respectivos perfiles de edad y anticipación de compra. La estructura tridimensional confirma que la solución obtenida por el Cluster Jerárquico se sostiene sobre las tres dimensiones latentes retenidas en el ACP.



Cluster Bietápico

Justificación de la técnica

El Cluster Bietápico combina dos fases. En la primera, *pre clustering*, el algoritmo hace un único pase sobre los datos y los condensa en micro-clusters representados por centroides, número de observaciones y suma de cuadrados. En la segunda, *clustering final*, aplica un algoritmo jerárquico aglomerativo sobre los micro-centroides.

Tiene dos virtudes frente a K-Medias y Jerárquico clásico. La primera es el manejo nativo de variables mixtas: en lugar de distancia euclídea usa una medida de log-verosimilitud que incorpora variables continuas y categóricas sin transformaciones artificiales como one-hot. La segunda es el manejo explícito de ruido: los casos que no se asimilan a ningún micro-cluster significativo se identifican como atípicos y se reportan aparte, lo que reduce la influencia de observaciones extremas y permite detectar perfiles minoritarios diferenciados.

Preparación de los datos

Se utiliza el dataset de 30.518 clientes a analizar obtenido en la sección anterior (pasajeros únicos afectados por al menos un vuelo clasificado como demorado por el árbol de decisión). A diferencia de K-Medias y Jerárquico, donde las categóricas se reservaron para la caracterización posterior, en el Bietápico se aprovecha la capacidad nativa del Two-Step de operar sobre variables mixtas, que constituía una limitación en la implementación de Python. El conjunto de variables del modelo es:

Como continuas, las seis ya identificadas como descriptores numéricos del cliente: edad, cant_vuelos, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio y gasto_acumulado. La variable gasto_acumulado_extra se mantiene excluida por su correlación de 0,906 con gasto_acumulado, conforme a la fase de preparación.

Como categóricas, las cuatro identificadas en el análisis multivariante como las que mejor discriminan los perfiles: ocupacion, clase_preferida, programaMillas y canal_compra. Sexo y provincia se mantienen excluidas: la primera por su nulo poder discriminante detectado en los ANOVA, la segunda por su elevado número de categorías sin patrón claro.

No se aplica estandarización previa sobre las continuas: SPSS realiza internamente la transformación z-score como parte del procedimiento. Las variables se cargan en su escala original y SPSS las normaliza al calcular las distancias.

Parámetros utilizados

El número de clusters se fija en K=3 de manera manual, no automática, para asegurar la coherencia con la asignación de beneficios definida por el negocio (un segmento Premium candidato a Sala VIP y los restantes candidatos a voucher de comida) y la comparabilidad con las soluciones obtenidas por K-Medias y Jerárquico, que también fueron configuradas con K=3. El resto de los parámetros corresponde a los valores por defecto del procedimiento de SPSS, considerados óptimos por la cátedra para datasets de esta escala.

Resultados de la segmentación


Sobre los 30.518 clientes a analizar, el procedimiento bietápico produjo la siguiente distribución: 17.093 clientes en el Cluster 1 (56,0% del total), 7.391 en el Cluster 2 (24,2%), 5.025 en el Cluster 3 (16,5%) y 1.009 clientes identificados como outliers (3,3%). El cociente entre el cluster más grande y el más pequeño es de 3,40, lo que indica una segmentación moderadamente desbalanceada pero sin la concentración extrema que se observaba en la

versión preliminar implementada en Python (donde un único cluster concentraba el 87,7% del dataset).

Distribución de clúster

		N	% de combinado	% del total
Clúster	1	17093	56,0%	56,0%
	2	7391	24,2%	24,2%
	3	5025	16,5%	16,5%
	Valor atípico (-1)	1009	3,3%	3,3%
	Combinado	30518	100,0%	100,0%
Total		30518		100,0%

Tamaños de clúster




Tamaño del clúster más pequeño	5025 (17%)
Tamaño del clúster más grande	17093 (57,9%)
Cociente de tamaños: De clúster más grande a clúster más pequeño	3,40

Resumen del modelo

Algoritmo	Bietápico
Entradas	10
Clústeres	3

Calidad de clúster




La medida de silueta de cohesión y separación informada por SPSS se ubica en la zona "Mala" de la escala (apenas por encima de 0,1, frente al umbral de 0,5 que define la zona "Regular"). Este valor, considerablemente inferior al 0,46 reportado por la implementación en Python, no debe leerse como una falla del modelo sino como una consecuencia

metodológica esperable de haber incorporado variables categóricas al input. La medida de silhouette que SPSS reporta es la clásica basada en distancia euclídea, mientras que el algoritmo bietápico optimiza una medida de log-verosimilitud que es la realmente adecuada para espacios mixtos. La calidad real del modelo se evalúa mejor a través de la importancia de los predictores y de la interpretabilidad de los perfiles obtenidos.

La inspección visual del peso de las variables en la formación de los clusters muestra que programaMillas aporta una contribución nula, lo cual coincide con el patrón observado en los tres segmentos (entre 76% y 80% de no afiliados en todos los clusters principales, sin diferenciación entre ellos). La variable anticipacion_compra_promedio también muestra una contribución baja, sin un patrón temporal distintivo que separe a los grupos. El resto de las variables (canal_compra, cant_vuelos, cantidad_millas, edad, gasto_acumulado, ingreso_mensual, ocupacion y clase_preferida) participan con pesos similares en el rango medio-alto, lo que indica que la segmentación se sostiene sobre una combinación equilibrada de descriptores económicos, demográficos y comportamentales.

Clústeres



Clúster	1	2	3
Etiqueta			
Descripción			
Tamaño	57,9% (17093)	25,0% (7391)	17,0% (5025)
Entradas	canal_compra Web (48,1%)	canal_compra App (50,1%)	canal_compra Agencia (59,5%)
	cant_vuelos 18,92	cant_vuelos 9,91	cant_vuelos 13,50
	clase_preferida Económica (65,9%)	clase_preferida Económica (91,2%)	clase_preferida Económica (90,3%)
	edad 39,48	edad 30,57	edad 42,57
	gasto_acumulado 6.555,90	gasto_acumulado 2.359,50	gasto_acumulado 3.592,09

ingreso_mensual 3.611,26	ingreso_mensual 1.256,95	ingreso_mensual 2.292,58
ocupacion	ocupacion Empleado (69,1%)	ocupacion Empleado (31,8%)
cantidad_millas 5.356,50	cantidad_millas 1.746,90	cantidad_millas 2.293,40
anticipacion_compra_promedio	anticipacion_compra_promedio	anticipacion_compra_promedio
programaMillas No (76,2%)	programaMillas No (79,7%)	programaMillas No (79,9%)

Caracterización de los clusters

Los perfiles numéricos medios de cada segmento, expresados en las unidades originales de cada variable, son los siguientes:

Cluster	tamaño	edad	vuelos	millas	ingreso (usd)	anticip.	gasto (usd)
C1	56,0%	39	19	5.357	3.611	19	6.556
C2	24,2%	31	10	1.747	1.257	24	2.359
C3	16,5%	43	14	2.293	2.293	20	3.592
Outliers	3,3%	40	55	87.188	11.613	17	52.063

Centroides													
		edad		cant_vuelos		anticipacion_compra_promedio		ingreso_mensual		cantidad_millas		gasto_acumulado	
		Media	Desv. Desviación	Media	Desv. Desviación	Media	Desv. Desviación	Media	Desv. Desviación	Media	Desv. Desviación	Media	Desv. Desviación
Clúster	1	39,4751	9,93054	18,9249	16,00235	18,5020	19,36904	3611,2608	2716,89546	5356,5034	13611,98762	6555,9024	7507,13734
	2	30,5665	11,84619	9,9077	7,09124	24,0253	25,86966	1256,9466	781,78151	1746,9004	5118,64744	2359,4996	2154,89568
	3	42,5747	11,55972	13,5015	8,98604	20,0856	20,70873	2292,5843	1685,94966	2293,3962	6284,96464	3592,0932	4283,61635
	Valor atípico (-1)	39,5173	9,13696	55,0704	21,86326	17,2735	24,07821	11612,9267	16472,93006	87188,3736	76887,00112	52062,9233	35961,52773
	Combinado	37,8293	11,49203	17,0432	15,77576	20,0598	21,61849	3088,5068	4145,57268	6683,5126	23156,77341	6556,1590	12353,48675

Frecuencias

		clase_preferida					
		Económica		Ejecutiva		Primera clase	
		Frecuencia	Porcentaje	Frecuencia	Porcentaje	Frecuencia	Porcentaje
Clúster	1	11270	49,8%	5254	78,2%	569	48,1%
	2	6739	29,8%	647	9,6%	5	0,4%
	3	4538	20,1%	361	5,4%	126	10,6%
	Valor atípico (-1)	67	0,3%	458	6,8%	484	40,9%
	Combinado	22614	100,0%	6720	100,0%	1184	100,0%

Cluster 1 - Profesionales digitales (56,0%):

Concentra a los pasajeros profesionales o calificados: 97,9% de los médicos, 83,3% de los abogados, 82,4% de los arquitectos, 80,9% de los Contadores, 79,2% de los comerciantes e ingenieros, 78,1% de los ejecutivos, 77,9% de

los profesionales independientes, 77,0% de los docentes y 71,2% de los empresarios. Edad media de 39 años, ingreso mensual de 3.611 USD y gasto acumulado de 6.556 USD, coherente con un perfil profesional asalariado. El 48,1% compra por Web, el 42,9% por App y solo el 9,1% por canales offline. El 65,9% viaja en clase Económica, con presencia significativa de Ejecutiva, y el 76,2% no está afiliado al programa de millas.

Cluster 2 - Empleados y estudiantes jóvenes (24,2%): El segmento más joven (31 años) y de menor poder adquisitivo (ingreso de 1.257 USD, gasto acumulado de 2.359 USD, 10 vuelos promedio). El 69,1% son Empleados y el 29,9% Estudiantes, sumando el 99% del cluster; captura al 72,8% de los Empleados del dataset y al 99,8% de los Estudiantes. El 91,2% viaja en Económica, el 79,7% no está afiliado al programa, y por canal el 50,1% usa App y el 45,9% Web, con uso prácticamente nulo de offline.

Cluster 3 - Pasajeros mayores no digitales (16,5%): Mayor edad media (43). Se distingue por compra offline: 59,5% por agencia y 40,5% en aeropuerto, sin uso de canales digitales. Composición ocupacional heterogénea (Empleado 31,8%, docente 12,0%, profesional independiente 10,6%, comerciante 8,8%), aunque concentra al 51,1% de los jubilados del dataset, asociados al canal offline. Ingreso de 2.293 USD y gasto de 3.592 USD, intermedio entre los Clusters 1 y 2. El 90,3% viaja en Económica y el 79,9% no está afiliado.

Grupo de outliers (3,3%): El procedimiento bietápico aisló 1.009 clientes como atípicos: 55 vuelos promedio (vs 10-19 en los clusters principales), 87.188 millas (vs 1.747-5.357), ingreso de 11.613 USD (vs 1.257-3.611) y gasto de 52.063 USD (vs 2.359-6.556). Concentra al 37,8% de los ejecutivos, 32,4% de los empresarios y 24,3% de los deportistas. Equivale al segmento Premium identificado en Jerárquico y K-Medias, pero el Bietápico lo

trata como ruido en lugar de cluster propio: no compromete el análisis porque el grupo es caracterizable y opera como segmento independiente. Candidato perfecto a Sala VIP por su perfil económico extremo y su correspondencia con ocupaciones Premium (Ejecutivos, Empresarios, Deportistas). Los tres clusters principales son candidatos al voucher de comida por su perfil no Premium y su comportamiento de compra no diferenciado.

Visualización mediante Análisis de Componentes Principales

El espacio sobre el que opera el modelo tiene diez dimensiones y no es representable visualmente, se hace un Análisis de Componentes Principales sobre las seis variables continuas estandarizadas, y se verifica mediante la medida Kaiser-Meyer-Olkin, que arroja un valor de 0,744 (aceptable, cercano a la categoría de bueno), y la prueba de esfericidad de Bartlett, con un Chi-cuadrado aproximado de 33.038,383 sobre 15 grados de libertad y significación de 0,000. Ambos indicadores confirman la pertinencia de aplicar la técnica sobre este conjunto de variables.

El primer componente principal presenta un autovalor de 2,358 y explica el 39,306% de la varianza total. El segundo aporta un autovalor de 1,054 y un 17,561% adicional, acumulando entre ambos el 56,867% de la información. La incorporación del tercer componente, con autovalor 0,923 y aporte del 15,384%, eleva la varianza acumulada al 72,252%. El gráfico de sedimentación muestra un codo nítido entre el segundo y el tercer componente, consistente con la retención de tres componentes como compromiso entre parsimonia y representación adecuada de la variabilidad original.


Las cargas factoriales de cada variable sobre los tres componentes son las siguientes:

Varianza total explicada						
Componente	Autovalores iniciales			Sumas de cargas al cuadrado de la extracción		
	Total	% de varianza	% acumulado	Total	% de varianza	% acumulado
1	2,358	39,306	39,306	2,358	39,306	39,306
2	1,054	17,561	56,867	1,054	17,561	56,867
3	,923	15,384	72,252	,923	15,384	72,252
4	,788	13,135	85,386			
5	,508	8,467	93,854			
6	,369	6,146	100,000			

Método de extracción: análisis de componentes principales.

Prueba de KMO y Bartlett

Medida Kaiser-Meyer-Olkin de adecuación de muestreo		,744
Prueba de esfericidad de Bartlett	Aprox. Chi-cuadrado	33038,383
	gl	15
	Sig.	,000



Matriz de componente^a

	Componente		
	1	2	3
edad	,175	-,724	,648
cant_vuelos	,821	,024	-,025
cantidad_millas	,753	,170	-,060
ingreso_mensual	,576	,007	,154
anticipacion_compra_pro medio	-,178	,697	,689
gasto_acumulado	,850	,117	-,016

Método de extracción: análisis de componentes principales.

a. 3 componentes extraídos.


	PC1	PC2	PC3
edad	0,175	-0,724	0,648
cant_vuelos	0,821	0,024	-0,025
cantidad_millas	0,753	0,170	-0,060
ingreso_mensual	0,576	0,007	0,154
anticipacion_compra_promedio	-0,178	0,697	0,689
gasto_acumulado	0,850	0,117	-0,016

El primer componente está dominado por las variables del valor económico del cliente, con cargas elevadas y positivas en gasto_acumulado (0,850), cant_vuelos (0,821), cantidad_millas (0,753) e ingreso_mensual (0,576), mientras que edad y anticipacion_compra_promedio aportan en magnitudes despreciables. Se interpreta como el eje del valor económico del cliente, donde las puntuaciones altas identifican a los pasajeros más activos comercialmente y las puntuaciones bajas a los menos relevantes desde el punto de vista del negocio.

El segundo componente está definido casi exclusivamente por edad (-0,724) y anticipacion_compra_promedio (0,697), con signos opuestos. Se interpreta como un eje generacional contrapuesto asociado al patrón temporal de compra, donde el polo positivo recoge a los pasajeros más jóvenes que planifican con mayor antelación y el polo negativo a los pasajeros de mayor edad que compran con menor anticipación.

El tercer componente está definido por anticipacion_compra_promedio (0,689) y edad (0,648), ambas con signos positivos, mientras que las cuatro variables económicas aportan en magnitudes prácticamente nulas. A diferencia de PC2, en PC3 ambas variables se mueven en el mismo sentido, separando a los pasajeros que combinan mayor edad con mayor planificación (perfil del adulto previsor) de los más jóvenes que compran sobre la fecha de vuelo. Se interpreta como un eje generacional concordante, ortogonal a PC2.


El gráfico muestra una estructura claramente delimitada por los dos componentes. Sobre el



eje horizontal (PC1, valor económico), los tres clusters principales se concentran en la franja izquierda del plano, con puntuaciones que oscilan aproximadamente entre -1 y 3, mientras que el grupo de outliers se proyecta marcadamente hacia la derecha, alcanzando puntuaciones superiores a 25. Esta separación lateral confirma que el valor económico extremo del grupo de outliers es la dimensión principal

que los distingue del resto del dataset y justifica que el procedimiento bietápico los haya

identificado como ruido en lugar de incorporarlos a algún cluster principal. Sobre el eje vertical (PC2, eje generacional), los tres clusters principales se separan entre sí de manera ordenada: el Cluster 2 ocupa la zona superior con puntuaciones positivas de PC2, consistente con su perfil de pasajeros jóvenes que compran con anticipación; el Cluster 3 se ubica en la zona inferior con puntuaciones negativas, alineado con su perfil de pasajeros mayores que compran con menor anticipación; y el Cluster 1 ocupa la franja intermedia, reflejando su composición etaria heterogénea de profesionales digitales adultos. La proyección bidimensional permite así visualizar simultáneamente las dos dimensiones de la segmentación: la separación radical de los outliers por valor económico (PC1) y la diferenciación generacional ordenada de los tres clusters principales (PC2).



La incorporación de PC3 al gráfico permite verificar que el ordenamiento general de los segmentos se mantiene. Los tres clusters principales conservan su disposición vertical en el plano (PC1, PC2) y el grupo de outliers continúa proyectándose hacia el extremo positivo del eje PC1. La tercera dimensión no introduce una separación adicional entre los clusters principales: las tres nubes mantienen un nivel de superposición similar al observado en la vista bidimensional. Esto

indica que el aporte explicativo del tercer componente (15,384% de varianza) opera principalmente como variabilidad interna a los segmentos, diferenciando subperfiles dentro de cada cluster, según la combinación de edad y anticipación más que como una dimensión que separe los grupos entre sí. La conclusión es que la estructura esencial de la segmentación queda razonablemente representada con los dos primeros componentes principales, y que PC3 cumple un rol secundario de captura de heterogeneidad intra-cluster.

Modelado de ACP

El Análisis de Componentes Principales se aplica sobre el mismo subconjunto de 30.518 clientes demorados utilizado por las técnicas de agrupamiento, garantizando la comparabilidad con ellas. A diferencia de K-Medias, Cluster Jerárquico y Bietápico, el ACP no constituye una técnica de segmentación, no asigna a cada cliente la pertenencia a un grupo. Su función dentro del trabajo es doble. Por un lado, valida cuantitativamente la

estructura latente del dataset, confirmando que las seis variables numéricas se organizan en torno a un número reducido de dimensiones independientes. Por otro, provee el espacio de baja dimensión sobre el cual se proyectan y visualizan los clusters obtenidos por las otras tres técnicas, dando respuesta al requisito del enunciado de representar la caracterización de los pasajeros mediante técnicas de reducción de dimensionalidad.

El procedimiento sigue el enfoque de estandarización previa de las variables, evaluación de la adecuación del dataset mediante la medida KMO y el test de esfericidad de Bartlett, extracción de los valores y vectores propios de la matriz de correlaciones, selección del número de componentes a retener e interpretación de cada componente a partir de sus cargas.

Preparación de los datos

El ACP opera sobre las seis variables numéricas de la vista minable común a las cuatro técnicas: edad, cant_vuelos, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio y gasto_acumulado. El identificador id_cliente se conserva en una columna paralela para vincular las puntuaciones resultantes con cada pasajero.

Conforme señala el material de la cátedra, cuando las variables están medidas en unidades distintas (años, dólares, miles de millas) el análisis debe realizarse sobre datos estandarizados, de lo contrario, las variables de mayor varianza dominarían artificialmente la primera componente y el resultado dependería de la escala de medición de cada variable. Por este motivo se estandarizan las seis variables mediante z-score. Estandarizar las variables y operar luego sobre su matriz de covarianzas es equivalente a trabajar directamente sobre la matriz de correlaciones de las variables originales, que es el enfoque estándar en este caso y el adoptado en este trabajo.

Adecuación del análisis

Antes de extraer los componentes se evalúa si el dataset es apto para la técnica.

Test de esfericidad de Bartlett:

Chi-cuadrado aproximado = 33,038.38

p-valor = 0

Medida KMO global = 0.7436

KMO por variable:

edad	0.687
cant_vuelos	0.730
cantidad_millas	0.787
ingreso_mensual	0.830
anticipacion_compra_promedio	0.749
gasto_acumulado	0.702

El test de esfericidad de Bartlett contrasta la hipótesis nula de que la matriz de correlaciones es la identidad (es decir, que las variables están incorrelacionadas y no tendría sentido aplicar el ACP). El estadístico arrojó un Chi-cuadrado aproximado de 33.038,38 con un p-valor inferior a 0,001, lo que permite rechazar la hipótesis nula y confirma que existen correlaciones aprovechables entre las variables.

La medida de adecuación muestral de Kaiser-Meyer-Olkin arrojó un valor global de 0,744, que se considera aceptable e indica que una proporción suficiente de la varianza entre las variables es varianza común susceptible de ser capturada por un número reducido de componentes. El KMO por variable se mantuvo en todos los casos por encima de 0,68, con ingreso_mensual (0,830) y cantidad_millas (0,787) como las variables mejor representadas. Ambos indicadores confirman la pertinencia de aplicar el ACP sobre este dataset.

Estos valores son coherentes con los obtenidos en el ACP exploratorio realizado en SPSS sobre el dataset original (KMO de 0,761), con diferencias atribuibles a que aquel análisis se efectuó sobre las siete variables numéricas y la totalidad de los 50.000 clientes, mientras que aquí se trabaja sobre seis variables (sin gasto_acumulado_extra, eliminada en la fase de Preparación) y sobre el subconjunto de 30.518 clientes demorados.

Extracción de componentes

Se calcularon los valores propios (autovalores) y los vectores propios de la matriz de correlaciones. Como las variables están estandarizadas, la varianza total del sistema es igual al número de variables (6), de modo que cada autovalor puede leerse como la cantidad de variables equivalentes que explica su componente.

Varianza total explicada:


Componente Autovalor % Varianza % Acumulado

PC1	2.3585	39.306	39.306
PC2	1.0537	17.561	56.867
PC3	0.9231	15.384	72.252
PC4	0.7881	13.135	85.386
PC5	0.5081	8.467	93.854
PC6	0.3688	6.146	100.000

El primer componente presenta un autovalor de 2,359 y explica el 39,31% de la varianza total. El segundo aporta un autovalor de 1,054 y un 17,56% adicional, acumulando entre ambos el 56,87% de la información del dataset. Los componentes siguientes presentan autovalores decrecientes: el tercero (0,923) aporta un 15,38%, el cuarto (0,788) un 13,14%, y los dos últimos cierran la varianza restante.

Selección del número de componentes

Se consideran los criterios habituales para decidir cuántos componentes retener.



Por el criterio de Kaiser, que retiene los componentes con autovalor superior a 1 (aquellos que explican más varianza que una variable original estandarizada), corresponde retener dos componentes: PC1 (2,359) y PC2 (1,054), mientras que el tercero queda apenas por debajo del umbral (0,923).

Por el criterio del 80% de varianza acumulada, el umbral orientativo utilizado en el material de la cátedra, serían necesarios cuatro componentes, ya que recién

con el cuarto se alcanza el 85,39% acumulado. Con dos componentes se llega al 56,87% y con tres al 72,25%.

Los dos criterios entran en tensión en este dataset, dado que ninguno de los valores intermedios cumple ambos simultáneamente. Se adopta como solución de compromiso la retención de los tres primeros componentes. Esta decisión se sustenta en tres argumentos. Primero, el autovalor de PC3 es 0,923, muy próximo al umbral de Kaiser, y su aporte de 15,38% sobre la varianza total no resulta despreciable frente al 13,14% de PC4 y al 8,47% de PC5. Segundo, la varianza acumulada del 72,25% queda sustancialmente más cerca del umbral del 80% que la solución de dos componentes, sin necesidad de incorporar PC4, cuyo autovalor (0,788) está claramente por debajo de la unidad y cuya interpretabilidad es menor. Tercero, una solución de tres dimensiones sigue siendo representable visualmente mediante una proyección tridimensional, manteniendo el rol del ACP como técnica de reducción de dimensionalidad con respaldo gráfico solicitado por el enunciado.

Interpretación de los componentes

La matriz de componentes recoge las cargas que ponderan a cada variable original en cada componente, permitiendo identificar a qué se refiere conceptualmente cada eje. Vectores propios (cargas de cada variable sobre cada componente):

El primer componente presenta cargas positivas y elevadas en gasto_acumulado (0,553), cant_vuelos (0,535), cantidad_millas (0,491) e ingreso_mensual (0,375), mientras que edad y anticipacion_compra_promedio aportan en magnitudes despreciables (0,114 y -0,116 respectivamente). Esta configuración identifica un eje latente que agrupa al conjunto de variables vinculadas al gasto, la frecuencia de vuelo y el poder adquisitivo del pasajero. Se interpreta como un eje del valor económico del cliente, donde las puntuaciones altas corresponden a los pasajeros comercialmente más activos y las bajas a los menos relevantes desde el punto de vista del negocio.

	PC1	PC2	PC3
edad	0,114	0,706	0,674
cant_vuelos	0,535	-0,023	-0,026
cantidad_millas	0,491	-0,165	-0,062
ingreso_mensual	0,375	-0,007	0,160
anticipacion_compra_promedio	-0,116	-0,679	0,718
gasto_acumulado	0,553	-0,114	-0,017

El segundo componente presenta cargas significativas únicamente en edad (0,706) y anticipacion_compra_promedio (-0,679), con signos opuestos, mientras que el resto de las variables aporta en magnitudes prácticamente nulas. Estas dos cargas de signo contrario definen un eje que contrasta perfiles distintos: en su polo positivo se ubican los pasajeros de

mayor edad que compran con poca anticipación, y en su polo negativo los pasajeros más jóvenes que planifican sus compras con mayor antelación. Se interpreta como un eje generacional contrapuesto asociado al patrón temporal de compra, independiente del eje económico.


El tercer componente presenta cargas elevadas en *anticipacion_compra_promedio* (0,718) y *edad* (0,674), ambas positivas, mientras que las cuatro variables del eje económico aportan en magnitudes despreciables (*ingreso_mensual* aporta 0,160 y el resto valores prácticamente nulos). A diferencia de PC2, donde *edad* y *anticipación* se contraponían, en PC3 ambas variables se mueven en el mismo sentido. En su polo positivo se ubican los pasajeros que combinan mayor edad con mayor planificación de la compra (perfil del adulto previsor), y en su polo negativo los pasajeros jóvenes que compran cerca de la fecha de vuelo. Geométricamente, PC2 y PC3 cubren juntos las dos direcciones independientes del subespacio formado por *edad* y *anticipacion_compra_promedio*, una contrapuesta y otra concordante, lo que es coherente con que estas dos variables fueran las únicas con correlación cercana a cero respecto del bloque económico en la matriz original.


Esta interpretación coincide con la obtenida en el ACP exploratorio realizado en SPSS sobre el dataset original, confirmando que la estructura latente del dataset es estable y no depende ni del número exacto de variables ni del subconjunto de clientes analizado.

Visualización


Se proyectan los 30.518 clientes sobre los tres primeros componentes. Las puntuaciones sobre PC1 y PC2 constituyen el espacio bidimensional que se reutiliza en los notebooks de K-Medias, Cluster Jerárquico y Bietápico para representar gráficamente los clusters obtenidos. Las puntuaciones sobre PC3 se conservan como tercera dimensión de la solución del ACP y se incorporan al archivo de salida del notebook.

La nube de clientes se concentra mayormente en el origen, con una cola hacia la derecha (PC1 alto) correspondiente a los pasajeros de mayor valor económico y una dispersión vertical sobre PC2 que recoge la diferencia generacional contrapuesta. La dirección horizontal ordena a los clientes por nivel de actividad comercial y la vertical por perfil etario y de anticipación de compra.





El biplot superpone las direcciones de las variables originales sobre el plano de los dos primeros componentes. Se observa que `gasto_acumulado`, `cant_vuelos`, `cantidad_millas` e `ingreso_mensual` apuntan hacia la derecha, definiendo el eje económico de PC1, mientras que `edad` apunta hacia arriba y `anticipacion_compra_promedio` hacia abajo, definiendo el eje generacional contrapuesto de PC2. Esta representación confirma visualmente la interpretación de los dos componentes principales.



La proyección tridimensional incorpora PC3 como tercer eje. Sobre esa dirección los clientes se ordenan según la combinación concordante de edad y anticipación, separando a los pasajeros que combinan alta edad con alta planificación de los que combinan baja edad con baja planificación, perfiles que en la proyección bidimensional sobre PC1 y PC2 quedaban superpuestos.

Salida del notebook

El notebook genera como salida un archivo Excel con tres hojas. La hoja `puntuaciones_pca` contiene las puntuaciones PC1, PC2 y PC3 de cada uno de los 30.518 clientes junto con su `id_cliente`; PC1 y PC2 son las que se utilizan como insumo directo para la visualización de los clusters en las otras técnicas y PC3 se conserva como tercera dimensión de la solución del ACP. La hoja `varianza_explicada` contiene la tabla de autovalores y porcentajes por componente. La hoja `vectores_propios` contiene la matriz de cargas de cada variable sobre cada componente.

Síntesis

El ACP cumple un rol transversal dentro del segundo objetivo. Confirma que el dataset de clientes demorados se estructura en torno a dos ejes latentes principales (un eje de valor económico y un eje generacional contrapuesto) y un eje secundario de menor peso que recoge la variación entre edad y anticipación de compra cuando se mueven en el mismo sentido. Los tres componentes retenidos explican en conjunto el 72,25% de la variabilidad, valor que constituye una solución de compromiso entre el criterio de Kaiser y el criterio del 80% de varianza acumulada. Adicionalmente, el ACP aporta el sistema de coordenadas bidimensional sobre el cual se visualizan los resultados de K-Medias, Cluster Jerárquico y Bietápico. A diferencia de esas tres técnicas, el ACP no produce una segmentación propia ni compete con ellas en la asignación de perfiles, sino que opera como herramienta de validación de la estructura del dataset y de reducción de dimensionalidad, integrando y dando coherencia visual al conjunto del análisis de segmentación.

Conclusiones finales del trabajo y aplicación de los modelos seleccionados al dataset casosNuevos.xls

Selección del modelo de segmentación

Para el segundo objetivo se desarrollaron tres técnicas de agrupamiento (K-Medias, Cluster Jerárquico y Cluster Bietápico) sobre la misma vista minable de seis variables numéricas estandarizadas y el mismo subconjunto de clientes demorados. El Análisis de Componentes Principales no se incluye en esta comparación porque no produce una segmentación: cumplió un rol transversal de validación de la estructura latente y de provisión del espacio de visualización bidimensional.

La comparación entre los tres modelos de agrupamiento se resume en el siguiente cuadro:

Modelo	Silhouette	Calinski-Harabasz	Distribución de los clusters	Estructura
K-Medias	0,219	8.453	8,7% / 46,6% / 44,7%	Tres grupos balanceados
Cluster Jerárquico	0,21	—	11,1% / 43,8% / 45,1%	Tres grupos balanceados
Cluster Bietápico	0,1	—	56% / 24,2% / 16,5% / 3,3% outliers	Un grupo dominante y dos minoritarios (con outliers)

El silhouette no resulta directamente comparable entre los tres modelos. K-Medias y Jerárquico operan sobre seis variables numéricas estandarizadas con distancia euclídea, métrica para la cual el silhouette es la evaluación natural. El Bietápico opera sobre diez

variables mixtas con distancia de log-verosimilitud, pero el silhouette informado por SPSS sigue siendo el euclídeo clásico, que no es la métrica optimizada por el algoritmo, por lo que cae a la zona "Mala". Esta caída es esperable y no implica fracaso del modelo, sino una limitación del indicador fuera de contexto. Tampoco se reporta Calinski-Harabasz para el Bietápico: SPSS no lo entrega y su cálculo manual sobre un modelo mixto no sería válido. La comparación debe apoyarse entonces en estructura, interpretabilidad y aplicabilidad al negocio.

El Bietápico produce una segmentación cualitativamente distinta: aísla al Premium como grupo de outliers (1.009 clientes, 3,3%) en lugar de constituirlo como cluster propio. Sus tres clusters principales (Profesionales digitales 56,0%, Empleados y estudiantes jóvenes 24,2%, Pasajeros mayores no digitales 16,5%) se ordenan por ocupación, canal y edad, no por valor económico. Esta segmentación es legítima y aprovecha el manejo nativo de variables mixtas, pero introduce dos dificultades: el Premium queda fuera de la solución y solo recuperable como ruido, lo que exige un parche metodológico innecesario en K-Medias y Jerárquico; y los tres clusters principales no se diferencian por valor económico, volviéndolos indistinguibles para la asignación de beneficios.

K-Medias y Jerárquico producen prácticamente la misma estructura: tres grupos balanceados con un Premium minoritario claramente identificable y dos segmentos mayoritarios diferenciados por edad y anticipación. Esta coincidencia entre técnicas independientes valida la solución.

Por estos factores (Premium como cluster propio, alineamiento con la lógica de beneficios, ejecución exacta sobre el dataset completo, coincidencia con Jerárquico) se selecciona K-Medias como modelo final. Sus tres segmentos (Premium, Adulto Frecuente y Joven Ocasional) se utilizan para la asignación de beneficios.

Asignación de beneficios según el segmento

A partir de los tres segmentos de K-Medias se define la asignación del beneficio compensatorio según la política de DS Airlines, que dispone de dos beneficios de distinto costo: el acceso a la sala VIP, reservado a pasajeros premium, y el voucher de comida.

Segmento	Beneficio	Justificación
Cliente Premium	Sala VIP	Único segmento de alto valor (mayor gasto, ingreso, millas y clase tarifaria); justifica el beneficio de mayor costo

Cliente Adulto Frecuente	Voucher de comida	Perfil económico moderado, sin características premium
Cliente Joven Ocasional	Voucher de comida	Perfil económico moderado, sin características premium

El acceso a la sala VIP, por ser el beneficio de mayor costo, se reserva al segmento cuyo valor estratégico lo justifica, mientras que los dos segmentos de perfil económico moderado reciben el voucher de comida. De los 30.518 clientes demorados, 2.654 (el segmento Premium) quedan asignados a sala VIP y los 27.864 restantes a voucher de comida.

Aplicación al dataset casosNuevos: reporte final de beneficios

Como cierre del trabajo se agrega al notebook de K-Medias una etapa final con un reporte que indica, para cada pasajero de cada vuelo de casosNuevos, si su vuelo fue predicho como demorado y qué beneficio le corresponde. Se construye cruzando tres fuentes: la relación completa vuelo-cliente de casosNuevos.xlsx (356.416 relaciones entre los 5.000 vuelos nuevos y sus pasajeros), la predicción de demora de cada vuelo generada por el Árbol de Decisión, y el segmento y beneficio asignado a cada cliente por K-Medias. Para cada par vuelo-pasajero, si el vuelo fue predicho demorado se asigna el beneficio según el segmento del pasajero; y no fue predicho como demorado, no corresponde beneficio.

Ejemplo pasajeros del vuelo demorado 10018:

	id_vuelo	id_cliente	predicho_demora_vuelo	segmento	tipo_beneficio
252	10018	645	SI	Cliente Joven Ocasional	Voucher comida
253	10018	1226	SI	Cliente Adulto Frecuente	Voucher comida
254	10018	1507	SI	Cliente Joven Ocasional	Voucher comida

El reporte resultante contiene las 356.416 relaciones vuelo–pasajero. De ellas, 47.247 corresponden a vuelos predichos como demorados, y se distribuyen en 4.044 asignaciones de sala VIP (pasajeros del segmento Premium) y 43.203 de voucher de comida (segmentos Adulto Frecuente y Joven Ocasional). Las 309.169 relaciones restantes corresponden a vuelos no demorados y no generan beneficio.

El notebook exporta un archivo Excel con dos hojas: clientes_categorizados, con los 30.518 clientes demorados, su segmento y su beneficio; y reporte_beneficios, con la tabla pasajero–vuelo–beneficio sobre la totalidad de los casos nuevos, en el formato solicitado por el enunciado.

Notebook integrador y reporte final

Como cierre del trabajo, y para que la solución desarrollada constituya una herramienta efectivamente operativa y no un conjunto de notebooks dispersos, se elaboró un cuaderno único de Google Colab que integra el pipeline completo de ambos objetivos del proyecto. Este notebook parte de los tres datasets originales provistos por la cátedra (Vuelos.xlsx, Clientes.xlsx y casosNuevos.xlsx), reentrena el Árbol de Decisión final con los parámetros seleccionados en la fase de Evaluación (criterion='gini', max_depth=5, random_state=42) sobre la totalidad de los 15.000 vuelos disponibles, lo aplica sobre los 5.000 vuelos de VuelosNuevos, deriva el subconjunto de 30.518 pasajeros únicos afectados por al menos un vuelo demorado, entrena sobre ese subconjunto el modelo K-Medias con $k = 3$ y la estandarización z-score de las seis variables numéricas conservadas, y asigna a cada cliente segmentado el beneficio compensatorio correspondiente conforme a la lógica definida (Cliente Premium -> Sala VIP; Cliente Adulto Frecuente y Cliente Joven Ocasional -> Voucher de comida).

La replicación de las transformaciones se realiza encapsulándolas en funciones reutilizables que garantizan que entrenamiento y casos nuevos reciban exactamente el mismo tratamiento (mismas categorías de referencia para la codificación dummy, mismos parámetros de escalamiento min-max calculados sobre el conjunto de entrenamiento y aplicados sin recalcular sobre casosNuevos). La asignación de nombres descriptivos a los clusters se implementa mediante una lógica robusta basada en las características de cada centroide (cliente Premium = mayor gasto_acumulado promedio; entre los dos restantes, joven Ocasional = menor edad promedio, adulto Frecuente = mayor edad promedio), de modo que los nombres asignados se mantienen estables aún ante variaciones en el orden numérico que scikit-learn pudiera devolver entre corridas o versiones.

La salida del notebook es un único archivo Excel (reporte_final_DS Airlines.xlsx) compuesto por dos hojas. La hoja asignacion_beneficios contiene la totalidad de los pares vuelo-pasajero presentes en la tabla relacional VuelosNuevos_Clientes, con cuatro columnas: ID vuelo, ID pasajero, Predicho_demora_vuelo (SI / NO) y Tipo beneficio (Sala VIP, Voucher comida o - cuando el vuelo no está predicho como demorado). La hoja solo_demorados replica el mismo formato pero filtrada únicamente a los pares cuyo vuelo fue clasificado como demorado, proveyendo así la vista operativa directa para el agente inteligente, dado que son esos casos los que disparan la notificación anticipada al pasajero y la asignación del beneficio compensatorio. Esta doble salida responde a dos necesidades distintas, la primera hoja constituye el reporte integral exigido por el enunciado del trabajo,

mientras que la segunda funciona como la lista accionable que efectivamente sería consumida en producción por el sistema de gestión de beneficios de DS Airlines.

Conclusiones finales del trabajo

El proyecto abordó de manera integral los dos objetivos planteados por DS Airlines. Para el primero, la clasificación de vuelos, se evaluaron cuatro técnicas supervisadas y se seleccionó el Árbol de Decisión por minimizar el costo total bajo la matriz de costos definida ($FN = 5$, $FP = 1$), criterio alineado con la prioridad del negocio de no dejar pasajeros demorados sin compensación. Para el segundo, la segmentación de pasajeros, se evaluaron tres técnicas de agrupamiento y se seleccionó K-Medias por producir la segmentación más balanceada y accionable, complementada por el ACP como herramienta de validación y visualización.

La integración de ambos modelos da forma al agente inteligente propuesto: el Árbol de Decisión anticipa qué vuelos se demorarán, y K-Medias determina, para cada pasajero afectado, el beneficio compensatorio más adecuado a su perfil. El reporte final sobre casosNuevos demuestra el funcionamiento conjunto de la solución sobre datos no vistos, pasando de una gestión reactiva de las demoras a una gestión proactiva que anticipa el incidente y orienta los recursos compensatorios de manera diferenciada según el valor de cada cliente.

Entre las limitaciones del trabajo se destaca la baja sensibilidad de los modelos de clasificación sobre la clase demorado (en torno al 22–25%), propia del desbalance de la variable objetivo y de la información disponible, que implica que una parte de los vuelos efectivamente demorados no es anticipada. Esta limitación, junto con las consideraciones de reentrenamiento periódico y monitoreo en producción, marca las líneas de mejora futuras del sistema.